



Gymnázium J. K. Tyla

DarkFactory
Agentic and Harness Engineering:
Artificial Intelligence in Practice

THESIS

Author: Patrik Marius, 4.D
Supervisor: Michal Dočekal

Extent: 4499 words / 29341 characters

Declaration

I declare that I prepared this specialized thesis independently under the supervision of the supervisor named on the title page. All sources used are listed in the bibliography and information derived from them is cited in the text. I agree that the printed version may be archived at Gymnázium J. K. Tyla and used there as a reference for future student work or for presenting education at GJKT.

In Hradci Králové on

.....

Author signature:

Annotation

[EN] This thesis examines the principles of agentic engineering: effective engineering practices for development with artificial intelligence through agentic systems and the architecture of these systems. The practical contribution of the thesis is the design and implementation of DarkFactory — an agentic harness installable as a GitHub App. The system aims to maximize automation of the development lifecycle, from interpreting requirements in GitHub Issues, through planning, to code development and merging changes. The thesis reflects that current agentic systems cannot be regarded as fully autonomous: language models require deterministic guardrails, context management, and human involvement (*Human-in-the-loop*).

Keywords

, Agent Harness , Agent Loop , , , , , Embedding , , , Hook , KV Cache , LLM , Loop Engineering , MCP ,
Plugins , , Skills , , Transformer

Contents

Declaration	2
Annotation	3
Keywords	4
1 Introduction	8
1.1 Motivation and Problem Definition	8
1.1.1 Global Generative AI Adoption	8
1.2 Thesis Objective and Research Questions	9
1.2.1 Main Goal	9
1.2.2 Sub-goals	9
1.2.3 Research Questions	9
1.3 Methodology	9
2 Development Environment and Practices	9
2.1 GitHub	10
2.2 Software Engineering	10
2.2.1 Planning	10
2.3 Version control	10
2.3.1 Git	10
2.3.1.1 Repository Branch	10
2.3.1.2 Branch Merge	11
2.3.1.3 Commit Squashing	11
2.3.1.4 GitHub Issue	11
2.3.1.5 Pull Request	11
2.3.1.6 Required Checks	11
2.3.1.7 Branch Protection	11
2.4 Continuous Integration	11
2.4.1 GitHub Actions	11
2.4.2 Software Container	11
2.4.3 Flaky Test	11
3 Language Models, Chatbots, and Agents	12
3.1 Chatbot	12
3.1.1 ChatGPT	12
3.1.1.1 ChatGPT App Interface	12
3.2 Agent	13
3.3 Large Language Model	13

3.3.1	GPT-5.6	13
3.3.1.1	GPT-5.6 Product Visual	13
3.3.2	Claude Opus 5	14
3.3.2.1	Claude Opus 5 Product Visual	14
3.3.3	DeepSeek-V4.1-Flash	15
3.3.3.1	DeepSeek-V4.1-Flash Product Visual	15
3.3.4	Transformer Architecture	15
3.3.5	Autoregressive Modeling	15
3.3.6	Stochastic Decoding	15
3.3.7	Tokenizer	15
3.3.8	Token	16
3.3.9	Embedding	16
3.3.10	Context Window	16
3.3.11	Key-Value Cache	16
3.3.12	Interaction Turn	16
4	Agentic Engineering	17
4.1	Prompt Engineering	17
4.1.1	System Prompt	17
4.2	Agent Harness	17
4.2.1	Codex	18
4.2.1.1	Codex App Interface	18
4.2.2	Claude Code	18
4.2.2.1	Claude Code Interface	18
4.2.3	Claude Desktop App	19
4.2.3.1	Claude Desktop Interface	19
4.2.4	Sandbox	20
4.2.5	Deterministic Guardrail	20
4.2.6	Human-in-the-loop	20
4.2.7	Plugins	21
4.2.8	ReAct Loop	21
4.2.8.1	Agent Session	22
4.2.8.2	Execution-loop Engineering	22
4.2.8.3	Agent Divergence Pathologies	22
4.2.9	Tool Calling	23
4.2.9.1	Model Context Protocol	23
4.2.10	Skills	23

4.2.10.1	Progressive Disclosure	24
4.2.10.2	Script	24
4.2.10.3	Event Hook	24
4.2.11	Context Engineering	24
4.2.11.1	Context Compaction	24
4.2.11.2	Retrieval-Augmented Generation	24
4.2.11.3	Context Rot	25
4.2.11.4	Semantic Drift	25
4.2.12	Workflow-graph Engineering	26
4.2.12.1	Subagent	26
4.2.12.2	Directed Acyclic Graph	26
5	Results and Discussion	26
6	Conclusion	26
	List of figures and tables	27
	List of appendices	28
	References	29

1 Introduction

1.1 Motivation and Problem Definition

Motivací práce je ukázat, jaké úlohy dokážou současné agentní systémy samostatně provádět a jaká technická vrstva umožňuje převést schopnost jazykového modelu do spolehlivého jednání nad skutečným softwarovým projektem. Generativní AI se během několika let rozšířila do masového používání. Microsoft AI Economy Institute odhaduje, že v prvním čtvrtletí 2026 použilo generativní AI 17,8 % světové populace v produktivním věku. Současně se rychle rozšiřují systémy, které už pouze negenerují odpověď, ale plánují více kroků, pracují se soubory a nástroji, spouštějí příkazy a testy, kontrolují vlastní výstupy a mohou vykonávat dlouhotrvající úlohy. ⁽¹⁾

V softwarovém inženýrství tento posun reprezentují například Codex a Claude Code: jejich oficiální popisy uvádějí práci nad reálnými repozitáři, paralelní agentní úlohy, úpravy souborů, spouštění testů a další činnosti přesahující jednorázové generování kódu. ^(2,3)

Práce proto nezkoumá pouze schopnost modelu vytvořit fragment programu. Zaměřuje se na **Agent Harness** jako systémovou vrstvu, která modelu poskytuje nástroje, stav, kontext, oprávnění, kontrolní smyčku a ověřování výsledků. Právě tato vrstva rozhoduje o tom, zda lze schopnosti modelu využít jako opakovatelný agentní proces.

1.1.1 Global Generative AI Adoption

Grafický podklad dokumentuje rychlost, s níž se generativní AI rozšířila z experimentální technologie do běžného používání. Microsoft AI Economy Institute uvádí pro druhé pololetí roku 2025 celosvětový podíl uživatelů 16,3 %, oproti 15,1 % v prvním pololetí. Novější zpráva pro první čtvrtletí 2026 odhaduje používání generativní AI na 17,8 % světové populace v produktivním věku.

Region	H1 2025 AI Diffusion	H2 2025 AI Diffusion	Change
Global North	22.9%	24.7%	+1.8
Global South	13.1%	14.1%	+1.0
World	15.1%	16.3%	+1.2

Obrázek 1: AI diffusion v globálním Severu, globálním Jihu a celosvětově, H1–H2 2025. Zdroj: Microsoft AI Economy Institute.

Měřítka adopce neposuzuje schopnosti jednotlivých systémů, ale dokládá jejich rychlé rozšíření do reálného používání. ^(1,4) Výchozí otázkou práce je, co současné agentní systémy skutečně dokážou a jak musí být navržen harness, aby jejich schopnosti bylo možné bezpečně a opakovatelně využít v reálném vývojovém prostředí. ^(1–3)

1.2 Thesis Objective and Research Questions

1.2.1 Main Goal

Vymezit teoretické principy agentického inženýrství (*agentic engineering*) a navrhnout modulární architekturu agent harnessu pro automatizovaný vývoj softwaru se zachováním lidského dohledu v klíčových rozhodovacích bodech.

1.2.2 Sub-goals

- Vymezit infrastrukturu pro správu verzí (Git, GitHub a kontinuální integraci).
- Analyzovat limity velkých jazykových modelů (dynamiku kontextového okna, jev Context Rot, ztrátovou kompresi a sémantický posun).
- Navrhnout architekturu agent harnessu zahrnující nástrojové smyčky (ReAct), bezpečnostní pískoviště a hierarchickou orchestraci subagentů.
- Formalizovat mechanismy zapojení člověka do smyčky (*Human-in-the-loop*), schvalovací brány a protokol revizních značek pro dohled nad textovými výstupy.

1.2.3 Research Questions

1.3 Methodology

Práce používá konceptově-analytický a inženýrský postup: vymezuje nezbytné části agentního systému, popisuje jejich vztahy a ověřuje je na návrhu a realizaci systému DarkFactory. Předmětem práce není trénování neuronových sítí, optimalizace vah ani podrobná matematika modelového učení. **LLM** je zde chápán jako hotová inferenční komponenta. Modelová vrstva je proto popsána pouze v rozsahu nutném pro pochopení agentního běhu, tokenizace, kontextového okna, paměťového stavu inference a nástrojových rozhraní.

Hlavním předmětem zkoumání je konstrukce **Agent Harness** pro autonomní softwarové inženýrství. Jednotlivé mechanismy jsou rozděleny do samostatných konceptů, aby každý pojem měl jedno místo pro definici, popis a shrnutí a aby se stejné vysvětlení neopakovalo v několika kapitolách.

Postup práce má tři kroky: nejprve jsou vymezeny relevantní koncepty a jejich závislosti; následně jsou tyto principy promítnuty do architektury DarkFactory; nakonec jsou vlastnosti výsledného systému posouzeny podle ověřitelných výstupů vývojového procesu. Terminologie zachovává zavedené oborové názvy tam, kde jsou v praxi přesnější než doslovný překlad, přičemž všechny používané termíny jsou vedeny jako kanonické koncepty. Rozsah práce je záměrně soustředěn na agentní systém kolem modelu: model je vstupní inferenční komponenta, zatímco předmětem návrhu a hodnocení je harness a jeho provozní mechanismy.

2 Development Environment and Practices

The set of versioning, planning, integration, and verification practices that form a deterministic environment for agentic software development. ⁽⁵⁾

2.1 GitHub

A platform for hosting Git repositories and coordinating the software-development lifecycle through features such as Issues, Pull Requests, and CI/CD automation. ⁽⁶⁾

2.2 Software Engineering

The systematic application of engineering principles to the specification, design, implementation, verification, operation, and maintenance of software systems. ⁽⁵⁾

2.2.1 Planning

The process of turning a requirement into an explicit sequence of steps, dependencies, and verification conditions before changes are executed. ⁽⁵⁾

2.3 Version control

The management and tracking of changes to source files and other versioned artifacts so changes can be safely branched, merged, audited, and reverted when necessary. ⁽⁷⁾

2.3.1 Git

A distributed version-control system that records project history, supports branching and merging, and enables deterministic return to earlier repository states. ⁽⁷⁾ Pro autonomní vývoj softwaru je spolehlivá správa verzí naprosto nezbytným základem. Jazykové modely generují kód na základě statistické pravděpodobnosti, a proto se nevyhnutelně dopouštějí chyb, logických přehmatů či regresí. Verzovací systém vytváří bezpečné a deterministické prostředí, v němž lze každou úpravu zaznamenat, otestovat a v případě selhání kdykoliv vrátit zpět k funkčnímu stavu. Namísto teoretických abstrakcí práce přímo využívá distribuovaný systém v kombinaci s platformou .

Klíčové komponenty infrastruktury zahrnují:

- Distribuovaný systém Git ⁽⁷⁾: Ukládá kompletní historii projektu v podobě jednotlivých revizí (*commitů*). Vývojář i agent pracují s plnou lokální kopií repozitáře, což umožňuje provádět změny, přepínat větve a spouštět lokální testy zcela nezávisle na síťovém připojení.
- Platforma GitHub: Slouží jako centrální bod pro sdílení kódu, týmovou koordinaci a automatizaci:
 - Zadávání a sledování úkolů (Issues): Strukturovaná textová zadání požadavků a hlášení chyb, která agentovi slouží jako výchozí specifikace úlohy.
 - Revize změn (Pull Requests): Uživatelské rozhraní pro přehledné zobrazení diffu, diskusi nad kódem a formální schválení člověkem.
 - Automatizace (GitHub Actions): Běhové prostředí pro automatické spouštění testů, linterů a překladů při každé události v repozitáři.

2.3.1.1 Repository Branch

A named line of development in version control that allows changes to proceed separately from another history line and later be compared or merged. ⁽⁷⁾

2.3.1.2 Branch Merge

A version-control operation that combines changes or history from two lines of development into a common resulting state; conflicts require explicit resolution. ⁽⁷⁾

2.3.1.3 Commit Squashing

An operation that replaces multiple consecutive commits with one aggregate commit, commonly to simplify history before integrating changes. ⁽⁷⁾

2.3.1.4 GitHub Issue

A structured repository record for a request, task, or defect that can carry a description, discussion, labels, assignments, and links to code changes. ⁽⁶⁾

2.3.1.5 Pull Request

A formal proposal to integrate changes from one repository branch into another, providing a place for automated checks, human review, and discussion of the proposed changes. ⁽⁷⁾

2.3.1.6 Required Checks

Automated checks whose successful completion is a mandatory condition for accepting or merging a change. ⁽⁸⁾

2.3.1.7 Branch Protection

Repository rules that restrict direct changes to protected branches and enforce approvals, checks, or other conditions before merging. ⁽⁷⁾ GitHub poskytuje pravidla ochrany větví (*Branch Protection Rules*), která zabráňují začlenění neověřeného kódu do stabilní větve `main`.

- Povinné schválení člověkem: Požadavek na explicitní autorizaci kódu lidským vývojářem dříve, než GitHub povolí sloučení do produkční větve.

2.4 Continuous Integration

A development practice in which changes are integrated frequently and automatically verified by builds, tests, and other checks so integration failures are detected early. ⁽⁸⁾

2.4.1 GitHub Actions

GitHub's automation platform for running declared workflows and their jobs in response to repository events or manual dispatch. ⁽⁹⁾

2.4.2 Software Container

An isolated user-space runtime packaging an application and its dependencies while sharing the host operating-system kernel; its security isolation depends on the implementation and configuration. ⁽¹⁰⁾

2.4.3 Flaky Test

A test that can alternately pass and fail on the same code because of nondeterminism, timing, environment dependence, or external services. ⁽⁸⁾

3 Language Models, Chatbots, and Agents

Tato skupina konceptů rozlišuje samotný jazykový model od produktových rozhraní a agentních systémů, které model používají. *LLM*, *·* a *·* označují různé systémové vrstvy. Toto rozlišení zabraňuje zaměňování schopností modelu s funkcemi, které ve skutečnosti poskytuje aplikační nebo agentní harness. Další sekce proto popisují model, jeho bezprostřední inferenční mechanismy a nadřazené systémy odděleně.

3.1 Chatbot


Chatbot je aplikační systém, který zpřístupňuje jazykový model prostřednictvím konverzační interakce. Na rozdíl od samotného modelu může chatbot přidávat historii konverzace, multimodální vstupy, práci se soubory, webové vyhledávání nebo další nástroje. Tyto funkce patří aplikační vrstvě, nikoli modelu samotnému.

3.1.1 ChatGPT

ChatGPT je konverzační produkt OpenAI zpřístupňující modely prostřednictvím chatového a aplikačního rozhraní. Jako příklad chatbota odděluje modelovou vrstvu od uživatelského produktu: rozhraní přidává práci se soubory, obrazem, webem a dalšími nástroji, které samotný model neposkytuje.

3.1.1.1 ChatGPT App Interface

Oficiální snímek rozhraní aplikace ChatGPT pro macOS. Snímek ukazuje vstupní rozhraní a nabídku práce se soubory, obrazem a webem.



Obrázek 2: Rozhraní ChatGPT pro macOS. Zdroj: OpenAI Help Center.

Příklad uživatelského povrchu nad jazykovým modelem.⁽¹¹⁾ ChatGPT ilustruje rozdíl mezi jazykovým modelem a aplikačním systémem, který model obaluje.⁽¹¹⁾ Chatbot je produktová vrstva nad modelem; agentní systém se od něj odlišuje především řízenou prováděcí smyčkou a schopností samostatně vykonávat akce.

3.2 Agent

A software system driven by a language model and equipped with tools that independently plans, observes its environment, and performs multi-step actions toward a specified engineering goal. ⁽¹²⁾ · — [cz] Systém založený na jazykovém modelu určený primárně k interakci s uživatelem prostřednictvím konverzačního rozhraní.. · — [cz] Softwarový systém řízený jazykovým modelem a vybavený nástroji, který samostatně plánuje, vnímá stav prostředí a provádí víceukrokové akce směřující k dosažení zadaného inženýrského cíle.. Rozdíl mezi nimi nespočívá v odlišném jazykovém modelu, ale v architektuře jeho zapojení do pracovního prostředí.

Srovnání obou přístupů:

- Konverzační chatbot:
 - Reaguje pouze na přímé textové výzvy v uzavřeném okně chatu.
 - Nemá přímý přístup k souborovému systému ani k nástrojům operačního systému.
 - Uživatel musí navržený kód ručně zkopírovat, vložit do projektu a otestovat.
- Autonomní agent:
 - Je vybaven sadou výkonných nástrojů (*tools*) pro práci s repozitářem.
 - Aktivně prozkoumává soubory, modifikuje zdrojový kód, spouští testy a interpretuje jejich návratové kódy.
 - Funguje v autonomní prováděcí smyčce, v níž iterativně reaguje na reálnou odezvu vývojového prostředí.

3.3 Large Language Model


Velký jazykový model je neuronový model pro zpracování a generování posloupností tokenů; současné modely tohoto typu typicky používají **Transformer**. Při generování model opakovaně odhaduje další token na základě dosavadního kontextu. Samostatné koncepty dále popisují tokenizaci, reprezentaci dat a omezení kontextu. Funkce jako práce se soubory, spouštění příkazů nebo správa úloh nejsou vlastnostmi jazykového modelu; poskytuje je nadřazený aplikační nebo agentní systém.

3.3.1 GPT-5.6

GPT-5.6 je modelová řada OpenAI vydaná v roce 2026 ve variantách Sol, Terra a Luna. Jde o příklad současného jazykového modelu, který je nasazován jako inferenční komponenta v produktech včetně ChatGPT a Codexu; aplikační schopnosti těchto produktů však vznikají až propojením modelu s jejich harnessy.

3.3.1.1 GPT-5.6 Product Visual

Oficiální produktový vizuál modelové řady GPT-5.6. Obrazový podklad je převzat z oficiálního vydání modelu OpenAI.



Obrázek 3: GPT-5.6. Zdroj: OpenAI.

Vizuální identifikace příkladu jazykového modelu.⁽¹³⁾ Příklad odděluje modelovou vrstvu od agentního systému, který model používá.⁽¹³⁾

3.3.2 Claude Opus 5

Claude Opus 5 je model společnosti Anthropic vydaný v červenci 2026. Model je příkladem současné modelové vrstvy používané v širších agentních produktech. Samotný model není totožný s Claude Code ani desktopovou aplikací Claude; ty přidávají nástroje, stav a orchestrace.

3.3.2.1 Claude Opus 5 Product Visual

Oficiální produktový vizuál modelu Claude Opus 5. Obrazový podklad je převzat z oficiálního oznámení společnosti Anthropic.



Obrázek 4: Claude Opus 5. Zdroj: Anthropic.


Vizuální identifikace příkladu jazykového modelu.⁽¹⁴⁾ Příklad zdůrazňuje rozdíl mezi modelem a agentním harness-em.⁽¹⁴⁾

3.3.3 DeepSeek-V4.1-Flash

DeepSeek-V4.1-Flash je multimodální model DeepSeek vydaný v září 2026. Jde o příklad odlišné současné modelové architektury: DeepSeek jej popisuje jako 552B MoE s asymetrickým Causal Encoder–Decoder uspořádáním a nativním vizuálním vstupem.

3.3.3.1 DeepSeek-V4.1-Flash Product Visual

Oficiální produktový vizuál modelu DeepSeek-V4.1-Flash. Obrazový podklad je převzat z oficiálního vydání společnosti DeepSeek.



Obrázek 5: DeepSeek-V4.1-Flash. Zdroj: DeepSeek.

Vizuální identifikace příkladu jazykového modelu.⁽¹⁵⁾ Příklad ukazuje, že pojem jazykového modelu v agentním systému zahrnuje různé konkrétní modelové rodiny a architektury.⁽¹⁵⁾ Jazykový model je inferenční komponenta. V této práci je důležité především jeho rozhraní a omezení, protože provozní chování agenta vzniká až propojením modelu s harness-em.

3.3.4 Transformer Architecture

A neural-network architecture based on attention mechanisms that models relationships among sequence elements and underlies most contemporary large language models.⁽¹⁶⁾

3.3.5 Autoregressive Modeling

A sequential modeling approach in which a model predicts the next token conditioned on preceding tokens in the current sequence.⁽¹⁶⁾

3.3.6 Stochastic Decoding

Selection of output tokens from a model probability distribution in a way that can yield different valid continuations for the same input.⁽¹⁶⁾

3.3.7 Tokenizer

A component that maps text or another input into a sequence of tokens and token identifiers and, where supported, performs the reverse decoding transformation.⁽¹⁷⁾

3.3.8 Token

A discrete unit processed by a language model. A token corresponds to an entry in the tokenizer vocabulary and is represented by a numeric identifier; it need not correspond to a whole word. ⁽¹⁷⁾ Jazykový model nepracuje přímo se znaky ani slovy v lidském slova smyslu. Vstupní text je nejprve deterministickým algoritmem převeden na číselné reprezentace, se kterými následně počítají maticové vrstvy neuronové sítě.

Tento proces zahrnuje následující pojmy:

- Tokeny a tokenizér (): Token představuje základní diskrétní jednotku (celé slovo, slabiku či fragment znaků). Převod mezi textem a posloupností číselných tokenů zajišťuje tokenizér (nejčastěji na bázi algoritmu Byte Pair Encoding, BPE).
- **Embedding** — [cz] Vícerozměrná vektorová reprezentace tokenů nebo jiných dat, v níž numerické vztahy mezi vektory zachycují užitečné sémantické vztahy mezi reprezentacemi. ⁽¹⁸⁾ (např. vektorová analogie král — muž + žena $\approx$ královna).
- Jazyková asymetrie tokenizace: Vzhledem k trénovacím datům optimalizovaným primárně pro angličtinu spotřebovávají flektivní jazyky s bohatou diakritikou (včetně češtiny) 2× až 3× více tokenů pro vyjádření téhož významu.

Z inženýrského hlediska je proto žádoucí vést systémové prompty, technické plány i komunikaci mezi nástroji v angličtině, aby se šetřila kapacita kontextu a snížila latence inference.

3.3.9 Embedding

A multidimensional vector representation of tokens or other data in which numerical relationships between vectors capture useful semantic relationships between representations. ⁽¹⁸⁾

3.3.10 Context Window

The maximum token-sequence span a model can include in active context during one inference run. In practice it limits the combined instructions, history, tool outputs, and other data supplied to the model. ⁽¹⁹⁾

3.3.11 Key-Value Cache

A cache of previously computed key and value vectors in transformer attention layers that reduces repeated computation of earlier tokens during autoregressive generation. ⁽²⁰⁾

3.3.12 Interaction Turn

One discrete unit of interaction in a conversational or agentic protocol, such as a user message, model response, or separately recorded tool result. ⁽²¹⁾ Interakce mezi modelem, uživatelem a okolním vývojovým prostředím neprobíhá spojitě, nýbrž v diskrétních krocích označovaných jako tahy (*turns*). Každý tah představuje jednu ucelenou výměnu zprávy, na niž systém reaguje.

Životní cyklus tahů a správa paměti zahrnují:

- Typy tahů v agentní smyčce:
 - Tah uživatele či prostředí (*User Turn*): Nové zadání úkolu nebo vnější událost.

- Tah modelu (*Model Turn*): Vygenerovaná odpověď nebo strukturovaný požadavek na spuštění nástroje.
- Tah nástroje (*Tool Execution Turn*): Zpětné hlášení výsledku exekuce (výpis souboru, výstup kompilátoru).
- Správa KV cache (KV Cache): Aby inferenční engine nemusel při každém novém tahu přepočítávat celou historii od začátku, ukládá mezivýpočty klíčů a hodnot matic pozornosti do paměti.
- Kontextové okno (): Pevně limitovaná kapacita paměti modelu. Tento strop je dán hardwarovými limity GPU akceleratorů a kvadratickou složitostí plné pozornosti ($O(N^2)$ vzhledem k délce sekvence).

4 Agentic Engineering

An engineering discipline focused on designing, orchestrating, and operating agentic systems around language models, including tools, context, execution loops, guardrails, and human oversight. ⁽²²⁾

4.1 Prompt Engineering

An engineering discipline for systematically designing, structuring, and optimizing instructions and system prompts to guide and constrain language-model behavior. ⁽²³⁾ Základní chování agenta vymezuje systémový prompt ⁽²³⁾, který definuje jeho identitu, sadu dostupných nástrojů a provozní mantinely. Při formulaci těchto pravidel však vývojáři narážejí na specifickou vlastnost autoregresivních modelů — problematické zpracování zákazů a negativních instrukcí.

Příčiny a inženýrská řešení tohoto jevu:

- Úskalí negativních instrukcí: Zákazy formulované negací (např. „nemazat existující testy“) modely často porušují, protože matice pozornosti (QK^T) asociativně aktivuje zakázaný pojem dříve, než autoregresní proces uplatní logický operátor negace.
- Afirmativní formulace: Pravidla je nutné formulovat pozitivně — namísto výčtu zákazů vymezit přesný postup a povolené mantinely chování.
- Deterministická ochrana v harnessu: Kde nestačí prompt, musí zasáhnout kód agent harnessu — například zpřístupněním testovacích souborů pouze pro čtení nebo zablokováním destruktivních operací na úrovni systémového volání.

4.1.1 System Prompt

A high-priority instruction layer that defines the role, behavior, available capabilities, and operating constraints of a language model or agent. ⁽²³⁾

4.2 Agent Harness

Agentní harness je aplikační a orchestrační vrstva, která propojuje model s prostředím a řídí jeho opakované jednání nad stavem a nástroji. Harness sestavuje kontext, zpřístupňuje a omezuje nástroje, spravuje stav sezení, vyhodnocuje výsledky akcí a rozhoduje o pokračování.


čování nebo ukončení prováděcí smyčky. Tím odděluje pravděpodobnostní rozhodování modelu od deterministických pravidel systému. Ústředním prováděcím mechanismem je **Agent Loop**.

4.2.1 Codex

Codex je agentní vývojový systém OpenAI určený pro samostatné plnění softwarově-inženýrských úloh. Desktopová aplikace umožňuje řídit více agentů paralelně, oddělovat jejich práci do vláken a worktree, kontrolovat diffy a delegovat dlouhotrvající úlohy. Tím představuje praktický příklad harnessu, který rozšiřuje model o stav, nástroje, izolaci a pracovní postup.

4.2.1.1 Codex App Interface

Oficiální produktový snímek aplikace Codex. Snímek dokumentuje specializované rozhraní pro práci s agentními úlohami a dovednostmi.



Obrázek 6: Aplikace Codex. Zdroj: OpenAI.


Vizuální příklad agentního vývojového prostředí.⁽²⁾ Codex ukazuje posun od generování fragmentů k řízenému agentnímu vývojovému procesu.⁽²⁾

4.2.2 Claude Code

Claude Code je agentní vývojové prostředí společnosti Anthropic dostupné v terminálu, IDE, na webu a v desktopové aplikaci. Systém může plánovat změny, číst a zapisovat soubory, spouštět příkazy a testy, používat Git a MCP a vytvářet pull requesty. Tyto schopnosti vznikají kombinací modelu s nástrojovou a stavovou vrstvou harnessu.

4.2.2.1 Claude Code Interface

Oficiální snímek rozhraní Claude Code při práci se zdrojovým kódem. Snímek zobrazuje čtení souboru, zápis změny a průběžný stav agentní úlohy.



Obrázek 7: Claude Code při práci se souborem. Zdroj: Anthropic.


Vizuální příklad nástrojově řízeného kódovacího agenta.⁽³⁾ Claude Code je konkrétní příklad agentního harnessu propojeného s reálným vývojovým prostředím.⁽³⁾

4.2.3 Claude Desktop App

Claude Desktop je desktopová aplikační vrstva nad modely Claude, která propojuje konverzaci s lokálními soubory, aplikacemi, webem a dalšími schopnostmi. Anthropic popisuje desktopovou aplikaci jako prostředí, v němž může Claude se souhlasem uživatele přímo číst, upravovat a ukládat soubory a pracovat s dalšími aplikacemi. Jde proto o širší příklad harnessu než samotný chatbot.

4.2.3.1 Claude Desktop Interface

Oficiální snímek aplikačního rozhraní Claude s pracovním artefaktem. Snímek ukazuje, že aplikační vrstva může vedle konverzace zpřístupnit soubory, nástroje a samostatný pracovní povrch.



Obrázek 8: Aplikační rozhraní Claude. Zdroj: Anthropic.

Vizuální příklad desktopového aplikačního harnessu.⁽²⁴⁾ Desktopová aplikace ukazuje, jak harness rozšiřuje model o oprávnění, kontext a akce v uživatelském prostředí.⁽²⁴⁾ Schopnosti agentního systému proto nelze připsat pouze modelu: vznikají souhrou modelu a harnessu, který mu poskytuje prostředí pro řízené jednání.

4.2.4 Sandbox

A constrained runtime environment intended to isolate executing code and its permissions from the host system.⁽²⁵⁾ Přímé spouštění kódu (*Code Execution*) umožňuje agentovi generovat skripty (bash, Python), které harness spouští v izolovaném terminálu. Tento model poskytuje maximální flexibilitu pro softwarový vývoj, avšak vyžaduje nekompromisní bezpečnostní izolaci.

4.2.5 Deterministic Guardrail

A programmatically enforced constraint or check that does not leave a critical operating rule solely to a model's probabilistic decision.

4.2.6 Human-in-the-loop

A design pattern in which a human operator remains part of the system's decision process through approval gates (Human Gates), especially before consequential or irreversible system operations.⁽²⁶⁾ Základním principem navrženého řešení není nekritická plná autonomie, nýbrž efektivní kooperace člověka a stroje. Autonomnímu systému náleží mechanické a rutinní úkony, zatímco klíčová architektonická a nevratná rozhodnutí zůstávají plně pod kontrolou vývojáře.

Řízení lidského dohledu staví na těchto pilířích:

- Lidské schvalovací brány (*Human Gates*): Formální procesní uzly, v nichž se automatický běh pozastaví a vyčká na autorizaci operátora:
 - 1. brána (Záměr a plán): Člověk autorizuje technický plán a rozpad požadavku dříve, než agent začne modifikovat kód v souborech.

- 2. brána (Sémantická revize): Člověk provádí finální kontrolu diffu v pull requestu před jeho začleněním do hlavní větve.
- Prevence únavy z revizí (*Review Fatigue*): Vyvážená frekvence kontrol — zamezení mikromanagementu na úrovni jednotlivých souborů při zachování kontroly nad celkovým architektonickým směrem.
- Dohledatelnost původního zadání: Trvalé uchovávání doslovného znění požadavku (GitHub Issue) bez ztrátových parafrází modelem, což brání vymizení okrajových podmínek v průběhu vývoje.
- Transparentnost selhání a deterministická eskalace: Zákaz tichého pohlcování chyb či halucinovaných omluv při selhání. Při vyčerpání rozpočtu nebo selhání testů harness vygeneruje strukturovaný diagnostický incident (diff, chybové hlášení, stav kontextu) a předá jej vývojáři k manuálnímu zásahu.

4.2.7 Plugins

Programmatic extension modules running directly in the harness environment that extend its execution core with specialized system adapters, tool drivers, and deterministic hooks. ⁽²⁷⁾

4.2.8 ReAct Loop

An iterative execution cycle of an autonomous agent based on the ReAct pattern (Reasoning + Acting), in which the model alternates between reasoning, tool calls, and evaluation of observations from the runtime environment. ⁽²¹⁾ Agentní smyčka (*Agent Loop*) představuje výkonné jádro celého agent harnessu. Zatímco pasivní konverzační chatbot jednorázově odpoví na uživatelský dotaz a čeká na další vstup, agentní smyčka autonomně udržuje kontinuální iterativní proces, v němž harness opakovaně vyhodnocuje stav repozitáře, volá jazykový model a vykonává požadované systémové akce.

V každé iteraci agentní smyčky harness zajišťuje tyto klíčové funkce:


- Inicializace a správa sezení: Sestavení systémového promptu, dynamická injekce kontextu repozitáře a sledování spotřeby tokenů.
- Běhové prostředí nástrojů: Bezpečné spouštění příkazů v operačním systému a zpětné předávání výstupů modelu.
- Řízení stavových přechodů a vynucování mantinelů (Loop Engineering): Dohled nad dodržováním procesních pravidel, detekce a zastavení uvíznutých běhů a vynucování lidských schvalovacích bran.

Vnitřní kognitivní krok modelu uvnitř smyčky se řídí operačním vzorem ReAct (*Reasoning + Acting*) ⁽²¹⁾, který propojuje rozvahu s přímým jednáním. Tento prováděcí cyklus sestává ze čtyř navazujících fází znázorněných na Obrázek 9:

1. Rozvaha (*Thought*): Model vyhodnotí aktuální stav kontextu a formuluje svůj nejbližší záměr.
2. Volání nástroje (*Tool Call*): Emitování strukturovaného požadavku na provedení konkrétní akce s určenými parametry.
3. Vykonání a pozorování (*Observation*): Harness bezpečně provede akci v systému a výstup (výpis souboru či chybovou zprávu) vloží zpět do kontextu.

4. Navazující iterace: Model v dalším tahu analyzuje získanou odezvu a rozhoduje o dalším kroku.

Kvalita a provozní spolehlivost celého systému tak závisí v první řadě na robustnosti architektury harnessu a spolehlivosti jeho agentní smyčky, nikoliv pouze na samotném jazykovém modelu.



Obrázek 9: Architektura autonomní ReAct smyčky (Reasoning + Acting) a tok dat mezi uživatelem, kontextem, modelem a výkonným prostředím.

4.2.8.1 Agent Session

A bounded agent run with shared state, system instructions, working context, turn history, and operating budgets.

4.2.8.2 Execution-loop Engineering

The design and control of an agent's iterative execution loop, including state transitions, termination conditions, budgets, retries, escalation, and the connection between model decisions and tools. ⁽²¹⁾

4.2.8.3 Agent Divergence Pathologies

A class of agent-loop failures in which iterative execution moves away from the goal through perseveration, oscillation, or uncontrolled resource consumption. ⁽²⁸⁾ Ponechání jazykového modelu v neomezené prováděcí smyčce vede k předvídatelným selháním. V důsledku autoregresivní povahy se v kontextu snadno vytvoří pravděpodobnostní atraktor, který model uvězní v neproduktivním cyklu.

Mezi typické patologie patří:

- **Perseverance a zacyklení:** Opakované volání identického nástroje se stejnými neplatnými argumenty (např. čtení neexistujícího souboru) i po obdržení chybové zprávy.
- **Oscilace a těkání (Thrashing):** Štrídavé přepínání mezi dvěma protichůdnými zásahy (úprava modulu A rozbije modul B a následná oprava B rozbije modul A).

- Nekontrolovaná spotřeba zdrojů (*Context Runaway*): Rychlé vyčerpání kontextového okna i finančního rozpočtu na volání API bez dosažení cíle.

4.2.9 Tool Calling

A mechanism through which a model structurally asks a harness to execute an external action or function with validated parameters. ⁽²⁹⁾

4.2.9.1 Model Context Protocol

Model Context Protocol — an open standard originally introduced by Anthropic for standardized communication between AI applications and external tools, resources, and data through JSON-RPC messages. ⁽³⁰⁾ Pro sjednocení rozhraní mezi AI aplikacemi a externími nástroji či datovými zdroji vznikl otevřený standard **MCP** — [cz] Model Context Protocol — otevřený standard původně navržený společností Anthropic pro standardizovanou komunikaci AI aplikací s externími nástroji, zdroji a daty prostřednictvím zpráv JSON-RPC. ⁽³⁰⁾. Namísto vytváření proprietárních rozhraní pro každou službu definuje MCP standardizovaný způsob komunikace.

Základní vlastnosti protokolu MCP:

- Protokolové rozhraní: Komunikace probíhá prostřednictvím standardu JSON-RPC (přes standardní vstup/výstup `stdio` nebo proud událostí `Server-Sent Events / SSE`).
- Architektonické oddělení: Implementace nástrojů běží jako samostatný proces mimo jádro harnessu. MCP servery fungují jako znovupoužitelné komponenty, které lze snadno sdílet napříč různými agenty a projekty.

4.2.10 Skills

Reusable modular packages of instructions (typically defined in a `SKILL.md` file), procedural rules, and optional helper scripts or resources that a harness dynamically loads into an agent's context for a particular class of task. ⁽³¹⁾ Se vzrůstající komplexitou úloh nelze veškeré instrukce, skripty a doménové znalosti vkládat do základního systémového promptu. K modulárnímu rozšíření schopností agenta slouží **Skills**.

Architektura dovedností staví na následujících principech:

- Definiční soubor `SKILL.md`: Dovednost tvoří adresář obsahující definiční soubor se strukturovanou hlavičkou (YAML frontmatter vymezující název a popis role) a detailním návodem k použití.
- Dynamické načítání pro úsporu kontextu: Do výchozího promptu se vloží pouze stručný přehled dostupných dovedností. Kompletní instrukce a skripty se do kontextu načtou až v okamžiku, kdy agent danou dovednost explicitně vyvolá.
- Skripty () a záchytné body (Hook): Dovednosti mohou obsahovat deterministické skripty pro rutinní transformace kódu a událostní háčky vyvolávané při stavových přechodech harnessu.

Kromě kontextových dovedností využívají pokročilé řídicí architektury také programové **Plugins** — [cz] Rozšíření běžící přímo v prostředí harnessu, která rozšiřují jeho exekuční

jádro o specializované systémové adaptéry, ovladače nástrojů a deterministické záchytné body. Zatímco *Skills* fungují jako kontextové procedury a instrukce interpretované modelem, pluginy rozšiřují samotný harness na nativní systémové úrovni.

4.2.10.1 Progressive Disclosure

A strategy where only compact capability descriptions are initially placed in active context and detailed instructions are loaded only when needed. ⁽³¹⁾

4.2.10.2 Script

A file or sequence of commands intended for automated execution by an interpreter, shell, or another runtime. ⁽³¹⁾

4.2.10.3 Event Hook

A defined lifecycle or event point to which custom deterministic logic can be attached before, after, or in place of standard system behavior. ⁽²⁷⁾

4.2.11 Context Engineering

The systematic design, selection, ordering, and lifecycle management of information made available to a model in active context, including instructions, memory, tool results, and externally retrieved data. ⁽¹⁹⁾

4.2.11.1 Context Compaction

The process of reducing active context, typically by summarizing, selecting, or replacing older history with a more compact representation so execution remains within the context window. ⁽³²⁾ Správa aktivního kontextu je součástí kontextového inženýrství (). Při rozsáhlejších úlohách se kontextové okno nevyhnutelně zaplní. V okamžiku, kdy objem historie dosáhne kritické hranice, musí agent harness přistoupit ke kompakci kontextu (*compaction*) — model je vyzván, aby dosavadní průběh sezení zkrátil do syntetického souhrnu, který nahradí starší část historie.

Tento proces však představuje destruktivní ztrátovou kompresi:

- Ztráta deterministických detailů: Model při rekurzivním zkracování vynechává přesná čísla řádků, signatury privátních funkcí, přesné cesty k souborům a doslovná chybová hlášení kompilátoru.
- Oslabení negativních pravidel: Explicitní zákazy (např. neměnit veřejné rozhraní API) bývají v souhrnu zevšeobecněny nebo zcela vypuštěny.
- Konfirmační zkreslení (*Confirmation Bias*): Model v souhrnu upřednostňuje fakta odpovídající jeho vnitřním statistickým asociacím na úkor netriviálních specifik konkrétního projektu.

4.2.11.2 Retrieval-Augmented Generation

An architecture in which a system retrieves relevant information from an external source before or during generation and places it into model context so the output can be grounded in the retrieved data. ⁽³³⁾ Aby se předešlo ztrátě informací způsobené kompakcí, moderní

agentní architektury přesouvají část paměti mimo samotné kontextové okno. Namísto spoléhání se na jediný lineární textový kontext se uplatňují strukturovaná externí úložiště. K hlavním přístupům patří:

- Hierarchická epizodická paměť (RAG): Ukládání doslovných protokolů nástrojů a historie úloh do externí databáze; do kontextu se selektivně injektují pouze bezprostředně relevantní fragmenty.
- Persistentní graf stavu projektu (*Project State Graph*): Udržování explicitního, strukturovaného přehledu o stavu repozitáře (seznam modifikovaných souborů, otevřené úkoly, výsledky testů a platné invarianty) mimo kontextové okno.

Díky tomu může agent kdykoliv obnovit přesný stav projektu bez závislosti na ztrátovém rekurzivním shrnování.

4.2.11.3 Context Rot

Degradation in a model's attention and reasoning quality caused by long, noisy, or internally competing context, leading to missed instructions and loss of relationships between facts. ⁽¹⁹⁾

Schopnost jazykového modelu pracovat s dlouhým kontextem nelze posuzovat pouze podle nominální velikosti okna. Ačkoliv moderní modely deklarují kapacitu statisíců tokenů, jejich schopnost efektivně vyhledávat a logicky propojovat fakta s rostoucí délkou kontextu výrazně klesá. Tento jev se označuje jako — [cz] Degradace pozornosti a kvality logického uvažování modelu způsobená zaplněním kontextového okna dlouhou historií, šumem nebo vzájemně si konkurujícími informacemi, která vede k přehlížení instrukcí a ztrátě souvislostí..

V praxi se projevuje dvěma hlavními mechanismy:

- Lost in the Middle ⁽¹⁹⁾: Pozornostní vrstvy transformeru spolehlivě vnímají informace na samém začátku a konci okna, zatímco fakta umístěná uprostřed dlouhého textu jsou často přehlížena.
- Multi-Needle Reasoning: Schopnost logicky provázat několik na sobě závislých informací rozptýlených napříč různými soubory; s rostoucí délkou kontextu tato schopnost prudce klesá.

Při komplexním křížovém refaktoringu ve velkém kontextu proto model často přehlédne klíčové souvislosti, které by v menším a čistším okně zpracoval bez potíží.

4.2.11.4 Semantic Drift

The gradual distortion of meaning and factual state through repeated lossy summarization or transformation of context. ⁽¹⁹⁾ Opakovaná ztrátová komprese vede k závažné patologii známé jako sémantický posun (*Semantic Drift*). Pokud je historie sezení v dlouhém vývojovém běhu shrnována vícekrát po sobě, vzniká řetězec ztrátových transformací ($S_{k+1} = f(S_k, \Delta_k)$).

Rizika sémantického posunu spočívají v těchto jevech:

- Efekt tiché pošty: Drobné zkreslení či halucinace vzniklá v kole k je v kole $k + 1$ přijata jako nezpochybnitelný historický fakt.

- Divergence modelu od reality: Po několika cyklech komprese se vnitřní model reality agenta zcela rozejde se skutečným stavem zdrojového kódu v souborovém systému. Výsledkem je stav, kdy agent sebevědomě reportuje vyřešení úkolu, ačkoliv reálný kód zůstává v nefunkčním či neúplném stavu.

4.2.12 Workflow-graph Engineering

The design of agentic or automation workflows as explicit graphs of nodes, dependencies, and transitions rather than as one unconstrained loop. ⁽³⁴⁾ Monolitická agentní smyčka selhává při řešení komplexních, vícefázových úloh. Pro spolehlivé škálování se v moderních systémech uplatňuje hierarchická dělba práce a formalizace procesu do podoby grafu.

4.2.12.1 Subagent

A temporary or specialized agent instance to which a parent orchestrator delegates a bounded subtask and from which it later receives the result. ⁽³⁴⁾

4.2.12.2 Directed Acyclic Graph

A directed graph containing no directed cycle. In workflows it can explicitly represent dependencies among steps and the ordering implied by those dependencies. ⁽³⁴⁾

5 Results and Discussion

6 Conclusion

List of figures and tables

Obrázek 1	AI diffusion v globálním Severu, globálním Jihu a celosvětově, H1–H2 2025. Zdroj: Microsoft AI Economy Institute.	8
Obrázek 2	Rozhraní ChatGPT pro macOS. Zdroj: OpenAI Help Center.	12
Obrázek 3	GPT-5.6. Zdroj: OpenAI.	14
Obrázek 4	Claude Opus 5. Zdroj: Anthropic.	14
Obrázek 5	DeepSeek-V4.1-Flash. Zdroj: DeepSeek.	15
Obrázek 6	Aplikace Codex. Zdroj: OpenAI.	18
Obrázek 7	Claude Code při práci se souborem. Zdroj: Anthropic.	19
Obrázek 8	Aplikační rozhraní Claude. Zdroj: Anthropic.	20
Obrázek 9	Architektura autonomní ReAct smyčky (Reasoning + Acting) a tok dat mezi uživatelé, kontextem, modelem a výkonným prostředím.	22

List of appendices

References

1. MICROSOFT AI ECONOMY INSTITUTE. Global AI Diffusion: Q1 2026 Trends and Insights. Online. 2026. [Accessed 20 září 2026]. Available from: <https://www.microsoft.com/en-us/research/wp-content/uploads/2026/05/Microsoft-AI-Diffusion-Report-2026-Q1.pdf>
2. OPENAI. Introducing the Codex app. Online. 2026. [Accessed 20 září 2026]. Available from: <https://openai.com/index/introducing-the-codex-app/>
3. ANTHROPIC. Claude Code. Online. 2026. [Accessed 20 září 2026]. Available from: <https://claude.com/product/claude-code>
4. MICROSOFT AI ECONOMY INSTITUTE. Global AI Adoption in 2025—A Widening Digital Divide. Online. 2026. [Accessed 20 září 2026]. Available from: <https://www.microsoft.com/en-us/corporate-responsibility/topics/ai-economy-institute/reports/global-ai-adoption-2025/>
5. SOMMERVILLE, Ian. *Software Engineering*. 10. Pearson, 2016. ISBN 978-0-13-394303-0.
6. DABBISH, Laura, STUART, Colleen, TSAY, Jason a HERBSLEB, Jim. Social coding in GitHub: transparency and collaboration in an open software repository. In : *Proceedings of the ACM 2012 conference on Computer Supported Cooperative Work*. 2012. p. 1277–1286.
7. CHACON, Scott a STRAUB, Ben. *Pro Git*. 2. New York : Apress, 2014. ISBN 978-1-4842-0076-6.
8. HUMBLE, Jez a FARLEY, David. *Continuous Delivery: Reliable Software Releases through Build, Test, and Deployment Automation*. Boston : Addison-Wesley, 2010. ISBN 978-0-321-60191-9.
9. KINSMAN, Timothy, WESSEL, Mairieli, GEROSA, Marco A. a TREUDE, Christoph. How do software developers use GitHub Actions to automate their workflows?. In : *Proceedings of the 18th International Conference on Mining Software Repositories*. 2021. p. 420–431.
10. MERKEL, Dirk. Docker: lightweight linux containers for consistent development and deployment. *Linux Journal*. 2014. Vol. 2014, no. 239, p. 2.
11. OPENAI. ChatGPT macOS app—Screenshot Tool. Online. 2026. [Accessed 20 září 2026]. Available from: <https://help.openai.com/en/articles/9295245-chatgpt-macos-app-screenshot-tool>
12. WOOLDRIDGE, Michael a JENNINGS, Nicholas R. Intelligent Agents: Theory and Practice. *The Knowledge Engineering Review*. 1995. Vol. 10, no. 2, p. 115–152.
13. OPENAI. GPT-5.6: Frontier intelligence that scales with your ambition. Online. 2026. [Accessed 20 září 2026]. Available from: <https://openai.com/index/gpt-5-6/>
14. ANTHROPIC. Introducing Claude Opus 5. Online. 2026. [Accessed 20 září 2026]. Available from: <https://www.anthropic.com/news/claude-opus-5>

15. DEEPSEEK. Introducing DeepSeek-V4.1-Flash: smarter, faster, more efficient. Online. 2026. [Accessed 20 září 2026]. Available from: <https://www.deepseek.com/en/news/deepseek-v4-1-flash/>
16. VASWANI, Ashish, SHAZEER, Noam, PARMAR, Niki, USZKOREIT, Jakob, JONES, Llion, GOMEZ, Aidan N., KAISER, Łukasz a POLOSUKHIN, Illia. Attention Is All You Need. *arXiv preprint arXiv:1706.03762*. Online. 2017. Available from: <https://arxiv.org/abs/1706.03762>
17. SENNRICH, Rico, HADDOW, Barry a BIRCH, Alexandra. Neural Machine Translation of Rare Words with Subword Units. *Proceedings of the 54th Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers)*. Online. 2016. P. 1715–1725. Available from: <https://aclanthology.org/P16-1162/>
18. MIKOLOV, Tomas, CHEN, Kai, CORRADO, Greg a DEAN, Jeffrey. Efficient Estimation of Word Representations in Vector Space. *arXiv preprint arXiv:1301.3781*. Online. 2013. Available from: <https://arxiv.org/abs/1301.3781>
19. LIU, Nelson F., LIN, Kevin, HEWITT, John, PARANJAPE, Ashwin, BEVILACQUA, Michele, PETRONI, Fabio a LIANG, Percy. Lost in the Middle: How Language Models Use Long Contexts. *Transactions of the Association for Computational Linguistics*. Online. 2024. Vol. 12, p. 157–173. Available from: <https://arxiv.org/abs/2307.03172>
20. DAO, Tri, FU, Daniel Y., ERMON, Stefano, RUDRA, Atri a RÉ, Christopher. FlashAttention: Fast and Memory-Efficient Exact Attention with IO-Awareness. *Advances in Neural Information Processing Systems*. Online. 2022. Vol. 35, p. 16344–16359. Available from: <https://arxiv.org/abs/2205.14135>
21. YAO, Shunyu, ZHAO, Jeffrey, YU, Dian, DU, Nan, SHAFRAN, Izhak, NARASIMHAN, Karthik a CAO, Yuan. ReAct: Synergizing Reasoning and Acting in Language Models. *arXiv preprint arXiv:2210.03629*. Online. 2022. Available from: <https://arxiv.org/abs/2210.03629>
22. WANG, Lei, MA, Chen, FENG, Xueyang, ZHANG, Zeyu, YANG, Hao, ZHANG, Jingsen, CHEN, Zhiyuan, TANG, Jiakai, CHEN, Xu, LIN, Yankai, ZHAO, Wayne Xin, WEI, Zhewei a WEN, Ji-Rong. A Survey on Large Language Model Based Autonomous Agents. *Frontiers of Computer Science*. Online. 2024. Vol. 18, no. 6, p. 186345. Available from: <https://arxiv.org/abs/2308.11432>
23. ANTHROPIC. Prompt Engineering overview. Online. 2026. Available from: <https://platform.claude.com/docs/en/build-with-claude/prompt-engineering/overview>
24. ANTHROPIC. Navigating the Claude desktop app. Online. 2026. [Accessed 20 září 2026]. Available from: <https://academy.claude.com/tutorials/navigating-the-claude-desktop-app>
25. AGACHE, Alexandru, DEACONESCU, Razvan, IORDACHE, Mihai, LUPU, Alexandra, RADU, Vlad, BUGA, Cezar, BALAN, Catalin a FLORESCU, Andreea. Firecracker: Lightweight

- Virtualization for Serverless Applications. In : *17th USENIX Symposium on Networked Systems Design and Implementation (NSDI 20)*. Online. 2020. p. 419–434. Available from: <https://www.usenix.org/conference/nsdi20/presentation/agache>
26. MOSQUEIRA-REY, Eduardo, HERNÁNDEZ-PEREIRA, Elena, ALONSO-RÍOS, David, BOBES-BASCARÁN, José a FERNÁNDEZ-LEAL, Ángel. Human-in-the-loop machine learning: a state of the art. *Artificial Intelligence Review*. Online. 2023. Vol. 56, no. 4, p. 3005–3054. Available from: <https://doi.org/10.1007/s10462-022-10246-w>
 27. Deepseek Harness. *arXiv preprint arXiv:2608.25512*. Online. 2026. Available from: <https://arxiv.org/abs/2608.25512>
 28. SHINN, Noah, CASSANO, Federico, GOPINATH, Ashwin, NARASIMHAN, Karthik a YAO, Shunyu. Reflexion: Language Agents with Verbal Reinforcement Learning. *Advances in Neural Information Processing Systems*. Online. 2023. Vol. 36, p. 8634–8652. Available from: <https://arxiv.org/abs/2303.11366>
 29. SCHICK, Timo, DWIVEDI-YU, Jane, DESSÌ, Roberto, RAILEANU, Roberta, LOMELI, Maria, ZETTMAYER, Luke, CANCEDEA, Nicola a SCIALOM, Thomas. Toolformer: Language Models Can Teach Themselves to Use Tools. *Advances in Neural Information Processing Systems*. Online. 2023. Vol. 36, p. 68539–68551. Available from: <https://arxiv.org/abs/2302.04761>
 30. ANTHROPIC. Model Context Protocol documentation. Online. 2026. Available from: <https://modelcontextprotocol.io/docs/2026-07-28/getting-started/intro#explore-mcp>
 31. ANTHROPIC. Building effective agents. Online. 2024. Available from: <https://www.anthropic.com/research/building-effective-agents>
 32. JIANG, Huiqiang, WU, Qianhui, LIN, Chin-Yew, YANG, Yuqing a QIU, Lili. LLMingua: Compressing Context for Accelerated Inference of Large Language Models. *arXiv preprint arXiv:2310.05736*. Online. 2023. Available from: <https://arxiv.org/abs/2310.05736>
 33. LEWIS, Patrick, PEREZ, Ethan, PIKTUS, Aleksandra, PETRONI, Fabio, KARPUKHIN, Vladimir, GOYAL, Naman, KÜTTLER, Heinrich, LEWIS, Mike, YIH, Wen-tau, ROCKTÄSCHEL, Tim, RIEDEL, Sebastian a KIELA, Douwe. Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks. *Advances in Neural Information Processing Systems*. Online. 2020. Vol. 33, p. 9459–9474. Available from: <https://arxiv.org/abs/2005.11401>
 34. WU, Qingyun, BANSAL, Gagan, ZHANG, Jieyu, WU, Yiran, LI, Beibin, ZHU, Erkang, JIANG, Li, ZHANG, Xiaoyun, ZHANG, Chi, LIU, Jue, AWADALLAH, Ahmed Hassan, WHITE, Ryan W., BURGER, Doug a WANG, Chi. AutoGen: Enabling Next-Gen LLM Applications via Multi-Agent Conversation. *arXiv preprint arXiv:2308.08155*. Online. 2023. Available from: <https://arxiv.org/abs/2308.08155>

35. MARIUS, Patrik. DarkFactory: autonomous, governed software engineering pipelines. Online. 2026. [Accessed 8 září 2026]. Available from: <https://github.com/marius-patrik/DarkFactory>
36. AINSLIE, Joshua, LEE-THORP, James, JONG, Michiel de, ZEMLYANSKIY, Yury, LEBRÓN, Federico a SANGHAI, Sumit. GQA: Training Generalized Multi-Query Transformer Models from Multi-Head Checkpoints. *arXiv preprint arXiv:2305.13245*. Online. 2023. Available from: <https://arxiv.org/abs/2305.13245>