



Gymnázium J. K. Tyla

Agentic AI, Agentic Engineering and Harness Engineering

ODBORNÁ PRÁCE

Autor práce: Patrik Marius, 4.D

Vedoucí práce: Michal Dočekal

Rozsah práce: 5964 slov / 40510 znaků
Rozsah práce: 5964 slov / 40510 znaků

Prohlášení

Prohlašuji, že jsem tuto studentskou odbornou práci vypracoval/a samostatně pod dohledem vedoucího uvedeného na první straně. Všechny použité zdroje jsou uvedeny v seznamu zdrojů a informace z nich získané jsou v textu řádně označeny odkazem na zdroj. Souhlasím s tím, aby tištěná forma práce byla uchována na Gymnázium J. K. Tyla a tam používána jako tištěný zdroj např. pro další studentské práce či pro prezentaci vzdělávání na GJKT.

V Hradci Králové dne

Podpis autora práce:

.....

Anotace

Tato odborná práce se zabývá současným využitím agentní umělé inteligence při vývoji softwaru. Popisuje, jaké části vývojového procesu mohou dnešní agentní systémy provádět samostatně a jaké nástroje, pravidla a kontrolní mechanismy potřebují pro opakovatelnou práci nad skutečným repozitářem. Praktickou část tvoří návrh a implementace systému DarkFactory, který tyto principy převádí do konkrétní architektury agentního harnessu.

Abstract

This thesis examines the current use of agentic artificial intelligence in software development. It describes which parts of the development process today's agentic systems can perform independently and which tools, rules, and control mechanisms they need for repeatable work on a real repository. The practical part is the design and implementation of DarkFactory, which applies these principles in a concrete agent-harness architecture.

Keywords (Klíčová slova)

Agent Harness (Agentní harness), Agent Loop (Smyčka ReAct) [ReAct Loop], Agentic Engineering (Agentické inženýrství), CI (Průběžná integrace) [Continuous Integration], Context Engineering (Kontextové inženýrství), Guardrail (Deterministický mantinel) [Deterministic Guardrail], HITL (Zapojení člověka do smyčky) [Human-in-the-loop], LLM (Jazykový model) [Large Language Model], Prompt Engineering (Promptové inženýrství), Sandbox (Izolované běhové prostředí), Tools (Nástroje), Version Control (Správa verzí)

Obsah

<u>Prohlášení</u>	2
<u>Anotace</u>	3
<u>Abstract</u>	4
<u>Keywords (Klíčová slova)</u>	5
1 Úvod	10
1.1 Motivace a vymezení problému	10
1.2 Cíl práce a výzkumné otázky	10
1.2.1 Hlavní cíl	10
1.2.2 Dílčí cíle	10
1.2.3 Výzkumné otázky	11
1.3 Metodika práce	11
2 Teoretická část	13
2.1 Úvod	13
2.2 Software Engineering	13
Software Engineering (Softwarové inženýrství)	13
2.2.1 AI-asistovaný vývoj	13
Vibe Coding	13
Slop	14
2.2.2 Specifikace a plánování	14
Spec-Driven Development (Vývoj řízený specifikací)	14
Plánování	14
DAG (Orientovaný acyklický graf) [Directed Acyclic Graph]	14
2.2.3 Řízení změn	15
Version Control (Správa verzí)	15
Branch (Větev)	15
Pull Request	15
2.2.4 Ověřování a integrace	15
CI (Průběžná integrace) [Continuous Integration]	15
Integration Test (Integrační test)	15
2.2.5 Běhová prostředí	15
Runtime (Běhové prostředí)	15
Container (Softwarový kontejner) [Software Container]	16
2.3 Model	16
2.3.1 Jazykové modely	16

Transformer	16
LLM (Jazykový model) [Large Language Model]	16
Tokenizér	16
Token	16
Embedding (Vektorová reprezentace)	17
2.3.2 Inferenční kontext	17
Kontextové okno	17
KV Cache (Mezipaměť klíčů a hodnot) [Key–Value Cache]	17
2.3.3 Limity modelu	18
Degradace kontextu	18
Divergence (Divergence modelu) [Model Divergence]	18
2.4 Harness	18
Agent Harness (Agentní harness)	18
2.4.1 Stav běhu	20
Session (Agentní sezení) [Agent Session]	20
Turn (Tah interakce)	20
Transcript (Přepis)	20
State (Stav)	20
2.4.2 Běh a prostředí	21
Agent Loop (Smyčka ReAct) [ReAct Loop]	21
Environment (Běhové prostředí agenta) [Agent Environment]	21
Sandbox (Izolované běhové prostředí)	21
2.4.3 Rozšíření harnessu	22
Plugins (Rozšíření)	22
Tools (Nástroje)	22
JSON Schema Tool Calling (Vyvolávání nástrojů s JSON Schema)	22
Code Execution (Spouštění kódu)	22
Scripts (Skripty)	22
Hooks (Událostní zachytné body)	22
MCP (Model Context Protocol)	22
Skills (Dovednosti)	23
2.5 Agentic Engineering	24
Agentic Engineering (Agentické inženýrství)	24
2.5.1 Instrukce modelu	24
Prompt Engineering (Promptové inženýrství)	24
System Prompt (Systémový prompt)	24

2.5.2	Kontextové mechanismy	24
	Context Engineering (Kontextové inženýrství)	24
	Context Injection (Vkládání kontextu)	24
	Prompt Injection (Prompt injection)	25
	Compaction (Kompakce kontextu) [Context Compaction]	25
	RAG (Generování rozšířené vyhledáváním) [Retrieval-Augmented Generation]	25
2.5.3	Řízení provádění	25
	Loops (Cílené smyčky) [Goal Loops]	25
	Guardrail (Deterministický mantinel) [Deterministic Guardrail]	25
	HITL (Zapojení člověka do smyčky) [Human-in-the-loop]	25
2.5.4	Multi-Agent Systems	26
	Subagent (Podřízený agent)	26
	Orchestrator (Orchestrátor)	26
	Handoff (Předání řízení)	26
	Swarm (Roj)	26
	Graphs (Pracovní grafy) [Workflow Graphs]	26
3	Praktická část	27
3.1	Úvod	27
3.2	Návrh systému DarkFactory	27
3.2.1	Cíle návrhu	27
3.2.2	Celková architektura	27
	DarkFactory	27
3.2.3	Vykonávací jádro a stav	28
	Protocol (Protokol DarkFactory) [DarkFactory Protocol]	28
	Run State (Stav běhu)	28
	Model Routing (Směrování modelu)	28
	Supervisor (Dohled nad během) [Execution Supervisor]	28
	Result Capture (Zachycení výsledku)	29
	Recovery (Obnova běhu)	29
3.2.4	Systém capabilities	29
	Capability	29
	Capability ABI (ABI capabilities)	29
	Capability Adapter (Adaptér capability)	29
3.2.5	Externí integrace	30
	GitHub Control Plane (GitHub jako řídicí vrstva)	30

3.2.6	Identita a bezpečnostní hranice	30
	Keychain (Správa strojových přihlašovacích údajů) [Machine Credential Key-chain]	30
	Auth (Autentizace uživatele) [Browser Authentication]	30
3.2.7	Rozhraní	30
	df CLI (Příkazové rozhraní df) [df Command-Line Interface]	31
	DarkFactory Web (Webové rozhraní DarkFactory)	31
	DarkFactory Docs (Kompilátor dokumentace DarkFactory) [DarkFactory Documentation Compiler]	31
3.3	Životní cyklus požadavku	31
3.3.1	Zachycení požadavku	31
	Request (Požadavek DarkFactory) [DarkFactory Request]	31
3.3.2	Plánování a schválení	31
	Planning (Plánování DarkFactory) [DarkFactory Planning]	32
	Review/Fix Loop (Smyčka revize a opravy)	32
3.3.3	Implementace	32
3.3.4	Ověření a revize	32
	Deterministic Verification (Deterministické ověření)	32
3.3.5	Finalizace a integrace	33
	Final Alignment (Finální kontrola souladu)	33
	Reconciliation (Rekonciliace stavu) [State Reconciliation]	33
3.3.6	Obnova a pokračování	33
3.4	Výsledky a diskuse	33
3.4.1	Metoda ověření	33
3.4.2	Technické výsledky	34
3.4.3	End-to-end ověření	34
3.4.4	Ověření na cílových repozitářích	35
3.4.5	Vyhodnocení cílů a výzkumných otázek	35
	Vyhodnocení výzkumných otázek	35
3.4.6	Omezení	35
	Omezení evaluace	35
3.4.7	Diskuse	36
4	Závěr	37
	<u>Seznam obrázků a tabulek</u>	38
	<u>Seznam příloh</u>	39
	Seznam zdrojů	40

1 Úvod

Tato práce zkoumá, jak dnes účinně využívat agentní umělou inteligenci při vývoji softwaru.

Zaměřuje se na to, co současní agenti dokážou samostatně provést a jaké prostředí, nástroje a pravidla potřebují, aby jejich práce byla opakovatelná a kontrolovatelná.

Praktickým příkladem je DarkFactory, na kterém jsou popsány principy převedeny do konkrétní architektury a vývojového procesu. Cílem úvodu je stručně vymezit, co práce zkoumá, proč je téma aktuální a podle čeho bude navržené řešení posuzováno.

1.1 Motivace a vymezení problému

Současné agentní systémy dokážou nad softwarovým projektem provádět více kroků, pracovat se soubory a nástroji a ověřovat vlastní změny. Hlavním problémem této práce proto není samotné generování kódu, ale technická vrstva, která převádí schopnosti jazykového modelu do řízeného, obnovitelného a ověřitelného vývojového procesu.

V softwarovém inženýrství tento posun reprezentují například Codex a Claude Code, které pracují nad repozitáři, upravují soubory a používají nástroje pro build nebo testování. ^(1,2)

Rozšíření generativní AI zároveň vytváří praktický důvod tyto systémy studovat: Microsoft AI Economy Institute pro první čtvrtletí roku 2026 odhadl používání generativní AI na 17,8 % světové populace ve věku 15–64 let. ⁽³⁾ Tento údaj v práci slouží pouze jako kontext rozšíření technologie, nikoli jako metrika kvality nebo autonomie agentních systémů.

DarkFactory slouží jako konkrétní artefakt, na kterém práce zkoumá oddělení modelu, trvalého stavu, prostředí, nástrojů a kontrolních mechanismů.

1.2 Cíl práce a výzkumné otázky

Tato část stanovuje hlavní cíl, dílčí cíle a výzkumné otázky práce. Společně vymezují rozsah návrhu DarkFactory a rámec jeho evaluace.

1.2.1 Hlavní cíl

Navrhnout, implementovat a ověřit architekturu agentního harnessu pro dlouhotrvající vývoj softwaru, která odděluje jazykový model od trvalého stavu, prostředí a kontrolních mechanismů a umožňuje autonomní provádění změn při zachování explicitních bodů lidského rozhodnutí.

DarkFactory je implementační artefakt této architektury. Úspěšnost cíle se neposuzuje podle obecné převahy nad jinými agenty, ale podle toho, zda implementace doložitelně realizuje navržené mechanismy a zda jimi projde ověřený end-to-end vývojový proces.

1.2.2 Dílčí cíle

- Vymezit teoretické mechanismy Software Engineering, Modelu, Harnessu a Agentic Engineering potřebné pro dlouhotrvající agentní vývoj softwaru.

- Navrhnout a implementovat DarkFactory jako systém s explicitním stavem běhu, odděleným prostředím, capability rozhraním, GitHub control plane a oddělenými hranicemi identity a přihlašovacími údaji.
 - Realizovat řízený životní cyklus požadavku od zachycení zadání přes Planning a implementaci po deterministické ověření, Final Alignment, integraci a obnovu přerušného běhu.
 - Ověřit implementaci pomocí automatických kontrol, end-to-end scénáře a provozu na vybraných cílových repozitářích a výsledky vztáhnout k výzkumným otázkám.
- Dílčí cíle vytvářejí sled od teoretického vymezení přes návrh artefaktu k jeho technickému ověření.

1.2.3 Výzkumné otázky

- O1: Které mechanismy agentního harnessu a vývojového životního cyklu umožňují agentovi samostatně provádět softwarovou změnu, zatímco rozhodnutí s vyšším dopadem zůstávají explicitně řízena člověkem?
 - O2: Jak může agentní harness omezit nebo obnovit neproduktivní či přerušný běh bez ztráty již ověřeného stavu a bez opakování přijatých deterministických účinků?
 - O3: Jak lze oddělit trvalý stav dlouhotrvající úlohy od omezeného kontextového okna modelu tak, aby bylo možné práci po přerušení bezpečně obnovit a pokračovat v ní?
- O1 sleduje řízenou autonomii, O2 odolnost provádění a O3 kontinuitu stavu přes hranice jednotlivých modelových kontextů a běhů. Otázky jsou záměrně formulovány tak, aby na ně bylo možné odpovědět konkrétními architektonickými prvky a reprodukovatelnými důkazy z implementace.

1.3 Metodika práce

Práce používá konstrukční přístup odpovídající design science: vymezuje problém a cíle řešení, navrhuje a implementuje artefakt DarkFactory, demonstruje jeho použití a následně jej technicky vyhodnocuje. ^(4,5)

Teoretická část vychází z odborných článků, standardů, protokolových specifikací a primární dokumentace současných agentních systémů. Jednotlivé mechanismy jsou rozděleny do samostatných konceptů, aby bylo možné přesně oddělit vlastnosti **LLM (Jazykový model) [Large Language Model]**, harnessu a agentických technik.

Předmětem práce není trénování neuronových sítí, optimalizace vah ani matematický rozbor učení modelu. **LLM (Jazykový model) [Large Language Model]** je chápán jako hotová inferenční komponenta a je popsán pouze v rozsahu nutném pro vysvětlení dalších částí systému.

Praktická část používá zdrojový kód, typované kontrakty, testy, workflow a generované artefakty DarkFactory jako primární důkaz skutečné implementace. Evaluace kombinuje kontrolu architektonického souladu, automatické buildy a testy, end-to-end průchod řízeným životním cyklem a ověření na vybraných cílových repozitářích.

Práce neprovádí statistický benchmark obecné výkonnosti agentních systémů. Každá odpověď na výzkumnou otázku musí být omezena na tvrzení, která podporují konkrétní reprodukovatelné důkazy.

2 Teoretická část

Vymezení konceptů potřebných pro pochopení současného agentního vývoje softwaru. Postupuje od Software Engineering přes Model a Harness k Agentic Engineering.

2.1 Úvod

Vymezení hranic teoretické části a vztahů mezi jejími hlavními vrstvami. Jazykový model je v práci chápán jako hotová inferenční komponenta. Teoretická část postupuje přes Software Engineering a Model k Harnessu a Agentic Engineering. Harness kolem modelu vytváří stavové, nástrojové a kontrolní mechanismy, na které navazují agentické techniky.

2.2 Software Engineering

Software Engineering (Softwarové inženýrství)

Systematické uplatňování inženýrských principů na specifikaci, vývoj, ověřování, provoz a údržbu softwarových systémů. ⁽⁶⁾

Pro tuto práci poskytuje procesní rámec, ve kterém musí být změny nejen vytvořeny, ale také řízeny, ověřeny a integrovány.

2.2.1 AI-asistovaný vývoj

Vibe Coding

Způsob tvorby softwaru, při kterém člověk iteruje pomocí pokynů v přirozeném jazyce bez průběžné kontroly vygenerovaného kódu. ⁽⁷⁾

Termín zavedl Andrej Karpathy v roce 2025 pro styl práce, ve kterém vývojář převážně přijímá a směřuje modelový výstup místo detailního čtení kódu. ^(7, 8)

Tweet Andreje Karpathyho z 2. února 2025, ve kterém popsal původní význam Vibe Coding.



Andrej Karpathy ✓
@karpathy



There's a new kind of coding I call "vibe coding", where you fully give in to the vibes, embrace exponentials, and forget that the code even exists. It's possible because the LLMs (e.g. Cursor Composer w Sonnet) are getting too good. Also I just talk to Composer with SuperWhisper so I barely even touch the keyboard. I ask for the dumbest things like "decrease the padding on the sidebar by half" because I'm too lazy to find it. I "Accept All" always, I don't read the diffs anymore. When I get error messages I just copy paste them in with no comment, usually that fixes it. The code grows beyond my usual comprehension, I'd have to really read through it for a while. Sometimes the LLMs can't fix a bug so I just work around it or ask for random changes until it goes away. It's not too bad for throwaway weekend projects, but still quite amusing. I'm building a project or webapp, but it's not really coding - I just see stuff, say stuff, run stuff, and copy paste stuff, and it mostly works.

3:17 PM · Feb 2, 2025 · **6.8M** Views

Obrázek 1: Původní tweet Andreje Karpathyho o Vibe Coding. ^(7,9)

Slop

Neformální označení pro nekvalitní digitální obsah, zejména obsah vytvořený umělou inteligencí. ⁽¹⁰⁾

V této práci označuje zejména AI-generovaný software, jehož objem nebo zdánlivá úplnost převyšují jeho ověřenou funkčnost a udržitelnost.

2.2.2 Specifikace a plánování

Spec-Driven Development (Vývoj řízený specifikací)

Přístup k AI-asistovanému vývoji, ve kterém explicitní specifikace řídí plánování, implementaci a ověřování změny. ⁽¹¹⁾

Specifikace odděluje požadované chování a omezení od konkrétní implementace a slouží jako společný referenční bod pro člověka i agenta. ⁽¹¹⁾

Plánování

Převod požadavku na explicitní kroky, závislosti a podmínky ověření před prováděním změn. ⁽⁶⁾

Plán rozděluje práci na kontrolovatelné části a určuje, podle jakých podmínek lze posoudit jejich dokončení. Závislosti mezi částmi práce lze reprezentovat například pomocí DAG. ⁽⁶⁾

DAG (Orientovaný acyklický graf) [Directed Acyclic Graph]

Orientovaný graf bez orientovaných cyklů. ⁽¹²⁾

DAG lze použít jako dependency graph: uzly představují prvky nebo úlohy a orientované hrany jejich pořadí či závislosti; absence cyklu umožňuje konzistentní topologické uspořádání. ⁽¹²⁾ Konkrétní Workflow Graph nemusí být DAG, pokud podporuje návraty nebo jiné cykly.

2.2.3 Řízení změn

Version Control (Správa verzí)

Systém pro zaznamenávání historie změn souborů a práci s oddělenými liniemi vývoje. ⁽¹³⁾

Historie commitů umožňuje změny porovnávat, vracet a slučovat; větve umožňují oddělit souběžnou práci před integrací. ⁽¹³⁾

Branch (Větev)

Oddělená linie vývoje v systému správy verzí, která ukazuje na vlastní posloupnost commitů. ⁽¹³⁾

Větev umožňuje izolovat souběžnou změnu od cílové větve a později ji sloučit po kontrole nebo ověření. ^(13, 14)

Pull Request

Návrh na sloučení změn z jedné větve do jiné, kolem kterého GitHub soustřeďuje revizi, diskusi a automatické kontroly. ⁽¹⁵⁾

Pull request zpřístupňuje diff navržené změny a její stav před integrací do cílové větve. ⁽¹⁵⁾

2.2.4 Ověřování a integrace

CI (Průběžná integrace) [Continuous Integration]

Vývojová praxe, při níž se změny průběžně integrují a automaticky ověřují sestavením, testy a dalšími kontrolami. ⁽¹⁶⁾

CI převádí část podmínek kvality do opakovatelných strojově vyhodnotitelných kontrol spouštěných nad změnami. ⁽¹⁶⁾

Integration Test (Integrační test)

Ověření spolupráce více komponent nebo vrstev systému přes jejich rozhraní. ⁽⁶⁾ Integrační test zachycuje chyby vznikající ve vzájemném propojení částí systému, které izolované testování jednotlivých komponent nemusí odhalit. ⁽⁶⁾

2.2.5 Běhová prostředí

Runtime (Běhové prostředí)

V této práci označuje Runtime prostředí a systémové prostředky dostupné programu během jeho vykonávání.

Běhové prostředí vymezuje například procesy, souborový systém, síť, oprávnění a další podmínky vykonávání. Standardizované runtime specifikace mohou tyto podmínky definovat jako přenositelný kontrakt; OCI Runtime Specification například popisuje konfiguraci, běhové prostředí a životní cyklus kontejneru. ⁽¹⁷⁾

Container (Softwarový kontejner) [Software Container]

Izolované procesové prostředí vytvořené podle definované konfigurace a pravidel životního cyklu, ve kterém běží aplikace se svými potřebnými soubory a závislostmi. ⁽¹⁷⁾ Kontejnery poskytují oddělené uživatelské prostředí při sdílení jádra hostitelského operačního systému a usnadňují přenositelné zabalení aplikace a jejích závislostí. ⁽¹⁸⁾

2.3 Model

2.3.1 Jazykové modely

Transformer

Architektura neuronové sítě založená na mechanismu pozornosti, který modeluje vztahy mezi prvky sekvence. ⁽¹⁹⁾ Při autoregresivním generování dekodér z dosavadní sekvence vytváří reprezentaci použitou k odhadu následujícího tokenu. ⁽¹⁹⁾

LLM (Jazykový model) [Large Language Model]

Velký neuronový jazykový model trénovaný na rozsáhlých textových datech pro predikci a generování posloupností tokenů. ⁽²⁰⁾ Současné LLM typicky používají architekturu **Transformer**, která při autoregresivním generování odhaduje další token z předchozí sekvence. ⁽¹⁹⁾ Práci s nástroji, stavem a prostředím zajišťuje okolní agentní runtime nebo harness, nikoli samotná textová inference. ⁽²¹⁾

Tokenizér


Komponenta, která převádí vstup na posloupnost tokenů a jejich identifikátorů a provádí odpovídající zpětné dekodování. ⁽²²⁾ Pravidla tokenizace určují slovník a segmentaci vstupu; subword metody, například Byte Pair Encoding, umožňují skládat text z jednotek menších než celé slovo. ⁽²²⁾

Token

Diskrétní jednotka vstupní nebo výstupní sekvence reprezentovaná identifikátorem ve slovníku tokenizéru. ⁽²²⁾ Token nemusí odpovídat celému slovu; subword tokenizace může pracovat s částmi slov nebo jinými textovými fragmenty. ⁽²²⁾ Identifikátor tokenu je před zpracováním neuronovou sítí převeden na vektorovou reprezentaci.

Embedding (Vektorová reprezentace)

Vícerozměrná vektorová reprezentace diskrétních prvků, v níž geometrické vztahy mohou zachycovat užitečné vztahy mezi reprezentovanými objekty. ⁽²³⁾
V jazykovém modelu embedding převádí identifikátory tokenů na spojitě vektory zpracovatelné neuronovou sítí; vektorové reprezentace lze také porovnávat podle podobnosti. ⁽²³⁾



Obrázek 2: Ilustrativní 2D projekce vztahu $\text{král} - \text{muž} + \text{žena} \approx \text{královna}$; osy Pohlaví a Královský status slouží pouze k názornému vysvětlení a nepředstavují doslovné naučené dimenze embeddingového prostoru.

2.3.2 Inferenční kontext

Kontextové okno

Maximální rozsah tokenové sekvence dostupný modelu v jednom inferenčním běhu. ⁽²⁴⁾
Do aktivního kontextu se společně vkládají instrukce, uživatelské vstupy, historie a výsledky nástrojů. Samotná nominální délka okna nezaručuje, že model všechny vložené informace využije stejně spolehlivě. ⁽²⁴⁾

KV Cache (Mezipaměť klíčů a hodnot) [Key-Value Cache]

Mezipaměť dříve vypočtených klíčů a hodnot v pozornostních vrstvách transformeru používaná při autoregresivním generování. ⁽²⁵⁾
Při generování dalšího tokenu lze uložené klíče a hodnoty předchozí sekvence znovu použít místo jejich úplného přepočítání; paměťové nároky cache přitom rostou s délkou aktivní sekvence. ^(25, 26)

2.3.3 Limity modelu

Degradace kontextu

Pokles spolehlivosti, s níž model využívá relevantní informace v dlouhém nebo zahlceném kontextu. ⁽²⁴⁾

Experimenty s dlouhým kontextem ukazují, že výkon může záviset na poloze relevantní informace a klesat, když je umístěna uvnitř dlouhého vstupu. ⁽²⁴⁾

Divergence (Divergence modelu) [Model Divergence]

V této práci označuje postupné odchýlení pracovní reprezentace nebo generované trajektorie modelu od zamýšleného cíle či skutečného stavu.

Divergenci mohou podporovat dlouhý nebo zahlcený kontext, ztrátová kompakce a převzetí nepřesné mezurepresentace jako dalšího vstupu. Tento pojem zde zahrnuje i jev dříve označovaný jako sémantický posun. ^(24,27)

2.4 Harness

Agent Harness (Agentní harness)


Běhová a orchestrační vrstva, která propojuje jazykový model se stavem, nástroji a prostředím. ⁽²⁸⁾

Harness řídí smyčku modelových volání a směřuje nástrojové akce do příslušné infrastruktury; může současně spravovat pracovní kontext, stav běhu a podmínky pokračování nebo ukončení. ⁽²⁸⁾ Opakované jednání v této práci reprezentuje **Agent Loop (Smyčka ReAct) [ReAct Loop]**.

Codex. Agentní vývojový systém OpenAI určený pro samostatné plnění softwarově-inženýrských úloh. ⁽¹⁾

Desktopová aplikace umožňuje řídit více agentů paralelně, oddělovat jejich práci do vláken a worktree, kontrolovat diffy a delegovat dlouhotrvající úlohy. ⁽¹⁾

Rozhraní pro práci s agentními úlohami a dovednostmi.




Obrázek 3: Aplikace Codex. Zdroj: OpenAI ⁽¹⁾.

Claude Code. Agentní vývojové prostředí společnosti Anthropic dostupné v terminálu, IDE, na webu a v desktopové aplikaci. ⁽²⁾

Claude Code může plánovat změny, upravovat soubory, spouštět příkazy a testy, používat Git a MCP a vytvářet pull requesty. ⁽²⁾

Čtení souboru, zápis změny a průběžný stav agentní úlohy.




Obrázek 4: Claude Code při práci se souborem. Zdroj: Anthropic ⁽²⁾.

Claude Desktop (Aplikace Claude pro desktop) [Claude Desktop App]. Desktopová aplikační vrstva nad modely Claude, která propojuje konverzaci s lokálními soubory, aplikacemi, webem a dalšími schopnostmi. ⁽²⁹⁾

Se souhlasem uživatele může aplikace číst, upravovat a ukládat soubory a pracovat s dalšími aplikacemi. ⁽²⁹⁾

Konverzace s pracovním artefaktem a samostatným pracovním povrchem.



Obrázek 5: Aplikační rozhraní Claude. Zdroj: Anthropic ⁽²⁹⁾.

2.4.1 Stav běhu

Session (Agentní sezení) [Agent Session]

Persistovaná jednotka agentní interakce, která umožňuje navazovat na předchozí průběh mezi jednotlivými běhy. ⁽³⁰⁾

Session uchovává historii nebo záznam událostí mimo aktuální modelový kontext a při pokračování z něj lze znovu sestavit relevantní vstup. ^(28, 30) V této práci Session zastřešuje jednotlivé tahy, jejich transcript a stav potřebný pro pokračování.

Turn (Tah interakce)

Jedna diskretní jednotka interakce v konverzačním nebo agentním běhu, například vstup uživatele, výstup modelu nebo výsledek nástroje. ⁽³¹⁾

Posloupnost tahů vytváří historii session; v agentní smyčce může výsledek jednoho tahu ovlivnit rozhodnutí v následujícím tahu. ⁽³¹⁾

Transcript (Přepis)

Uspořádaný historický záznam událostí nebo položek vzniklých během Session, například zpráv, tahů a výsledků nástrojů. ⁽²⁸⁾

Transcript odpovídá na otázku, co se během běhu stalo. Není totožný se State, který zachovává aktuální pracovní skutečnosti, ani s aktivním kontextem, který obsahuje pouze informace právě předané modelu. Persistovaný transcript lze při pokračování použít k rekonstrukci potřebného kontextu. ⁽²⁸⁾

State (Stav)

Persistovaná reprezentace aktuálních skutečností a řídicích údajů, které musí harness zachovat mezi jednotlivými kroky běhu. ⁽²⁸⁾


State odpovídá na otázku, co je pro pokračování právě platné. Nemusí obsahovat úplnou historii Transcriptu a nemusí být celý předán modelu; Context Engineering vybírá, která část dostupného stavu a historie vstoupí do aktivního kontextu. ⁽²⁸⁾

2.4.2 Běh a prostředí

Agent Loop (Smyčka ReAct) [ReAct Loop]

Iterativní cyklus, v němž model vyhodnotí stav, zvolí akci, harness ji provede a výsledek vrátí do další iterace. ⁽³¹⁾

ReAct formalizuje střídání rozhodnutí, akce a pozorování výsledku; nové pozorování se stává vstupem dalšího kroku. ⁽³¹⁾



Obrázek 6: Smyčka ReAct: model zvolí akci, harness ji provede a výsledek vrátí modelu.

Environment (Běhové prostředí agenta) [Agent Environment]

Vnější prostředí, které agent prostřednictvím harnessu pozoruje a mění, například pracovní soubory, procesy, síťové služby a další systémové prostředky. ⁽²⁸⁾

Environment představuje skutečný stav světa mimo model: změna souboru nebo spuštění procesu mění prostředí, nikoli pouze textový kontext. Harness určuje, které části prostředí jsou dostupné a jakými rozhraními na ně může agent působit. ⁽²⁸⁾

Sandbox (Izolované běhové prostředí)

Oddělené běhové prostředí, ve kterém agent může spouštět kód nebo měnit pracovní soubory bez přímého přístupu ke všem prostředkům hostitelského systému. ⁽²⁸⁾ Sandbox vytváří bezpečnostní hranici kolem nedůvěryhodných účinků; konkrétní realizace může používat například kontejner nebo microVM. ^(28, 32)

2.4.3 Rozšíření harnessu

Plugins (Rozšíření)

V této práci označují Plugins distribuovatelný mechanismus pro doplnění schopností a běhového chování agentního prostředí. ⁽³³⁾

Konkrétní platformy mohou do jednoho plugin balíčku zahrnout různé druhy rozšíření, například skills, agenty, hooks nebo konfiguraci MCP serverů. ⁽³³⁾ Taxonomie této práce ale odděluje koncept Skills od Plugins a pod Plugins řadí Tools, Scripts, Hooks a MCP.

Tools (Nástroje)

Rozhraní, kterým agent vyvolává operace mimo samotnou textovou inferenci, například čtení dat, volání API nebo změnu stavu systému. ⁽²¹⁾

Harness zprostředkuje požadavek na nástroj, provede operaci v prostředí a vrátí její výsledek modelu jako další pozorování. ^(21, 34)

JSON Schema Tool Calling (Vyvolávání nástrojů s JSON Schema)

Popis parametrů nástroje pomocí JSON Schema, podle kterého lze validovat strukturu vygenerovaných argumentů. ⁽³⁵⁾

Schéma určuje například povinná pole, datové typy a další omezení; structured-output mechanismy mohou generování argumentů omezit tak, aby zadanému schématu odpovídaly. ⁽³⁶⁾

Code Execution (Spouštění kódu)

Nástrojová schopnost umožňující vykonat program nebo příkaz a vrátit jeho skutečný výstup modelu. ⁽³⁷⁾

Při vývoji softwaru zpřístupňuje agentovi například testy, buildy, formátovače a diagnostické příkazy místo odhadování jejich výsledku. ⁽³⁷⁾

Scripts (Skripty)

Spustitelné soubory nebo posloupnosti příkazů používané k deterministickému provedení opakovatelné operace. ⁽³³⁾

Agentní rozšíření mohou skripty používat pro transformace, validace nebo jiné kroky, které je výhodnější provést programově než novým modelovým rozhodnutím. ^(33, 38)

Hooks (Událostní zachytné body)

Konfigurované reakce spouštěné při určených událostech životního cyklu agentního prostředí. ⁽³⁹⁾

Hook může před nebo po vybrané události spustit deterministickou logiku, například validaci, příkaz nebo jinou automatizaci. ⁽³⁹⁾

MCP (Model Context Protocol)

Otevřený protokol pro standardizované propojení AI aplikací s externími nástroji a datovými zdroji. ⁽⁴⁰⁾

MCP odděluje klientskou AI aplikaci od serverů poskytujících nástroje a další schopnosti, takže integrace lze implementovat mimo vlastní jádro harnessu. ^(40, 41)

Skills (Dovednosti)

Znovupoužitelný balíček instrukcí a volitelných zdrojů, který se načítá pro úlohy odpovídající jeho účelu. ⁽³⁸⁾

Agent Skill je definován souborem `SKILL.md` a může odkazovat na doplňující skripty, reference nebo další zdroje načítané podle potřeby. ⁽³⁸⁾

SKILL.md (Formát SKILL.md) [SKILL.md Format]. Povinný definiční soubor Agent Skill.

Podle specifikace obsahuje YAML frontmatter následovaný instrukcemi v Markdownu;

povinnými poli frontmatteru jsou `name` a `description`. ⁽³⁸⁾

Následující úplný příklad používá povinná pole i několik volitelných polí povolených specifikací: ⁽³⁸⁾

```
---
name: repository-tests
description: Run, diagnose, and summarize the repository test suite. Use
when a software change must be validated before completion.
license: MIT
compatibility: Requires the repository's test runner to be available in
the runtime.
metadata:
  author: DarkFactory
  version: "1.0"
allowed-tools: Bash Read
---

# Repository tests

Use this skill when a change must be validated against the repository's
tests.

## Procedure

1. Detect the test command documented by the repository.
2. Run the smallest relevant test scope first.
3. Fix or report failures before continuing.
4. Run the complete required suite before completion.
5. Report the commands run and the final result.

## Failure reporting
```

For every unresolved failure, include the command, failing target, and relevant output.

Specifikace dovoluje vedle `SKILL.md` také volitelné adresáře například pro skripty, reference a assety; ty se načítají pouze podle potřeby. ⁽³⁸⁾

2.5 Agentic Engineering

Agentic Engineering (Agentické inženýrství)

V této práci zastřešuje návrh systémů, které kolem jazykového modelu zajišťují nástroje, kontext, stav, provádění a kontrolní mechanismy.

Předmětem není trénování modelu, ale inženýrství systému, který z modelových rozhodnutí vytváří řízené akce nad prostředím. ^(21, 42)

2.5.1 Instrukce modelu

Prompt Engineering (Promptové inženýrství)

Systematický návrh instrukcí, příkladů a jejich struktury s cílem ovlivnit chování jazykového modelu. ⁽⁴³⁾

Prompt ovlivňuje pravděpodobnostní chování modelu, ale sám nevynucuje technickou bezpečnostní nebo autorizační hranici; pravidla, která musí systém garantovat, patří do **Guardrail (Deterministický mantinel) [Deterministic Guardrail]** nebo jiné běhové kontroly.

System Prompt (Systémový prompt)

Systémová instrukční vrstva, která vymezuje roli, pravidla a výchozí způsob chování modelu nebo agenta. ⁽⁴³⁾

Systémový prompt poskytuje stabilní instrukční kontext, ale sám o sobě není technickou izolační ani autorizační hranicí. ⁽⁴³⁾

2.5.2 Kontextové mechanismy

Context Engineering (Kontextové inženýrství)

Systematický výběr a správa informací, které jsou modelu zpřístupněny v aktivním kontextu během inference. ⁽⁴⁴⁾

Aktivní kontext může obsahovat instrukce, popisy dostupných nástrojů, externí data a vybranou historii interakce. Jeho obsah je nutné kurátorovat vzhledem k omezené kapacitě a nerovnoměrnému využití dlouhého kontextu. ^(24, 44)

Context Injection (Vkládání kontextu)

V této práci označuje Context Injection cílené vložení relevantních informací do aktivního kontextu až v okamžiku, kdy jsou potřebné pro aktuální krok. ⁽⁴⁴⁾

Just-in-time přístup umožňuje mimo modelový kontext uchovávat odkazy nebo trvalý stav a potřebná data načíst nástrojem až během běhu. ⁽⁴⁴⁾

Prompt Injection (Prompt injection)

Manipulace chování jazykového modelu pomocí instrukcí vložených do vstupu nebo do externího obsahu, který systém následně zpracuje jako kontext. ⁽⁴⁵⁾

Přímá prompt injection přichází v uživatelském vstupu; nepřímá injection je vložena do externích dat, například webové stránky, e-mailu, dokumentu, repozitáře nebo zdroje RAG.

⁽⁴⁶⁾ Typickým příkladem je životopis obsahující skrytou instrukci, která se pokusí ovlivnit následné hodnocení kandidáta modelem, přestože dokument měl sloužit pouze jako data.

⁽⁴⁵⁾ Důsledky proto závisejí také na oprávněních a nástrojích, které má agent k dispozici. ⁽⁴⁷⁾

Compaction (Kompakce kontextu) [Context Compaction]

Zmenšení aktivního kontextu nahrazením části historie kratší reprezentací, typicky shrnutím nebo výběrem důležitých informací. ⁽⁴⁴⁾

Kompakce uvolňuje kapacitu pro další běh, ale příliš agresivní komprese může odstranit detaily, které se později ukážou jako důležité. ^(27, 44)

RAG (Generování rozšířené vyhledávání) [Retrieval-Augmented Generation]

Architektura, ve které systém před generováním vyhledá relevantní informace z externího zdroje a poskytne je modelu jako další kontext. ⁽⁴⁸⁾

RAG odděluje znalost uloženou v externím korpusu od parametrů modelu a umožňuje vybírat podklady podle aktuálního dotazu. ⁽⁴⁸⁾

2.5.3 Řízení provádění

Loops (Cílené smyčky) [Goal Loops]

V této práci označují řídicí smyčky, které opakují jednání podle explicitního cíle, pozorovaného výsledku a podmínky dalšího pokračování nebo ukončení.

Na rozdíl od samotného běhového Agent Loopu zahrnuje Goal Loop také zpětnou vazbu k dosažení cíle, ověření výsledku a rozhodnutí, zda pokračovat, změnit postup nebo běh ukončit. ^(21, 31)

Guardrail (Deterministický mantinel) [Deterministic Guardrail]

V této práci označuje Guardrail programově vynucenou kontrolu, která může před pokračováním běhu validovat nebo zablokovat vstup, výstup či použití nástroje. ⁽⁴⁹⁾

Agentní frameworky mohou guardrails implementovat různými způsoby; zde je důležitá deterministicky vyhodnotitelná hranice oddělená od samotného modelového rozhodnutí.

Kontrola může běh zastavit nebo odmítnout konkrétní akci před provedením jejího účinku.

⁽⁴⁹⁾

HITL (Zapojení člověka do smyčky) [Human-in-the-loop]

Uspořádání automatizovaného procesu, ve kterém člověk v určených bodech poskytuje zpětnou vazbu, schválení nebo rozhodnutí. ⁽⁵⁰⁾

HITL ponechává vybraná rozhodnutí člověku místo úplné automatizace. V agentním workflow může být lidský zásah explicitní přechod nebo schvalovací bod, po kterém automatizované provádění pokračuje. ⁽⁵⁰⁾

2.5.4 Multi-Agent Systems

Subagent (Podřízený agent)

Specializovaná agentní instance, které jiný agent nebo orchestrátor deleguje vymezenou dílčí úlohu. ⁽⁵¹⁾

Subagent umožňuje oddělit roli, instrukce a pracovní kontext dílčí úlohy od koordinujícího běhu a následně vrátit výsledek zpět nadřazené orchestrace. ^(51, 52)

Orchestrator (Orchestrátor)

Koordinační role nebo komponenta, která rozhoduje, kterému specializovanému agentovi předat dílčí práci a jak jeho výsledek začlenit do pokračujícího běhu. ⁽⁵¹⁾

Centralizovaný orchestrátor zůstává vlastníkem hlavního workflow a může specialisty volat jako omezené pracovní jednotky, případně jejich práci kombinovat nebo spouštět paralelně. ^(21, 51)

Handoff (Předání řízení)

Vzor koordinace, při kterém aktivní agent předá další řízení specializovanému agentovi. ⁽⁵¹⁾

Handoff se liší od centralizované orchestrace tím, že specialista není pouze zavolán jako dílčí pracovní jednotka a vrácen orchestrátoru, ale přebírá aktivní pokračování interakce nebo úlohy. ⁽⁵¹⁾

Swarm (Roj)

Decentralizovaný multiagentní vzor, ve kterém agenti lokálně předávají úlohu dalším agentům podle jejich schopností bez nutnosti jediného centrálního orchestrátoru. ⁽⁵³⁾ Jednotliví účastníci sdílejí pracovní kontext a rozhodnutí o dalším aktivním agentovi vzniká prostřednictvím handoffů mezi členy týmu. ⁽⁵³⁾

Graphs (Pracovní grafy) [Workflow Graphs]

Explicitní grafová reprezentace vícefázového workflow, v níž uzly představují dílčí práci a hrany určují přechody nebo závislosti mezi kroky. ⁽⁵²⁾ Workflow Graph může vyjádřit sekvenční, podmíněné i paralelní větvení a může koordinovat více agentů. Pokud hrany vyjadřují pouze acyklické závislosti, může mít podobu DAG; workflow s návraty nebo opakováním však obecně DAG být nemusí. ^(21, 52)

3 Praktická část

Aplikace teoretických principů na konkrétní systém DarkFactory.
Praktická část popisuje ověřenou architekturu DarkFactory, životní cyklus požadavku a doložitelné výsledky implementace.

3.1 Úvod

Vymezení způsobu, jakým praktická část aplikuje teoretické mechanismy na systém DarkFactory.

Praktická část popisuje pouze ověřenou implementaci DarkFactory a následně hodnotí chování a důkazy, které lze skutečně doložit.

3.2 Návrh systému DarkFactory

Tato část popisuje architekturu DarkFactory podle aktuální implementace a jejích veřejných balíčkových a protokolových hranic.
DarkFactory odděluje vykonávací mechanismy, verzované capabilities, GitHub integraci, credential boundaries a operátorská rozhraní do samostatných komponent s explicitními odpovědnostmi. Následující podsekcce vycházejí z aktuálního produktového kontraktu a zdrojového kódu, nikoli z plánované kompatibilní mezivrstvy nebo historické architektury.

(54)

3.2.1 Cíle návrhu

DarkFactory je navržen jako řízený autonomní systém pro vývoj softwaru, ve kterém člověk zadává záměr a schvaluje vybraná rozhodnutí, zatímco systém provádí Planning, implementaci, ověření, revizi, integraci a obnovu běhu. (54)

Návrh sleduje několik současně platných požadavků: běh musí být obnovitelný, skutečné změny musí být ověřovány podle pozorovaného stavu místo tvrzení modelu, agentní chování musí být rozšiřitelné mimo jádro a GitHub musí zůstat trvalou řídicí vrstvou pro Requesty, pull requesty, kontroly a autorizaci. (54)

3.2.2 Celková architektura

DarkFactory odděluje stabilní běhové mechanismy od agentního a doménového chování a od externích integračních hranic.

Root Bun workspace je rozdělen na protocol, core, capability, GitHub, keychain, auth, docs, CLI a web. Core vlastní provádění a stav, capability vrstva rozšiřitelné chování, GitHub trvalou vývojovou řídicí vrstvou a samostatné auth/keychain balíčky oddělují lidskou identitu od strojových přihlašovacích údajů. (54)

DarkFactory

Autonomní systém pro řízený vývoj softwaru, který spojuje agentní běh, verzované capabilities a GitHub jako trvalou řídicí vrstvou.

Aktuální implementace je rozdělena do samostatných balíčků pro protokol, vykonávací jádro, capability systém, GitHub integraci, správu přihlašovacích údajů, autentizaci, dokumentaci, CLI a webové rozhraní.

3.2.3 Vykonávací jádro a stav

Vykonávací jádro DarkFactory vlastní mechanismy, které musí zůstat konzistentní napříč jednotlivými capabilities: sdílené kontrakty, stav workflow, směřování modelů, dohled nad během, zachycení výsledků a obnovu.

`@darkfactory/protocol` poskytuje browser/runtime-safe serializované kontrakty; `@darkfactory/core` nad nimi exportuje graph/run state, routing, Supervisor, result capture a recovery. Tato hranice odděluje deterministické běhové mechanismy od agentního chování dodávaného capabilities. ⁽⁵⁴⁾

Protocol (Protokol DarkFactory) [DarkFactory Protocol]

Sdílená vrstva serializovaných schémat a kontraktů používaná mezi balíčky DarkFactory a capabilities.

Balíček `@darkfactory/protocol` exportuje kontrakty pro modely, workflow, Planning, review, kvóty, zachycení výsledků a recovery a je navržen jako bezpečný pro runtime i browserové použití.

Run State (Stav běhu)

Persistovaná reprezentace aktuálního průběhu workflow, která umožňuje vykonávacímu jádru navázat na předchozí stav místo opakování dokončených účinků. V DarkFactory patří správa graph/run state do vykonávacího jádra a používá sdílené serializované kontrakty z protokolu.

Model Routing (Směřování modelu)

Mechanismus vykonávacího jádra pro výběr vhodného modelu, poskytovatele a účtu podle požadavků úlohy, dostupnosti a provozních omezení. Model Routing je součástí `@darkfactory/core`; vyhodnocuje vhodnost kandidátů podle task kind, capability tier, kontextové kapacity, kvót a dostupnosti. Samotné přepínání mezi kandidáty při selhání řídí Supervisor.

Supervisor (Dohled nad během) [Execution Supervisor]

Komponenta vykonávacího jádra, která řídí jeden modelový běh nad uspořádanou množinou kandidátů a vynucuje jeho provozní hranice. DarkFactory Supervisor spravuje failover mezi modely a poskytovateli, kvótové a rate-limit podmínky, maximální počet tahů, časový rozpočet běhu a capability-tier escalation. Selhaný kandidát může být nahrazen dalším bez opakování již přijatých deterministických účinků.

Result Capture (Zachycení výsledku)

Mechanismus pro převod výsledku agentního kroku a pozorovaných účinků do strukturovaného, validovatelného výsledku.

Aktuální implementace obsahuje schema-driven capture pro strukturované soudy i deterministické zachycení výsledku kódového kroku z reálně změněných souborů, ověřovacích akcí a commitů.

Recovery (Obnova běhu)

Mechanismus DarkFactory pro bezpečné převzetí zachovaného rozpracovaného stavu a rozhodnutí, zda lze předchozí Planning a další důkazy znovu použít.

Recovery ověřuje původ zachovaného stavu, změny požadavku a base SHA, pravidla publikace a podmínky bezpečného odstranění dočasného recovery stavu.

3.2.4 Systém capabilities

Agentní a produktové chování DarkFactory není pevně zabudováno do vykonávacího jádra, ale je dodáváno verzovanými capabilities přes společné ABI. Capability může přidat nástroje, příkazy, graph-node chování, deterministické akce, verifikační pravidla, hooks, dokumentaci nebo požadavky na credentials. Z jedné kanonické TypeScript definice lze generovat podporované adaptéry, takže stejné chování nemusí mít samostatnou ručně udržovanou implementaci pro každý harness nebo integrační formát.

(54)

Capability

Verzovaný modul DarkFactory, který přidává agentní nebo produktové chování přes jednotné rozhraní.

Capability může deklarovat nástroje, příkazy, detektory, graph contributions, verifikaci, hooks, deterministické akce, credential requirements a publikační surfaces.

Capability ABI (ABI capabilities)

Verzovaný kontrakt určující strukturu a kompatibilitu capability modulů DarkFactory. Aktuální ABI definuje metadata, credential requirements, nástroje, příkazy, detektory, graph contributions, verifikační pravidla, hooks, actions a další surfaces, které capability může poskytovat.

Capability Adapter (Adaptér capability)

Odvozené rozhraní, které zpřístupňuje jednu kanonickou capability jinému runtime nebo integračnímu formátu.

Současná implementace umí z capability definice vytvořit nativní in-process adaptér, Pi adaptér a MCP adaptér bez duplikace samotné capability definice.

3.2.5 Externí integrace

Externí stav vývojového procesu zůstává v systémech, které jsou jeho autoritativním vlastníkem, místo vytváření paralelní databáze uvnitř DarkFactory. GitHub v aktuální architektuře vlastní trvalý stav Requestů, pull requestů, kontrol, projektů, událostí a autorizace. DarkFactory nad ním používá typovanou integrační vrstvu `@darkfactory/github`; runtime graph může externí kontroly pozorovat, aniž by jejich stav duplikoval. ⁽⁵⁴⁾

GitHub Control Plane (GitHub jako řídicí vrstva)

Použití GitHubu jako trvalé vrstvy pro repozitáře, pull requesty, kontroly, workflow a další stav řízeného vývojového procesu DarkFactory. DarkFactory odděluje vlastní agentní runtime od trvalého vývojového stavu a oprávnění, která zůstávají reprezentována v GitHubu a jeho integračních rozhraních.

3.2.6 Identita a bezpečnostní hranice

DarkFactory odděluje strojovou identitu a tajné credentials používané runtime od lidské identity používané webovým rozhraním.

`@darkfactory/keychain` je jediným vlastníkem strojových credentials, tokenů, GitHub App private-key operací, redakce a související diagnostiky. `@darkfactory/auth` naproti tomu poskytuje browser-safe autentizaci uživatele a session pro DarkFactory Web; browserová část nesmí importovat machine-secret implementace. ⁽⁵⁴⁾

Keychain (Správa strojových přihlašovacích údajů) [Machine Credential Keychain]

Bezpečnostní hranice DarkFactory pro držení a zpřístupňování strojových přihlašovacích údajů, tokenů a souvisejících autentizačních dat. Balíček `@darkfactory/keychain` vlastní machine credential custody a nesmí být importován browserovými balíčky; zahrnuje mimo jiné OS keychain, vault, GitHub App credentials, OAuth, redaction a diagnostiku.

Auth (Autentizace uživatele) [Browser Authentication]

Oddělená browser-safe hranice pro lidskou autentizaci a session DarkFactory Web. `@darkfactory/auth` odděluje uživatelskou GitHub autentizaci od machine credentials, refresh tokenů, client secrets a GitHub App private-key operací, které zůstávají mimo browserovou část.

3.2.7 Rozhraní

Stejné protokolové a stavové modely jsou zpřístupněny více operátorskými a publikačními rozhraními bez vytvoření druhého vykonávacího systému.

`@darkfactory/cli` vlastní příkaz `df` a interaktivní operátorské rozhraní, `@darkfactory/web` browserové zobrazení a operátorský web a `@darkfactory/docs` headless kompilaci dokumentačního content graphu. Vykreslení dokumentace patří webové vrstvě, nikoli druhému frontendovému runtime. ⁽⁵⁴⁾

df CLI (Příkazové rozhraní df) [df Command-Line Interface]

Veřejné příkazové a operátorské rozhraní DarkFactory pro spouštění a řízení funkcí systému.

Balíček `@darkfactory/cli` skládá veřejné příkazy nad sdílenými protocol, core a capability vrstvami.

DarkFactory Web (Webové rozhraní DarkFactory)

Browserové operátorské a renderovací rozhraní DarkFactory.

`@darkfactory/web` používá pouze browser-safe protocol, GitHub a auth kontrakty a nesmí importovat machine-secret implementace z keychain vrstvy.

DarkFactory Docs (Kompilátor dokumentace DarkFactory) [DarkFactory Documentation Compiler]

Headless dokumentační kompilátor, který vytváří typovaný obsahový graf z kanonických zdrojů projektu.

`@darkfactory/docs` vlastní konfiguraci a kompilaci dokumentace; vykreslení výsledného content graphu patří `@darkfactory/web`.

3.3 Životní cyklus požadavku

3.3.1 Zachycení požadavku

Řízený životní cyklus začíná zachycením původního zadání do trvalého Requestu před zahájením implementace.

Request zachovává verbatim znění zadání, relevantní kontext a explicitní vztahy k další práci. Tím vzniká trvalý referenční bod pro následný Planning a pro pozdější kontrolu, zda implementace stále odpovídá schválenému záměru. ⁽⁵⁴⁾

Request (Požadavek DarkFactory) [DarkFactory Request]

Trvale evidovaná jednotka práce, která zachovává původní zadání a stav doručení před zahájením implementace.

DarkFactory váže řízenou práci na Request reprezentovaný v GitHubu a používá jeho verzi, acceptance criteria a vztahy jako vstup do Planning a následného životního cyklu.

3.3.2 Plánování a schválení

Z Requestu a aktuálního stavu repozitáře vzniká jeden sjednocený Planning artefakt, který před implementací projde nezávislou revizí a jedním explicitním schválením vlastníka.

Planning obsahuje interpretaci požadavku, acceptance criteria, scope, závislosti, pořadí práce a očekávané ověření. Revize a automatická oprava se opakují do čistého výsledku; po materiální změně Requestu, base stavu, závislostí nebo recovery kontextu se předchozí schválení považuje za zastaralé. ⁽⁵⁴⁾

Planning (Plánování DarkFactory) [DarkFactory Planning]

Verzovaný a revidovaný plánovací artefakt, který převádí konkrétní Request a aktuální stav repozitáře na závazný rámec implementace a ověření.

Planning zachovává verbatim Request, acceptance criteria, behavioral contract, scope, exclusions, dependencies, sequencing, verification a známé či ještě zjišťované implementační vlastnosti.

Review/Fix Loop (Smyčka revize a opravy)

Opakovaný DarkFactory mechanismus, ve kterém je Planning nebo implementace nezávisle zkontrolována, zjištění jsou strukturovaně zachycena a následná oprava pokračuje do čistého výsledku.

Runtime ukládá předmět revize, fingerprint kontextu, nalezené problémy, stav čistoty, číslo iterace a historii review/fix kroků.

3.3.3 Implementace

Po schválení Planningu runtime provádí změnu pomocí capabilities a deterministických mechanismů nad pracovním prostředím repozitáře.

Model může rozhodovat o obsahu změny a používat dostupné nástroje, ale pravdu o mutacích nevlastní jeho textový výstup. Stav souborů, diff, scope, verifikační akce, commity a další účinky jsou zjišťovány z prostředí a zachycovány vykonávacím jádrem. ⁽⁵⁴⁾

3.3.4 Ověření a revize

Výsledek implementace je nejprve deterministicky ověřen a následně prochází samotnou review/fix smyčkou.

Automatické kontroly vycházejí z pozorovaných změn a skutečně spuštěných verifikačních akcí. Revize následně hledá problémy v implementaci a může vyvolat opravu a nové ověření; pokud oprava vyžaduje materiální práci mimo schválený Planning, musí být rozsah explicitně změněn a schválen. ⁽⁵⁴⁾

Deterministic Verification (Deterministické ověření)

Ověření výsledku změny pomocí přímo pozorovatelných strojových důkazů místo spoléhání na tvrzení modelu o tom, co provedl.

DarkFactory odvozuje výsledek kódového kroku ze skutečně změněných souborů, scope checku, detekovaných verifikačních akcí, jejich exit stavů a případně vytvořeného commitu.

3.3.5 Finalizace a integrace

Před merge je implementace znovu porovnávána se schváleným Planningem a případnými schválenými změnami rozsahu.

Po Final Alignment následují požadované externí kontroly a finální review nebo merge autorizace. Teprve poté je změna integrována a DarkFactory deterministicky rekonziluje stav navázaných Requestů, pull requestů, projektu a bezpečně odstranitelných větví. ⁽⁵⁴⁾

Final Alignment (Finální kontrola souladu)

Závěrečná kontrola, která před integrací ověřuje soulad implementace s aktuálním schváleným Planningem a případnými schválenými změnami rozsahu. DarkFactory provádí Final Alignment až po deterministickém ověření a čisté implementační review/fix smyčce; teprve poté mohou následovat povinné kontroly, finální review a merge.

Reconciliation (Rekonciliace stavu) [State Reconciliation]

Sjednání trvalého stavu Requestu, pull requestu, projektu a souvisejících workflow po dokončení nebo změně životního cyklu.

DarkFactory používá kanonické stavy Backlog, ToDo, In Progress, Blocked, Done, Superseded a Dropped a po terminálních událostech aktualizuje navázaný trvalý stav podle skutečně dosaženého výsledku.

3.3.6 Obnova a pokračování

Přerušeni běhu, vyčerpání kvóty nebo konflikt nesmí samo o sobě zneplatnit již dokončené a ověřené deterministické účinky.

DarkFactory ukládá stav potřebný k pokračování a při recovery ověřuje jeho původ, změnu Requestu, base SHA a další podmínky bezpečného převzetí. Modelový nebo provider failover používá stejný princip: další kandidát pokračuje nad zachovaným stavem, místo aby bez kontroly opakoval již provedené účinky. ⁽⁵⁴⁾

3.4 Výsledky a diskuse

Tato část odděluje doložené vlastnosti implementace DarkFactory od tvrzení, která vyžadují další end-to-end nebo fleet-level důkaz.

Výsledky vycházejí z konkrétního referenčního commitu, automatických testů, CI check runů a zdrojového kódu. Architektonická existence mechanismu není zaměňována za důkaz jeho úspěšného použití v celém produkčním životním cyklu.

3.4.1 Metoda ověření

Evaluace odděluje tři druhy důkazů: strukturu a kontrakty implementace, automatické testy jednotlivých mechanismů a integrační důkazy z CI nad konkrétním commitem.

Jako reprodukovatelný referenční bod je použit commit `e9c10221b40589512d262a0edb95f709b923150c` z 21. září 2026.⁽⁵⁵⁾ Nad tímto commitem byl vyhodnocen CI run `35616745304`, jeho jednotlivé joby a jejich logy.⁽⁵⁶⁾

Architektonická tvrzení jsou kontrolována proti aktuálním balíčkovým hranicím, protokolovým kontraktům a testovanému zdrojovému kódu. Funkční tvrzení jsou přijata pouze tehdy, pokud pro ně existuje konkrétní test nebo pozorovaný workflow výsledek. Existence deklarované funkce v PRD sama o sobě není považována za důkaz úspěšného provedení.

3.4.2 Technické výsledky

Referenční CI run `35616745304` dokončil všech 15 jobů úspěšně, včetně detekce quality matrix, dokumentace, hlavní testovací sady, testů `@darkfactory/core`, `@darkfactory/keychain`, `@darkfactory/web`, capabilities a čtyř Python testovacích běhů.⁽⁵⁶⁾

Hlavní Bun testovací sada vykazala 670 úspěšných testů v 102 souborech, 0 selhání a 2909 assertion volání. Samostatný test balíčku `@darkfactory/core` vykazal 9/9 úspěšných recovery-contract testů, `@darkfactory/keychain` 13/13 testů a vybraný webový testovací job 4/4.⁽⁵⁶⁾

Testy současně ověřují konkrétní mechanismy používané v architektuře: atomické uložení Run State, detekci stale nebo driftovaného Planningu, zachování konverzační a nástrojové historie při provider failoveru, odvozování výsledku kódového kroku ze skutečně změněných souborů a commitů, blokování změn mimo povolený scope, recovery provenance a blokování secret-bearing recovery materiálu.⁽⁵⁵⁾

Výsledek dokládá, že tyto mechanismy mají implementované automatické ověření a že referenční commit prošel deklarovanou quality pipeline. Neprokazuje sám o sobě úspěšnost libovolné autonomní softwarové úlohy.

3.4.3 End-to-end ověření

Testovací sada ověřuje integrované části agentního běhu a workflow, ale v referenčním evidence setu zatím není jeden reprodukovatelný živý běh, který by prošel celým produkčním životním cyklem Requestu od vytvoření zadání až po merge a následnou rekonsiliaci. Integrační testy pokrývají například přechody workflow, review/fix iterace, persistovaný Run State, události GitHubu, required-check gate, nástrojové účinky, modelový failover, result capture a recovery.⁽⁵⁵⁾

Tato evidence dokládá spolupráci hlavních mechanismů uvnitř testovaného runtime, ale není ekvivalentní živému GitHub scénáři s reálným Requestem, schválením Planningu, vytvořením změny, pull requestem, externími kontrolami, Final Alignment, autorizovaným merge a deterministickou rekonsiliací. Dokud takový běh nebude uložen jako reprodukovatelný artefakt evaluace, práce jej nepočítá jako splněný end-to-end důkaz.

3.4.4 Ověření na cílových repozitářích

Tato část bude obsahovat pouze repozitáře, na kterých byl DarkFactory skutečně spuštěn v rozsahu potřebném pro evaluaci.

Samotná přítomnost instalační konfigurace, workflow nebo submodulu není považována za úspěšné ověření cílového repozitáře. Pro zařazení výsledku je nutný konkrétní commit nebo release DarkFactory, identita cílového repozitáře, provedený scénář a ověřitelné artefakty nebo check runy. Aktuální evidence set tuto fleet-level demonstraci ještě neuzavírá.

3.4.5 Vyhodnocení cílů a výzkumných otázek

Vyhodnocení výzkumných otázek

Strukturované přiřazení každé výzkumné otázky ke konkrétním důkazům, ze kterých bude možné ve finální evaluaci odvodit omezenou odpověď.

O1 bude vyhodnocena pomocí end-to-end životního cyklu Requestu, explicitních schvalovacích bodů, deterministických kontrol, pull requestu a finální integrace. Tato evidence může doložit umístění lidských rozhodnutí a samostatně prováděných kroků, nikoli obecně určit „maximální“ možnou míru autonomie.

O2 bude vyhodnocena pomocí omezení počtu tahů a času, chování Supervisoru při selhání kandidáta nebo kvótě, review/fix smyček, deterministického zachycení výsledku a recovery/resume scénáře. Důkaz musí zahrnovat, že již přijaté deterministické účinky nejsou při pokračování zbytečně opakovány.

O3 bude vyhodnocena pomocí oddělení Run State, Session/Transcriptu a modelového kontextu a pomocí reprodukovatelného přerušení a obnovení běhu. Evidence musí ukázat zachování nezbytného trvalého stavu; sama o sobě nebude dokazovat nulovou informační ztrátu pro libovolně dlouhou úlohu.

3.4.6 Omezení

Omezení evaluace

Vymezení tvrzení, která nelze z architektonického, testovacího a integračního ověření spolehlivě odvodit.

Práce nepředstavuje statistický benchmark úspěšnosti agentů, ceny, latence ani četnosti zacyklení na reprezentativním souboru úloh. Taková tvrzení by vyžadovala samostatný kontrolovaný experiment.

Aktuální evidence také ještě neobsahuje jeden živý produkční běh celého Request lifecycle ani uzavřenou fleet-level evaluaci všech cílových repozitářů. Výsledky proto zatím podporují technickou realizaci a testované vlastnosti jednotlivých mechanismů, nikoli tvrzení o obecné autonomii nebo převaze DarkFactory nad jinými agentními systémy.

3.4.7 Diskuse

Dosavadní evidence podporuje architektonické oddělení modelového rozhodování od deterministických mechanismů stavu, verifikace, credentials a obnovy, ale zatím nepodporuje obecné tvrzení o vyšší výkonnosti nebo úplné autonomii.

Silnou stránkou evaluace je přímá vazba mezi jednotlivými tvrzeními a implementačními nebo testovacími důkazy: například výsledek kódového kroku je odvozován z pracovního stromu a scope checku místo textového tvrzení modelu a recovery kontrakt je testován proti neplatné provenance i citlivému obsahu. ⁽⁵⁵⁾

Slabší část evidence leží na úrovni celého systému. Jednotlivé mechanismy a jejich integrace jsou automaticky testovány a referenční quality run je zelený, ale živá end-to-end demonstrace celého Request lifecycle a ověření na cílové fleetě musí být doplněny dříve, než budou výzkumné otázky uzavřeny finálními odpověďmi.

4 Závěr

Práce zkoumala, jak lze současnou agentní AI účinně zapojit do vývoje softwaru a jakou architekturu musí mít agent harness, aby spojoval autonomii s kontrolovatelným prováděním.

Současné závěry jsou pracovní a budou v závěrečném alignment passu přepsány podle skutečně doložených výsledků, výzkumných otázek a omezení evaluace.

Seznam obrázků a tabulek

Obrázek 1	Původní tweet Andreje Karpathyho o Vibe Coding. ^(7,9)	14
Obrázek 2	Ilustrativní 2D projekce vztahu král – muž + žena $\approx$ královna; osy Pohlaví a Královský status slouží pouze k názornému vysvětlení a nepředstavují doslov- né naučené dimenze embeddingového prostoru.	17
Obrázek 3	Aplikace Codex. Zdroj: OpenAI ⁽¹⁾	18
Obrázek 4	Claude Code při práci se souborem. Zdroj: Anthropic ⁽²⁾	19
Obrázek 5	Aplikační rozhraní Claude. Zdroj: Anthropic ⁽²⁹⁾	20
Obrázek 6	Smyčka ReAct: model zvolí akci, harness ji provede a výsledek vrátí modelu. .	21

Seznam příloh

Seznam zdrojů

1. OPENAI. Introducing the Codex app. Online. 2026. [Accessed 20 září 2026]. Available from: <https://openai.com/index/introducing-the-codex-app/>
2. ANTHROPIC. Claude Code. Online. 2026. [Accessed 20 září 2026]. Available from: <https://claude.com/product/claude-code>
3. MICROSOFT AI ECONOMY INSTITUTE. Global AI Diffusion Q1 2026: Trends and Insights. Online. 2026. [Accessed 21 září 2026]. Available from: <https://www.microsoft.com/en-us/research/wp-content/uploads/2026/05/Microsoft-AI-Diffusion-Report-2026-Q1.pdf>
4. HEVNER, Alan R., MARCH, Salvatore T., PARK, Jinsoo a RAM, Sudha. Design Science in Information Systems Research. *MIS Quarterly*. 2004. Vol. 28, no. 1.
5. PEFERS, Ken, TUUNANEN, Tuure, ROTHENBERGER, Marcus A. a CHATTERJEE, Samir. A Design Science Research Methodology for Information Systems Research. *Journal of Management Information Systems*. 2007. Vol. 24, no. 3, p. 45–77. DOI [10.2753/MIS0742-1222240302](https://doi.org/10.2753/MIS0742-1222240302).
6. SOMMERVILLE, Ian. *Software Engineering*. 10. Pearson, 2016. ISBN 978-0-13-394303-0.
7. KARPATY, Andrej. A new kind of coding I call vibe coding. Online. 2025. [Accessed 20 září 2026]. Available from: <https://twitter.com/karpathy/status/1886192184808149383>
8. WILLISON, Simon. A quote from Andrej Karpathy. Online. 2025. [Accessed 20 září 2026]. Available from: <https://simonwillison.net/2025/Feb/6/andrej-karpathy/>
9. KRAVETS, David. A semantic history: How the term 'vibe coding' went from a tweet to prod. Online. 2026. [Accessed 21 září 2026]. Available from: <https://www.coderabbit.ai/blog/a-semantic-history-how-the-term-vibe-coding-went-from-a-tweet-to-prod>
10. CAMBRIDGE UNIVERSITY PRESS. AI slop. Online. 2026. [Accessed 20 září 2026]. Available from: <https://dictionary.cambridge.org/dictionary/english/ai-slop>
11. BÖCKELER, Birgitta. Understanding Spec-Driven-Development: Kiro, spec-kit, and Tessel. Online. 2025. [Accessed 21 září 2026]. Available from: <https://martinfowler.com/articles/exploring-gen-ai/sdd-3-tools.html>
12. NETWORKX DEVELOPERS. Directed Acyclic Graphs and Topological Sort. Online. 2026. [Accessed 21 září 2026]. Available from: <https://networkx.org/nx-guides/content/algorithms/dag/index.html>
13. CHACON, Scott a STRAUB, Ben. *Pro Git*. 2. New York : Apress, 2014. ISBN 978-1-4842-0076-6.
14. GITHUB. Branches | GitHub Docs. Online. 2026. [Accessed 21 září 2026]. Available from: <https://docs.github.com/en/pull-requests/reference/branches>

15. GITHUB. About pull requests | GitHub Docs. Online. 2026. [Accessed 21 září 2026]. Available from: <https://docs.github.com/en/pull-requests/get-started/about-pull-requests>
16. HUMBLE, Jez a FARLEY, David. *Continuous Delivery: Reliable Software Releases through Build, Test, and Deployment Automation*. Boston : Addison-Wesley, 2010. ISBN 978-0-321-60191-9.
17. OPEN CONTAINER INITIATIVE. Open Container Initiative Runtime Specification. Online. 2025. [Accessed 21 září 2026]. Available from: <https://specs.opencontainers.org/runtime-spec/>
18. DOCKER. What is a container?. Online. 2026. [Accessed 21 září 2026]. Available from: <https://docs.docker.com/get-started/docker-concepts/the-basics/what-is-a-container/>
19. VASWANI, Ashish, SHAZEER, Noam, PARMAR, Niki, USZKOREIT, Jakob, JONES, Llion, GOMEZ, Aidan N., KAISER, Łukasz a POLOSUKHIN, Illia. Attention Is All You Need. *arXiv preprint arXiv:1706.03762*. Online. 2017. Available from: <https://arxiv.org/abs/1706.03762>
20. BROWN, Tom B., MANN, Benjamin, RYDER, Nick, SUBBIAH, Melanie, KAPLAN, Jared, DHARIWAL, Prafulla, NEELAKANTAN, Arvind, SHYAM, Pranav, SASTRY, Girish, ASKELL, Amanda, HERBERT-VOSS, Ariel, KRUEGER, Gretchen, HENIGHAN, Tom, CHILD, Rewon, RAMESH, Aditya, ZIEGLER, Daniel M., WU, Jeffrey, WINTER, Clemens, HESSE, Christopher, CHEN, Mark, SIGLER, Eric, LITWIN, Mateusz, GRAY, Scott, CHESSE, Benjamin, CLARK, Jack, BERNER, Christopher, MCCANDLISH, Sam, RADFORD, Alec, SUTSKEVER, Ilya a AMODEI, Dario. Language Models are Few-Shot Learners. *Advances in Neural Information Processing Systems*. Online. 2020. Vol. 33. Available from: <https://arxiv.org/abs/2005.14165>
21. ANTHROPIC. Building effective agents. Online. 2024. Available from: <https://www.anthropic.com/research/building-effective-agents>
22. SENNRICH, Rico, HADDOW, Barry a BIRCH, Alexandra. Neural Machine Translation of Rare Words with Subword Units. *Proceedings of the 54th Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers)*. Online. 2016. P. 1715–1725. Available from: <https://aclanthology.org/P16-1162/>
23. MIKOLOV, Tomas, CHEN, Kai, CORRADO, Greg a DEAN, Jeffrey. Efficient Estimation of Word Representations in Vector Space. *arXiv preprint arXiv:1301.3781*. Online. 2013. Available from: <https://arxiv.org/abs/1301.3781>
24. LIU, Nelson F., LIN, Kevin, HEWITT, John, PARANJAPE, Ashwin, BEVILACQUA, Michele, PETRONI, Fabio a LIANG, Percy. Lost in the Middle: How Language Models Use Long

- Contexts. *Transactions of the Association for Computational Linguistics*. Online. 2024. Vol. 12, p. 157–173. Available from: <https://arxiv.org/abs/2307.03172>
25. AINSLIE, Joshua, LEE-THORP, James, JONG, Michiel de, ZEMLYANSKIY, Yury, LEBRÓN, Federico a SANGHAI, Sumit. GQA: Training Generalized Multi-Query Transformer Models from Multi-Head Checkpoints. *arXiv preprint arXiv:2305.13245*. Online. 2023. Available from: <https://arxiv.org/abs/2305.13245>
 26. DAO, Tri, FU, Daniel Y., ERMON, Stefano, RUDRA, Atri a RÉ, Christopher. FlashAttention: Fast and Memory-Efficient Exact Attention with IO-Awareness. *Advances in Neural Information Processing Systems*. Online. 2022. Vol. 35, p. 16344–16359. Available from: <https://arxiv.org/abs/2205.14135>
 27. JIANG, Huiqiang, WU, Qianhui, LIN, Chin-Yew, YANG, Yuqing a QIU, Lili. LLMingua: Compressing Context for Accelerated Inference of Large Language Models. *arXiv preprint arXiv:2310.05736*. Online. 2023. Available from: <https://arxiv.org/abs/2310.05736>
 28. ANTHROPIC. Scaling Managed Agents: Decoupling the brain from the hands. Online. 2026. [Accessed 21 září 2026]. Available from: <https://www.anthropic.com/engineering/managed-agents>
 29. ANTHROPIC. Navigating the Claude desktop app. Online. 2026. [Accessed 20 září 2026]. Available from: <https://academy.claude.com/tutorials/navigating-the-claude-desktop-app>
 30. OPENAI. Sessions | OpenAI Agents SDK. Online. 2026. [Accessed 21 září 2026]. Available from: <https://openai.github.io/openai-agents-js/guides/sessions/>
 31. YAO, Shunyu, ZHAO, Jeffrey, YU, Dian, DU, Nan, SHAFRAN, Izhak, NARASIMHAN, Karthik a CAO, Yuan. ReAct: Synergizing Reasoning and Acting in Language Models. *arXiv preprint arXiv:2210.03629*. Online. 2022. Available from: <https://arxiv.org/abs/2210.03629>
 32. AGACHE, Alexandru, DEACONESCU, Razvan, IORDACHE, Mihai, LUPU, Alexandra, RADU, Vlad, BUGA, Cezar, BALAN, Catalin a FLORESCU, Andreea. Firecracker: Lightweight Virtualization for Serverless Applications. In : *17th USENIX Symposium on Networked Systems Design and Implementation (NSDI 20)*. Online. 2020. p. 419–434. Available from: <https://www.usenix.org/conference/nsdi20/presentation/agache>
 33. ANTHROPIC. Create plugins | Claude Code Docs. Online. 2026. [Accessed 21 září 2026]. Available from: <https://code.claude.com/docs/en/plugins>
 34. SCHICK, Timo, DWIVEDI-YU, Jane, DESSÌ, Roberto, RAILEANU, Roberta, LOMELI, Maria, ZETTMELMOYER, Luke, CANCELEDDA, Nicola a SCIALOM, Thomas. Toolformer: Language Models Can Teach Themselves to Use Tools. *Advances in Neural Information Processing Systems*. Online. 2023. Vol. 36, p. 68539–68551. Available from: <https://arxiv.org/abs/2302.04761>

35. WRIGHT, Austin, ANDREWS, Henry, HUTTON, Ben a DENNIS, Greg. JSON Schema Draft 2020-12. Online. 2022. [Accessed 20 září 2026]. Available from: <https://json-schema.org/draft/2020-12>
36. OPENAI. Introducing Structured Outputs in the API. Online. 2024. [Accessed 20 září 2026]. Available from: <https://openai.com/index/introducing-structured-outputs-in-the-api/>
37. ANTHROPIC. Code execution tool. Online. 2026. [Accessed 20 září 2026]. Available from: <https://platform.claude.com/docs/en/agents-and-tools/tool-use/code-execution-tool>
38. AGENT SKILLS. Agent Skills Specification. Online. 2026. [Accessed 20 září 2026]. Available from: <https://agentskills.io/specification>
39. ANTHROPIC. Hooks reference | Claude Code Docs. Online. 2026. [Accessed 21 září 2026]. Available from: <https://code.claude.com/docs/en/hooks>
40. ANTHROPIC. Model Context Protocol documentation. Online. 2026. Available from: <https://modelcontextprotocol.io/docs/2026-07-28/getting-started/intro#explore-mcp>
41. ANTHROPIC. Connect Claude Code to tools via MCP. Online. 2026. [Accessed 21 září 2026]. Available from: <https://code.claude.com/docs/en/mcp>
42. WANG, Lei, MA, Chen, FENG, Xueyang, ZHANG, Zeyu, YANG, Hao, ZHANG, Jingsen, CHEN, Zhiyuan, TANG, Jiakai, CHEN, Xu, LIN, Yankai, ZHAO, Wayne Xin, WEI, Zhewei a WEN, Ji-Rong. A Survey on Large Language Model Based Autonomous Agents. *Frontiers of Computer Science*. Online. 2024. Vol. 18, no. 6, p. 186345. Available from: <https://arxiv.org/abs/2308.11432>
43. ANTHROPIC. Prompt Engineering overview. Online. 2026. Available from: <https://platform.claude.com/docs/en/build-with-claude/prompt-engineering/overview>
44. ANTHROPIC. Effective context engineering for AI agents. Online. 2025. [Accessed 21 září 2026]. Available from: <https://www.anthropic.com/engineering/effective-context-engineering-for-ai-agents>
45. OWASP GENAI SECURITY PROJECT. LLM01:2025 Prompt Injection. Online. 2025. [Accessed 21 září 2026]. Available from: <https://genai.owasp.org/llmrisk/llm01-prompt-injection/>
46. OWASP FOUNDATION. LLM Prompt Injection Prevention Cheat Sheet. Online. 2026. [Accessed 21 září 2026]. Available from: https://cheatsheetseries.owasp.org/cheatsheets/LLM_Prompt_Injection_Prevention_Cheat_Sheet.html
47. OPENAI. Understanding prompt injections. Online. 2026. [Accessed 21 září 2026]. Available from: <https://openai.com/safety/prompt-injections/>
48. LEWIS, Patrick, PEREZ, Ethan, PIKTUS, Aleksandra, PETRONI, Fabio, KARPUKHIN, Vladimir, GOYAL, Naman, KÜTTLER, Heinrich, LEWIS, Mike, YIH, Wen-tau, ROCKTÄ-

- SCHEL, Tim, RIEDEL, Sebastian a KIELA, Douwe. Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks. *Advances in Neural Information Processing Systems*. Online. 2020. Vol. 33, p. 9459–9474. Available from: <https://arxiv.org/abs/2005.11401>
49. OPENAI. Guardrails | OpenAI Agents SDK. Online. 2026. [Accessed 21 září 2026]. Available from: <https://openai.github.io/openai-agents-js/guides/guardrails/>
 50. MOSQUEIRA-REY, Eduardo, HERNÁNDEZ-PEREIRA, Elena, ALONSO-RÍOS, David, BOBES-BASCARÁN, José a FERNÁNDEZ-LEAL, Ángel. Human-in-the-loop machine learning: a state of the art. *Artificial Intelligence Review*. Online. 2023. Vol. 56, no. 4, p. 3005–3054. Available from: <https://doi.org/10.1007/s10462-022-10246-w>
 51. OPENAI. Agent orchestration | OpenAI Agents SDK. Online. 2026. [Accessed 21 září 2026]. Available from: https://openai.github.io/openai-agents-python/multi_agent/
 52. WU, Qingyun, BANSAL, Gagan, ZHANG, Jieyu, WU, Yiran, LI, Beibin, ZHU, Erkang, JIANG, Li, ZHANG, Xiaoyun, ZHANG, Chi, LIU, Jue, AWADALLAH, Ahmed Hassan, WHITE, Ryen W., BURGER, Doug a WANG, Chi. AutoGen: Enabling Next-Gen LLM Applications via Multi-Agent Conversation. *arXiv preprint arXiv:2308.08155*. Online. 2023. Available from: <https://arxiv.org/abs/2308.08155>
 53. MICROSOFT. Swarm | AutoGen. Online. 2026. [Accessed 21 září 2026]. Available from: <https://microsoft.github.io/autogen/dev/user-guide/agentchat-user-guide/swarm.html>
 54. MARIUS, Patrik. DarkFactory: autonomous, governed software engineering pipelines. Online. 2026. [Accessed 8 září 2026]. Available from: <https://github.com/marius-patrik/DarkFactory>
 55. MARIUS, Patrik. DarkFactory commit e9c10221. Online. 2026. [Accessed 21 září 2026]. Available from: <https://github.com/marius-patrik/DarkFactory/commit/e9c10221b40589512d262a0edb95f709b923150c>
 56. GITHUB ACTIONS. DarkFactory CI run 35616745304. Online. 2026. [Accessed 21 září 2026]. Available from: <https://github.com/marius-patrik/DarkFactory/actions/runs/35616745304>
 57. SHI, Yifan, ZHANG, Wei a CUI, Tianyi. A Programming Paradigm for Spatiotemporal Composability. *arXiv preprint arXiv:2608.25512*. Online. 2026. Available from: <https://arxiv.org/abs/2608.25512>
 58. WOOLDRIDGE, Michael a JENNINGS, Nicholas R. Intelligent Agents: Theory and Practice. *The Knowledge Engineering Review*. 1995. Vol. 10, no. 2, p. 115–152.
 59. SHINN, Noah, CASSANO, Federico, GOPINATH, Ashwin, NARASIMHAN, Karthik a YAO, Shunyu. Reflexion: Language Agents with Verbal Reinforcement Learning. *Advances in Neural Information Processing Systems*. Online. 2023. Vol. 36, p. 8634–8652. Available from: <https://arxiv.org/abs/2303.11366>

60. MERKEL, Dirk. Docker: lightweight linux containers for consistent development and deployment. *Linux Journal*. 2014. Vol. 2014, no. 239, p. 2.
61. KINSMAN, Timothy, WESSEL, Mairieli, GEROSA, Marco A. a TREUDE, Christoph. How do software developers use GitHub Actions to automate their workflows?. In : *Proceedings of the 18th International Conference on Mining Software Repositories*. 2021. p. 420–431.
62. DABBISH, Laura, STUART, Colleen, TSAY, Jason a HERBSLEB, Jim. Social coding in GitHub: transparency and collaboration in an open software repository. In : *Proceedings of the ACM 2012 conference on Computer Supported Cooperative Work*. 2012. p. 1277–1286.
63. OPENAI. The ChatGPT home page. Online. 2026. [Accessed 20 září 2026]. Available from: <https://help.openai.com/en/articles/9125172>
64. OPENAI DEVELOPER COMMUNITY. Seeking Community Advice: Best Practices for Creating a Comprehensive GPT Manual. Online. 2024. [Accessed 20 září 2026]. Available from: <https://community.openai.com/t/seeking-community-advice-best-practices-for-creating-a-comprehensive-gpt-manual/1033512>
65. FOWLER, Martin. Vibe Coding. Online. 2026. [Accessed 20 září 2026]. Available from: <https://martinfowler.com/bliki/VibeCoding.html>
66. GONÇALVES, Pavlína Wurzel, FREGNAN, Enrico, BAUM, Tobias, SCHNEIDER, Kurt a BACCHELLI, Alberto. Do explicit review strategies improve code review performance? Towards understanding the role of cognitive load. *Empirical Software Engineering*. Online. 2022. Vol. 27, no. 4, p. 99. DOI [10.1007/s10664-022-10123-8](https://doi.org/10.1007/s10664-022-10123-8).
67. GVISOR AUTHORS. Introduction to gVisor security. Online. 2026. [Accessed 20 září 2026]. Available from: https://gvisor.dev/docs/architecture_guide/intro/
68. MARIUS, Patrik. DarkFactory. Online. 2026. [Accessed 20 září 2026]. Available from: <https://github.com/marius-patrik/DarkFactory>
69. GITHUB. Understanding GitHub Actions. Online. 2026. [Accessed 21 září 2026]. Available from: <https://docs.github.com/en/actions/get-started/understand-github-actions>
70. ANTHROPIC. Harness design for long-running application development. Online. 2026. [Accessed 21 září 2026]. Available from: <https://www.anthropic.com/engineering/harness-design-long-running-apps>