



Gymnázium J. K. Tyla

DarkFactory
Agentické a harnessové inženýrství:
Umělá inteligence v praxi

ODBORNÁ PRÁCE

Autor práce: Patrik Marius, 4.D

Vedoucí práce: Michal Dočekal

Rozsah práce: 3630 slov / 24196 znaků
Rozsah práce: 3630 slov / 24196 znaků

Prohlášení

Prohlašuji, že jsem tuto studentskou odbornou práci vypracoval/a samostatně pod dohledem vedoucího uvedeného na první straně. Všechny použité zdroje jsou uvedeny v seznamu zdrojů a informace z nich získané jsou v textu řádně označeny odkazem na zdroj. Souhlasím s tím, aby tištěná forma práce byla uchována na Gymnázium J. K. Tyla a tam používána jako tištěný zdroj např. pro další studentské práce či pro prezentaci vzdělávání na GJKT.

V Hradci Králové dne

Podpis autora práce:

.....

Anotace

Tato odborná práce se zabývá současným využitím agentní umělé inteligence při vývoji softwaru. Popisuje, jaké části vývojového procesu mohou dnešní agentní systémy provádět samostatně a jaké nástroje, pravidla a kontrolní mechanismy potřebují pro opakovatelnou práci nad skutečným repozitářem. Praktickou část tvoří návrh a implementace systému DarkFactory, který tyto principy převádí do konkrétní architektury agentního harnessu.

Abstract

This thesis examines the current use of agentic artificial intelligence in software development. It describes which parts of the development process today's agentic systems can perform independently and which tools, rules, and control mechanisms they need for repeatable work on a real repository. The practical part is the design and implementation of DarkFactory, which applies these principles in a concrete agent-harness architecture.

Keywords (Klíčová slova)

Agent , Agent Harness (Agentní harness) , Agent Loop (Smyčka ReAct) [ReAct Loop] , Agentic Engineering (Agentické inženýrství) , CI (Průběžná integrace) [Continuous Integration] , Context Engineering (Kontextové inženýrství) , Guardrail (Deterministický mantinel) [Deterministic Guardrail] , HITL (Zapojení člověka do smyčky) [Human-in-the-loop] , LLM (Jazykový model) [Large Language Model] , Prompt Engineering (Promptové inženýrství) , Sandbox (Izolované běhové prostředí) , Tool Calling (Vývolávání nástrojů) , Version Control (Správa verzí)

Obsah

<u>Prohlášení</u>	2
<u>Anotace</u>	3
<u>Abstract</u>	4
<u>Keywords (Klíčová slova)</u>	5
1 Úvod	9
1.1 Motivace a vymezení problému	9
1.2 Cíl práce a výzkumné otázky	10
1.2.1 Hlavní cíl	11
1.2.2 Dílčí cíle	11
1.2.3 Výzkumné otázky	11
1.3 Metodika práce	11
2 Teoretická část: koncepty agentického AI	12
2.1 Jazykové modely, chatboti a agenti	12
2.1.1 Chatbot	12
2.1.2 Agent	13
2.1.3 LLM (Jazykový model) [Large Language Model]	13
2.1.3.1 Transformer (Transformerová architektura) [Transformer Architecture]	13
2.1.3.2 Tokenizér	14
2.1.3.3 Token	14
2.1.3.4 Embedding (Vektorová reprezentace)	14
2.1.3.5 Kontextové okno	15
2.1.3.6 KV Cache (Mezipaměť klíčů a hodnot) [Key-Value Cache]	15
2.1.3.7 Turn (Tah interakce) [Interaction Turn]	15
2.2 Agentické inženýrství	16
2.2.1 Vibe Coding	16
2.2.2 Slop	16
2.2.3 Promptové inženýrství	16
2.2.3.1 Systémový prompt	16
2.2.4 Agent Harness (Agentní harness)	16
2.2.4.1 Sandbox (Izolované běhové prostředí)	19
2.2.4.2 Guardrail (Deterministický mantinel) [Deterministic Guardrail] ..	19
2.2.4.3 HITL (Zapojení člověka do smyčky) [Human-in-the-loop]	19
2.2.4.4 Plugins (Rozšíření)	20

2.2.4.5	Agent Loop (Smyčka ReAct) [ReAct Loop]	20
2.2.4.5.1	Agentní sezení	20
2.2.4.5.2	Loop Engineering (Inženýrství prováděcí smyčky) [Execution-loop Engineering]	20
2.2.4.5.3	Patologie divergence	21
2.2.4.6	Tool Calling (Vyvolávání nástrojů)	21
2.2.4.6.1	MCP (Model Context Protocol)	21
2.2.4.7	Skills (Dovednosti)	22
2.2.4.7.1	Skript	23
2.2.4.7.2	Hook (Událostní zachytný bod) [Event Hook]	23
2.2.4.8	Kontextové inženýrství	23
2.2.4.8.1	Compaction (Kompakce kontextu) [Context Compaction]	23
2.2.4.8.2	RAG (Generování rozšířené vyhledáváním) [Retrieval-Augmented Generation]	23
2.2.4.8.3	Degradace kontextu	23
2.2.4.8.4	Sémantický posun	24
2.2.4.9	Graph Engineering (Inženýrství pracovních grafů) [Workflow-graph Engineering]	24
2.2.4.9.1	Subagent (Podřízený agent)	24
2.3	Vývojové prostředí a praxe	24
2.3.1	GitHub	24
2.3.2	Runtime (Běhové prostředí) [Runtime Environment]	24
2.3.3	Softwarové inženýrství	25
2.3.3.1	Plánování	25
2.3.3.2	DAG (Orientovaný acyklický graf) [Directed Acyclic Graph]	25
2.3.3.3	Version Control (Správa verzí)	25
2.3.4	CI (Průběžná integrace) [Continuous Integration]	25
2.3.4.1	Actions (GitHub Actions)	26
2.3.4.2	Container (Softwarový kontejner) [Software Container]	26
2.3.4.3	Integration Test (Integrační test)	26
3	Praktická část: DarkFactory Harness	27
3.1	Výsledky a diskuse	27
3.1.1	Vyhodnocení výzkumných otázek	27
3.1.2	Omezení evaluace	27
4	Závěr	28

<u>Seznam obrázků a tabulek</u>	29
<u>Seznam příloh</u>	30
Seznam zdrojů	31

1 Úvod

Tato práce zkoumá, jak dnes účinně využívat agentní umělou inteligenci při vývoji softwaru.

Zaměřuje se na to, co současní agenti dokážou samostatně provést a jaké prostředí, nástroje a pravidla potřebují, aby jejich práce byla opakovatelná a kontrolovatelná.

Praktickým příkladem je DarkFactory, na kterém jsou popsány principy převedeny do konkrétní architektury a vývojového procesu. Cílem úvodu je stručně vymezit, co práce zkoumá, proč je téma aktuální a podle čeho bude navržené řešení posuzováno.

1.1 Motivace a vymezení problému

Motivací práce je ukázat, jaké úlohy dokážou současné agentní systémy samostatně provádět a jaká technická vrstva umožňuje převést schopnost jazykového modelu do spolehlivého jednání nad skutečným softwarovým projektem.

Generativní AI se během několika let rozšířila do masového používání. CPA.RIP uvádí odhad Gradually AI, podle kterého generativní AI používá přibližně 2,4 miliardy lidí, tedy 29 % světové populace. Článek zároveň upozorňuje, že jde o přibližný odhad založený na datech DataReportal a dalších zdrojích. Současně se rozšiřují systémy, které plánují více kroků, pracují se soubory a nástroji, spouštějí příkazy a testy a vykonávají delší úlohy. ⁽¹⁾

V softwarovém inženýrství tento posun reprezentují například Codex a Claude Code. Jejich oficiální popisy uvádějí práci nad skutečnými repozitáři, úpravy souborů, spouštění testů a další činnosti přesahující jednorázové generování kódu. ^(2,3)

Práce proto sleduje praktické využití těchto systémů při vývoji softwaru: jak jim zpřístupnit repozitář, nástroje a ověřování tak, aby dokázaly samostatně provádět užitečnou část vývojové práce a člověk si zachoval kontrolu nad důležitými rozhodnutími.


Generative AI Usage Worldwide (Používání generativní AI ve světě) . Grafický podklad znázorňuje odhad celosvětového používání generativní AI pomocí bodové reprezentace světové populace.

CPA.RIP dne 14. září 2026 publikoval odhad Gradually AI, podle kterého generativní AI používá přibližně 2,4 miliardy lidí, tedy 29 % světové populace. Výpočet vychází z dat DataReportal pro duben 2026 a článek výslovně uvádí, že všechny globální hodnoty jsou přibližné. ⁽¹⁾

How many people use AI? The world population as a dot grid

Each dot represents roughly 3.3 million people

2,500 dots = 8.3 billion people. Color = most advanced AI usage. Own estimate, as of August 2026.



Sources: DataReportal, OpenAI, ITU et al.

gradually.ai

Obrázek 1: Odhad používání AI ve světové populaci. Zdroj: CPA.RIP / Gradually AI ⁽¹⁾.

1.2 Cíl práce a výzkumné otázky

Cíl práce a výzkumné otázky určují, co má návrh DarkFactory řešit a podle čeho bude posuzován.

Hlavní cíl vymezuje výsledný návrh, dílčí cíle jeho oblasti a výzkumné otázky hodnotící problémy.

1.2.1 Hlavní cíl

Zjistit, jak lze současnou agentní AI účinně používat při vývoji softwaru, a navrhnout architekturu agent harnessu, která podporuje vysokou míru autonomie při zachování lidského dohledu v důležitých rozhodnutích.

Cíl spojuje popis současných agentních postupů s návrhem konkrétního systému Dark-Factory. Výsledná architektura má podporovat samostatné provádění vývojových úloh a současně zachovat jasná místa pro lidskou kontrolu.

1.2.2 Dílčí cíle

- Vymezit infrastrukturu pro správu verzí a průběžné automatické ověřování změn.
 - Popsat limity modelového kontextu, jeho správu a mechanismy pro dlouhotrvající agentní úlohy.
 - Popsat nástrojové a prováděcí mechanismy současného agentního harnessu.
 - Navrhnout způsob, jak zachovat lidský dohled nad důležitými rozhodnutími bez nutnosti ručně provádět každou rutinní změnu.
- Dílčí cíle pokrývají vývojové prostředí, kontext, provádění a lidský dohled.

1.2.3 Výzkumné otázky

- O1: Jak lze současný agentní systém zapojit do vývoje softwaru tak, aby samostatně prováděl co největší část běžné práce a člověk se soustředil na zadání, kontrolu a důležitá rozhodnutí?
 - O2: Jaké mechanismy harnessu pomáhají rozpoznat a zastavit neproduktivní opakování, oscilaci nebo zacyklení během delší úlohy?
 - O3: Jak spravovat pracovní kontext agenta tak, aby při delších úlohách neztrácel důležité požadavky a stav projektu?
- Otázky soustřeďují hodnocení na praktickou míru samostatnosti, spolehlivost prováděcí smyčky a zachování potřebného pracovního kontextu.

1.3 Metodika práce

Práce porovnává veřejně popsané principy současných agentních systémů, rozděluje je do samostatných konceptů a používá je při návrhu DarkFactory.
Předmětem práce není trénování neuronových sítí, optimalizace vah ani podrobná matematika modelového učení. **LLM (Jazykový model) [Large Language Model]** je chápán jako hotová inferenční komponenta a je popsán pouze v rozsahu potřebném pro další části práce.

Architektura kolem modelu je rozložena do samostatných konceptů, aby měl každý mechanismus vlastní definici, popis a nebylo nutné stejné vysvětlení opakovat v několika kapitolách.

Navržené principy jsou následně promítnuty do DarkFactory.

2 Teoretická část: koncepty agentického AI

Teoretická část vymezuje koncepty agentického AI používané v práci. Obsahuje jazykové modely, agentické inženýrství a vývojové prostředí potřebné pro návrh agentního harnessu.

2.1 Jazykové modely, chatboti a agenti

Jazykový model, chatbot a agent jsou odlišné systémové vrstvy.

LLM (Jazykový model) [Large Language Model] provádí inferenci, **Chatbot** přidává konverzační aplikační vrstvu a **Agent** navíc samostatně jedná pomocí nástrojů.

2.1.1 Chatbot

Chatbot je aplikační systém, který zpřístupňuje jazykový model prostřednictvím konverzační interakce.


Na rozdíl od samotného modelu může chatbot přidávat historii konverzace, multimodální vstupy, práci se soubory, webové vyhledávání nebo další nástroje. Tyto funkce patří aplikační vrstvě, nikoli modelu samotnému.

ChatGPT . ChatGPT je konverzační produkt OpenAI zpřístupňující modely prostřednictvím chatového a aplikačního rozhraní.

Jako příklad chatbota odděluje modelovou vrstvu od uživatelského produktu: rozhraní přidává práci se soubory, obrazem, webem a dalšími nástroji, které samotný model neposkytuje.

ChatGPT Web Interface (Webové rozhraní ChatGPT) . Snímek úplného webového rozhraní ChatGPT v prohlížeči.

Snímek ukazuje celé rozhraní chatgpt.com včetně postranního panelu, aktivní konverzace a vstupního pole.



Obrázek 2: Webové rozhraní ChatGPT. Zdroj: OpenAI Developer Community.

(4, 5)

2.1.2 Agent

Agent je softwarový systém řízený jazykovým modelem a vybavený nástroji, který samostatně vnímá stav prostředí a provádí víceukrokové akce směřující k zadanému cíli. Rozdíl mezi *Chatbot* a agentem nespočívá nutně v použitém jazykovém modelu, ale v architektuře jeho zapojení do prostředí. Agent může číst stav repozitáře, provádět změny, spouštět nástroje a podle jejich výsledků pokračovat v další iteraci. Tuto schopnost zajišťuje nadřazená prováděcí a nástrojová vrstva, nikoli samotný model.

2.1.3 LLM (Jazykový model) [Large Language Model]

Jazykový model je neuronový model pro zpracování a generování posloupností tokenů; současné modely tohoto typu typicky používají *Transformer* (*Transformerová architektura*) [*Transformer Architecture*].

Model při generování odhaduje další token z aktivního kontextu. Práci se soubory, příkazy, nástroji a stavem poskytuje až okolní aplikační nebo agentní vrstva.

2.1.3.1 Transformer (Transformerová architektura) [Transformer Architecture]

Transformer je architektura neuronových sítí založená na mechanismu pozornosti, která modeluje vztahy mezi prvky sekvence a tvoří základ většiny současných velkých jazykových modelů.

Současné velké jazykové modely jsou typicky realizovány transformerovou architekturou. Pro generování textu se často používá dekodérové uspořádání, které nad dosavadní sekvencí vytváří reprezentace potřebné k odhadu následujícího tokenu.

2.1.3.2 Tokenizér


Tokenizér je komponenta, která převádí text nebo jiný podporovaný vstup na posloupnost tokenů a jejich identifikátorů a provádí odpovídající zpětné dekodování. Konkrétní tokenizér určuje slovník i pravidla rozdělení vstupu, často pomocí subword metod, jako je Byte Pair Encoding. Stejný text proto může mít u různých modelových rodin odlišný počet tokenů a jinou segmentaci.

2.1.3.3 Token

Token je diskrétní jednotka zpracovávaná jazykovým modelem, odpovídající položce slovníku tokenizéru a reprezentovaná číselným identifikátorem. Token nemusí odpovídat celému slovu; podle použitého tokenizéru může představovat slovo, část slova, znakový fragment nebo jinou jednotku. Po tokenizaci jsou identifikátory převedeny na vektorové reprezentace, se kterými pracují vrstvy modelu.

2.1.3.4 Embedding (Vektorová reprezentace)

Embedding je vícerozměrná vektorová reprezentace tokenů nebo jiných dat, v níž numerické vztahy mezi vektory zachycují užitečné vztahy mezi reprezentovanými objekty. V jazykovém modelu embedding převádí diskrétní identifikátory tokenů na spojitě vektory zpracovatelné neuronovou sítí. Podobné reprezentace lze použít také pro sémantické vyhledávání nebo porovnávání podobnosti. Známým didaktickým příkladem je přibližný relační vztah mezi vektory slov král, muž, žena a královna. Obrázek zobrazuje pouze trojrozměrnou projekci; skutečný embeddingový prostor má obvykle mnohem více rozměrů. ⁽⁶⁾



Obrázek 3: Třírozměrná projekce příkladu vektorového vztahu $\text{král} - \text{muž} + \text{žena} \approx \text{královna}$.

2.1.3.5 Kontextové okno

Kontextové okno je maximální rozsah tokenové sekvence, kterou model při jednom inferenčním běhu dokáže zahrnout do aktivního kontextu.
Do tohoto limitu se společně započítávají systémové instrukce, uživatelský vstup, historie běhu, výsledky nástrojů a další data předaná modelu. Omezení proto přímo ovlivňuje, kolik pracovního stavu může agent udržovat současně bez výběru, externí paměti nebo kompakce.

2.1.3.6 KV Cache (Mezipaměť klíčů a hodnot) [Key-Value Cache]

KV Cache je mezipaměť dříve vypočtených vektorů klíčů a hodnot v pozornostních vrstvách transformeru, která při autoregresivním generování omezuje opakovaný výpočet předchozích tokenů.

Při každém novém tokenu lze znovu použít klíče a hodnoty vytvořené pro předchozí část sekvence namísto jejich úplného přepočítání. Mezipaměť tím snižuje výpočetní režii generování, ale její velikost roste s délkou aktivní sekvence a představuje významnou část paměťových nároků inference.

2.1.3.7 Turn (Tah interakce) [Interaction Turn]

Tah je jedna diskrétní jednotka interakce v konverzačním nebo agentním protokolu, například zpráva uživatele, výstup modelu nebo samostatně evidovaný výsledek nástroje. Agentní běh skládá sekvenci tahů, v níž se střídají vstupy prostředí, modelová rozhodnutí a výsledky provedených akcí. Historie těchto tahů tvoří část pracovního kontextu a harness rozhoduje, které z nich zůstávají modelu dostupné v dalších iteracích.

2.2 Agentické inženýrství

Agentické inženýrství je návrh a provoz systémů kolem jazykových modelů, které zajišťují nástroje, kontext, stav, provádění, mantinely a lidský dohled. Jeho předmětem je systém, který převádí modelový výstup na řízené a ověřitelné jednání, nikoli architektura nebo trénování samotného modelu.

2.2.1 Vibe Coding

Vibe Coding je způsob tvorby softwaru, při kterém člověk zadává požadované chování přirozeným jazykem a iteruje nad výsledkem bez průběžné kontroly vygenerovaného kódu. Termín zavedl Andrej Karpathy v roce 2025. Přístup urychluje experimentování, ale u udržovaného softwaru nenahrazuje kontrolu požadavků, testů a výsledného chování. ^(7,8)

2.2.2 Slop

Slop je neformální označení pro velmi nekvalitní digitální obsah, zejména obsah vytvořený umělou inteligencí. V softwaru se projevuje jako rychle vytvořený, ale zbytečně složitý, duplicitní nebo neověřený výstup; kvalitu proto musí určovat skutečné chování, testy a udržitelnost. ⁽⁹⁾

2.2.3 Promptové inženýrství

Promptové inženýrství je systematický návrh instrukcí a kontextu určujících požadované chování jazykového modelu nebo agenta. Prompt může řídit postup a používání nástrojů, ale nevynucuje bezpečnostní nebo procesní pravidla; ta zajišťuje **Guardrail (Deterministický mantinel)** [**Deterministic Guardrail**].

2.2.3.1 Systémový prompt


Systémový prompt je instrukční vrstva s vysokou prioritou, která vymezuje roli a základní pravidla chování modelu nebo agenta. V harnessu tvoří stabilní instrukční základ pro práci s kontextem a nástroji, nikoli technickou bezpečnostní hranicí.

2.2.4 Agent Harness (Agentní harness)

Agentní harness je aplikační a orchestrační vrstva, která propojuje model s prostředím a řídí jeho opakované jednání nad stavem a nástroji. Harness spravuje pracovní kontext, nástroje, stav úlohy, výsledky akcí a podmínky pokračování nebo ukončení běhu; provádění koordinuje **Agent Loop (Smyčka ReAct)** [**ReAct Loop**]. Codex. Codex je agentní vývojový systém OpenAI určený pro samostatné plnění softwarově-inženýrských úloh. Desktopová aplikace umožňuje řídit více agentů paralelně, oddělovat jejich práci do vláken a worktree, kontrolovat diffy a delegovat dlouhotrvající úlohy. Tím představuje praktický příklad harnessu, který rozšiřuje model o stav, nástroje, izolaci a pracovní postup.

Codex App Interface (Rozhraní aplikace Codex) . Oficiální produktový snímek aplikace Codex.

Snímek dokumentuje specializované rozhraní pro práci s agentními úlohami a dovednostmi.



Obrázek 4: Aplikace Codex. Zdroj: OpenAI.


(2, 2)

Claude Code . Claude Code je agentní vývojové prostředí společnosti Anthropic dostupné v terminálu, IDE, na webu a v desktopové aplikaci.

Systém může plánovat změny, číst a zapisovat soubory, spouštět příkazy a testy, používat Git a MCP a vytvářet pull requesty. Tyto schopnosti vznikají kombinací modelu s nástrojovou a stavovou vrstvou harnessu.

Claude Code Interface (Rozhraní Claude Code) . Oficiální snímek rozhraní Claude Code při práci se zdrojovým kódem.

Snímek zobrazuje čtení souboru, zápis změny a průběžný stav agentní úlohy.



Obrázek 5: Claude Code při práci se souborem. Zdroj: Anthropic.


(3, 3)

Claude Desktop (Aplikace Claude pro desktop) [Claude Desktop App] . Claude Desktop je desktopová aplikační vrstva nad modely Claude, která propojuje konverzaci s lokálními soubory, aplikacemi, webem a dalšími schopnostmi.

Anthropic popisuje desktopovou aplikaci jako prostředí, v němž může Claude se souhlasem uživatele přímo číst, upravovat a ukládat soubory a pracovat s dalšími aplikacemi. Jde proto o širší příklad harnessu než samotný chatbot.

Claude Desktop Interface (Rozhraní aplikace Claude) . Oficiální snímek aplikačního rozhraní Claude s pracovním artefaktem.

Snímek ukazuje, že aplikační vrstva může vedle konverzace zpřístupnit soubory, nástroje a samostatný pracovní povrch.



Obrázek 6: Aplikační rozhraní Claude. Zdroj: Anthropic.

(10, 10)

2.2.4.1 Sandbox (Izolované běhové prostředí)

Sandbox je omezené běhové prostředí, které odděluje prováděný kód a jeho oprávnění od hostitelského systému.

Harness v sandboxu omezuje přístup k souborům, síti, tajnostem a dalším systémovým prostředkům. Silnější izolaci nedůvěryhodného kódu mohou poskytovat virtualizované hranice, například microVM. ⁽¹¹⁾

2.2.4.2 Guardrail (Deterministický mantinel) [Deterministic Guardrail]

Guardrail je programově vynucené omezení nebo kontrola, která neponechává kritické provozní pravidlo pouze na pravděpodobnostním rozhodnutí modelu.

Pokud samotná instrukce v promptu neposkytuje dostatečnou záruku, harness může pravidlo vynutit deterministicky, například omezením přístupových práv, validací parametrů nástroje nebo odmítnutím nepovoleného stavového přechodu. Kritická bezpečnostní a procesní pravidla patří do deterministicky vynucované vrstvy harnessu, nikoli pouze do textových instrukcí modelu.

2.2.4.3 HITL (Zapojení člověka do smyčky) [Human-in-the-loop]

Zapojení člověka do smyčky (HITL) je návrhový vzor, v němž člověk schvaluje nebo přebírá rozhodnutí v určených bodech automatizovaného procesu.

V DarkFactory zůstávají člověku zejména významná nebo nevratná rozhodnutí, zatímco rutinní kroky může harness provádět samostatně. Ke kontrole má předkládat pozorovatelný stav, například diff, výsledky kontrol a chyby. ⁽¹²⁾

2.2.4.4 Plugins (Rozšíření)


Plugin je programové rozšíření běžící přímo v prostředí harnessu, které může doplnit exekuční jádro o systémové adaptéry, ovladače nástrojů nebo deterministické zachytň body.

Plugin rozšiřuje běhovou vrstvu harnessu programovou komponentou; pluginové systémy jsou příkladem dynamické kompozice komponent. ⁽¹³⁾

2.2.4.5 Agent Loop (Smyčka ReAct) [ReAct Loop]

Agent Loop je iterativní cyklus, v němž model vyhodnotí stav, zvolí akci, harness ji provede a výsledek vrátí do další iterace.

Ve vzoru ReAct se cyklus opakuje jako rozhodnutí – volání nástroje – pozorování výsledku – další rozhodnutí. Harness zajišťuje provedení nástroje a vrácení pozorování do aktivního kontextu. ⁽¹⁴⁾



Obrázek 7: Smyčka ReAct: model rozhodne o akci, harness ji provede a výsledek vrátí modelu.

2.2.4.5.1 Agentní sezení

Agentní sezení je ohraničený běh agenta se sdíleným stavem, systémovými instrukcemi, pracovním kontextem, historií tahů a provozními rozpočty.

Správa agentního sezení zahrnuje sestavení systémového promptu, načtení relevantního kontextu repozitáře, průběžné uchování stavu a sledování rozpočtů, například spotřeby tokenů nebo počtu iterací.

2.2.4.5.2 Loop Engineering (Inženýrství prováděcí smyčky) [Execution-loop Engineering]

Inženýrství prováděcí smyčky je návrh a řízení stavových přechodů, podmínek ukončení, rozpočtů, opakování, eskalací a vazby mezi rozhodováním modelu a nástroji.

Inženýrství prováděcí smyčky odděluje provozní řízení od samotného modelového rozhodování. Patří sem stavové přechody, podmínky ukončení, rozpočty běhu, opakování po selhání, detekce uvíznutí a pravidla pro eskalaci nebo lidské schválení.

2.2.4.5.3 Patologie divergence

Divergence je selhání agentní smyčky, při němž se běh vzdaluje cíli opakováním neúčinných kroků, oscilací nebo nekontrolovanou spotřebou zdrojů.

Typickými projevy jsou opakování stejné neúspěšné akce, střídání protichůdných změn a pokračování běhu bez měřitelného pokroku. Harness je proto musí rozpoznat pomocí pozorovaného stavu, limitů a podmínek ukončení. ⁽¹⁵⁾

2.2.4.6 Tool Calling (Vyvolávání nástrojů)

Vyvolávání nástrojů je mechanismus, kterým model požádá okolní systém o provedení konkrétní externí akce a předá jí potřebné parametry.

Nástroj zpřístupňuje modelu operaci, kterou samotná textová inference neprovádí, například čtení souboru, dotaz na API nebo změnu stavu systému. Harness přijme požadavek modelu, zkontroluje jej, provede příslušnou operaci a vrátí výsledek zpět do dalšího kroku agentního běhu.

JSON Schema Tool Calling (Vyvolávání nástrojů s JSON Schema) . JSON Schema Tool Calling popisuje parametry nástroje formálním JSON Schema a před provedením ověřuje, že vygenerované argumenty odpovídají očekávané struktuře.

JSON Schema je standardní formát pro popis struktury a validaci JSON dat. Při vyvolávání nástrojů tak může harness přesně určit povinná pole, datové typy a další omezení vstupu. Moderní rozhraní modelů mohou navíc generování argumentů přímo omezit tak, aby odpovídalo dodanému schématu. ^(16,17)

Code Execution (Spouštění kódu) . Spouštění kódu je nástrojová schopnost, která agentovi umožňuje vykonat program nebo příkaz a získat jeho skutečný výstup.

V současných agentních systémech se tato schopnost typicky poskytuje přes řízené shellové nebo programové prostředí. Například dokumentace Anthropic popisuje provádění Bash a Python operací v sandboxovaném kontejneru včetně práce se soubory. ⁽¹⁸⁾

Pro vývoj softwaru umožňuje Code Execution spouštět testy, formátovače, buildy, diagnostické příkazy a další ověřovací kroky místo toho, aby model jejich výsledek pouze odhadoval.

2.2.4.6.1 MCP (Model Context Protocol)

Model Context Protocol (MCP) je otevřený protokol pro standardizované propojení AI aplikací s externími nástroji, zdroji a daty.

MCP používá klient-server rozhraní nad JSON-RPC, takže nástroje a datové zdroje mohou být implementovány mimo jádro harnessu a znovu používány různými aplikacemi. ⁽¹⁹⁾

2.2.4.7 Skills (Dovednosti)

Skill je znovupoužitelný balíček instrukcí a volitelných zdrojů načítaný pro úlohy, ke kterým je relevantní.

Formát Agent Skills používá soubor SKILL.md s metadaty a instrukcemi a může doplnit skripty, reference nebo další zdroje. ⁽²⁰⁾

SKILL.md (Formát SKILL.md) [SKILL.md Format] . SKILL.md je povinný definiční soubor Agent Skill. Podle specifikace obsahuje YAML frontmatter následovaný instrukcemi v Markdownu; povinnými poli frontmatteru jsou `name` a `description`. ⁽²⁰⁾

Následující úplný příklad používá povinná pole i několik volitelných polí povolených specifikací: ⁽²⁰⁾

```
---
name: repository-tests
description: Run, diagnose, and summarize the repository test suite. Use
when a software change must be validated before completion.
license: MIT
compatibility: Requires the repository's test runner to be available in
the runtime.
metadata:
  author: DarkFactory
  version: "1.0"
allowed-tools: Bash Read
---

# Repository tests

Use this skill when a change must be validated against the repository's
tests.

## Procedure

1. Detect the test command documented by the repository.
2. Run the smallest relevant test scope first.
3. Fix or report failures before continuing.
4. Run the complete required suite before completion.
5. Report the commands run and the final result.

## Failure reporting

For every unresolved failure, include the command, failing target, and
relevant output.
```

Specifikace dovoluje vedle `SKILL.md` také volitelné adresáře například pro skripty, reference a assety; ty se načítají pouze podle potřeby. ⁽²⁰⁾

2.2.4.7.1 Skript

Skript je soubor nebo posloupnost příkazů určených k automatizovanému vykonání interpretem, shellem nebo jiným běhovým prostředím. Skript poskytuje deterministickou exekuci pro úlohy, u nichž není vhodné znovu rozhodovat pomocí jazykového modelu, například pro opakovatelné transformace, validace nebo obslužné kroky dovednosti.

2.2.4.7.2 Hook (Událostní záchytný bod) [Event Hook]

Hook je definovaný bod životního cyklu nebo události, na který lze navázat vlastní deterministickou logiku před, po nebo místo standardního chování systému. Hook váže deterministickou logiku na konkrétní událost životního cyklu harnessu, například před spuštěním nástroje, po dokončení kroku nebo při změně stavu běhu.

2.2.4.8 Kontextové inženýrství

Kontextové inženýrství je systematický výběr, pořadí a životní cyklus informací přístupovaných modelu v aktivním kontextu. Určuje, které instrukce, pracovní stav, výsledky nástrojů a externí data model právě vidí a jak se tento obsah mění při omezené kapacitě kontextového okna.

2.2.4.8.1 Compaction (Kompakce kontextu) [Context Compaction]

Kompakce kontextu je zmenšení aktivního kontextu výběrem, shrnutím nebo nahrazením starší historie kompaktnější reprezentací. Kompakce uvolňuje místo v kontextovém okně za cenu možné ztráty přesných detailů; důležité požadavky a stav proto nemají existovat pouze v rekurzivně shrnované historii. ⁽²¹⁾

2.2.4.8.2 RAG (Generování rozšířené vyhledáváním) [Retrieval-Augmented Generation]

Retrieval-Augmented Generation (RAG) je architektura, v níž systém vyhledá relevantní informace z externího zdroje a vloží je do kontextu modelu. RAG umožňuje načítat potřebné informace podle aktuální úlohy místo jejich trvalého držení v aktivním kontextu. ⁽²²⁾

2.2.4.8.3 Degradace kontextu

Degradace kontextu je pokles schopnosti modelu spolehlivě využívat informace v dlouhém nebo zahlceném kontextu. Nominální délka kontextového okna nezaručuje rovnoměrné využití všech informací; výkon může klesat zejména u relevantních údajů umístěných uvnitř dlouhého vstupu. ⁽²³⁾

2.2.4.8.4 Sémantický posun

Sémantický posun je postupné zkreslování významu nebo faktického stavu při opakovaném ztrátovém shrnování či transformaci kontextu.

Každá další komprese může převzít nepřesnost z předchozí verze jako fakt, až se pracovní reprezentace agenta rozejde se skutečným stavem systému.

2.2.4.9 Graph Engineering (Inženýrství pracovních grafů) [Workflow-graph Engineering]

Inženýrství pracovních grafů je návrh agentních nebo automatizačních workflow jako explicitních grafů uzlů, závislostí a přechodů namísto jediné neomezené smyčky.

Monolitická agentní smyčka selhává při řešení komplexních, vícefázových úloh. Pro spolehlivé škálování se v moderních systémech uplatňuje hierarchická dělba práce a formalizace procesu do podoby grafu.

Škálování je dále rozloženo na dva samostatné koncepty: hierarchickou delegaci prostřednictvím **Subagent (Podřízený agent)** : a explicitní závislosti pracovního postupu prostřednictvím **DAG (Orientovaný acyklický graf) [Directed Acyclic Graph]** .

2.2.4.9.1 Subagent (Podřízený agent)

Subagent je dočasná nebo specializovaná agentní instance, které nadřazený orchestrátor deleguje vymezenou dílčí úlohu a následně převezme její výsledek.

Při hierarchické dělbě práce hlavní orchestrátor rozděljuje rozsáhlou úlohu a jednotlivé části deleguje specializovaným subagentům, například pro průzkum repozitáře, plánování nebo implementaci. Po dokončení dílčího běhu může nadřazený agent převzít pouze jeho výsledek namísto celé pracovní historie subagenta.

2.3 Vývojové prostředí a praxe

Vývojové prostředí a praxe tvoří verzovací, plánovací, integrační a kontrolní mechanismy, ve kterých agent provádí změny softwaru.

Tyto mechanismy poskytují explicitní stav repozitáře, ověřování změn a kontrolní body nezávislé na tvrzení modelu.

2.3.1 GitHub

GitHub je cloudová platforma pro hosting gitových repozitářů a koordinaci vývojového cyklu pomocí Issues, Pull Requests a automatizačních workflow.

GitHub poskytuje nad repozitářem koordinační vrstvu pro zadání práce, revizi změn a automatizaci.

2.3.2 Runtime (Běhové prostředí) [Runtime Environment]

Běhové prostředí je prostředí, ve kterém se program nebo agent vykonává a využívá procesy, souborový systém, síť a další systémové prostředky.

Runtime určuje skutečné nástroje, soubory a oprávnění dostupné agentovi a může být omezen kontejnerem nebo sandboxem.

2.3.3 Softwarové inženýrství

Softwarové inženýrství je systematické uplatňování inženýrských principů na specifikaci, návrh, implementaci, ověřování, provoz a údržbu softwarových systémů. V agentním vývoji zasazuje generování kódu do řízeného procesu požadavků, změn, automatického ověřování a revize.

2.3.3.1 Plánování

Plánování je proces převodu požadavku na explicitní posloupnost kroků, závislostí a ověřovacích podmínek před prováděním změn. V agentním vývoji plán omezuje okamžité přecházení od požadavku k úpravám kódu. Rozděluje práci na kontrolovatelné kroky a předem určuje, jak bude možné ověřit, že jednotlivé části i celek splnily zadání.

2.3.3.2 DAG (Orientovaný acyklický graf) [Directed Acyclic Graph]

Orientovaný acyklický graf (DAG) je orientovaný graf bez orientovaného cyklu, který umožňuje explicitně vyjádřit závislosti a pořadí kroků pracovního postupu. V agentním workflow může DAG modelovat kroky jako uzly a jejich povinné závislosti jako hrany. Tím lze explicitně vyjádřit například posloupnost příjem požadavku → plán → implementace → testy → schválení a zabránit spuštění navazujícího kroku před splněním jeho předpokladů.

2.3.3.3 Version Control (Správa verzí)

Správa verzí je sledování historie změn v repozitáři tak, aby bylo možné změny porovnávat, oddělovat a bezpečně slučovat. DarkFactory používá Git a GitHub jako auditovatelnou hranici mezi pracovním stavem agenta a hlavní historií projektu. Větve, pull requesty a slučování jsou zde prostředky pracovního toku, nikoli samostatné teoretické koncepty. ⁽²⁴⁾

2.3.4 CI (Průběžná integrace) [Continuous Integration]

Průběžná integrace (CI) je vývojová praxe, při níž se změny často integrují a automaticky ověřují sestavením, testy a dalšími kontrolami. Kód vytvořený jazykovým modelem nelze považovat za ověřený pouze proto, že byl úspěšně vygenerován. CI poskytuje externí a opakovatelnou kontrolu sestavení, testů a dalších strojově vyhodnitelných podmínek. ⁽²⁵⁾ Konkrétní automatizační platformu popisuje [Actions \(GitHub Actions\)](#) ; izolaci běhu [Container \(Softwarový kontejner\)](#) [[Software Container](#)] ; a ověření spolupráce částí systému [Integration Test \(Integrační test\)](#) ;

2.3.4.1 Actions (GitHub Actions)

GitHub Actions je automatizační platforma GitHubu pro spouštění deklarovaných workflow a jejich jobů v reakci na události repozitáře nebo ruční spuštění. GitHub Actions spouští deklarovaná workflow v reakci na události repozitáře. V této práci představuje konkrétní automatizační prostředí, které realizuje CI kontroly a další repozitářové procesy.

2.3.4.2 Container (Softwarový kontejner) [Software Container]

Softwarový kontejner je izolované uživatelské běhové prostředí, které balí aplikaci a její závislosti při sdílení jádra hostitelského operačního systému. Kontejner může CI běhu poskytnout opakovatelné uživatelské prostředí s deklarovanými nástroji a závislostmi. Tím omezuje vliv lokální konfigurace vývojářského počítače, aniž by sám o sobě zaručoval úplnou bezpečnostní izolaci.

2.3.4.3 Integration Test (Integrační test)

Integrační test ověřuje spolupráci více komponent nebo vrstev systému přes jejich skutečná rozhraní. V agentním vývoji ověřuje, že změna funguje nejen izolovaně, ale také v toku mezi částmi aplikace, službami, úložišti nebo automatizačními kroky. ⁽²⁶⁾

3 Praktická část: DarkFactory Harness

Praktická část převádí popsané principy do návrhu harnessu DarkFactory. Zaměřuje se na výsledné řešení, jeho vyhodnocení a omezení.

3.1 Výsledky a diskuse

Výsledky a diskuse vyhodnocují, jak návrh DarkFactory odpovídá stanoveným cílům a výzkumným otázkám.

Hodnocení je rozděleno na vyhodnocení výzkumných otázek a omezení evaluace.

3.1.1 Vyhodnocení výzkumných otázek

Vyhodnocení výzkumných otázek posuzuje, jak navržená architektura DarkFactory odpovídá na stanovené otázky.

O1 — autonomie při zachování lidského dohledu: harness odděluje zadání, provádění, automatické kontroly a lidská rozhodnutí tak, aby rutinní kroky mohl vykonávat agent a člověk zůstal u významných rozhodnutí.

O2 — rozpoznání neproduktivního běhu: návrh používá explicitní stav, limity běhu, deterministické kontroly a eskalaci k člověku namísto neomezeného pokračování modelové smyčky.

O3 — zachování kontextu: trvalý stav úlohy je oddělen od omezeného kontextového okna modelu a potřebné informace lze průběžně komprimovat a znovu načítat.

3.1.2 Omezení evaluace

Omezení evaluace vymezují, která tvrzení nelze z architektonického a implementačního ověření spolehlivě odvodit.

Práce nepředstavuje statistický benchmark úspěšnosti agentů, ceny, latence ani četnosti zacyklení na reprezentativním souboru úloh. Taková tvrzení vyžadují samostatný kontrolovaný experiment.

Výsledky proto hodnotí návrh a jeho technické ověření, nikoli obecnou výkonnostní převahu DarkFactory nad jinými agentními systémy.

4 Závěr

Práce zkoumala, jak lze současnou agentní AI účinně zapojit do vývoje softwaru a jakou architekturu musí mít agent harness, aby spojoval autonomii s kontrolovatelným prováděním.

Výsledný návrh odděluje jazykový model od vrstvy, která spravuje stav, nástroje, provádění, automatické kontroly a lidské rozhodovací body.

K O1 architektura přesouvá rutinní kroky na agentní systém a ponechává člověku zadání, kontrolu a důležitá rozhodnutí. K O2 používá explicitní stav, limity, kontrolní uzly a eskalaci namísto neomezené smyčky. K O3 odděluje trvalý stav úlohy od omezeného pracovního kontextu modelu.

DarkFactory tyto principy převádí do konkrétní architektury harnessu. Kvantitativní srovnání výkonu agentů, ceny nebo dlouhodobé spolehlivosti však vyžaduje samostatnou experimentální evaluaci.

Seznam obrázků a tabulek

Obrázek 1	Odhad používání AI ve světové populaci. Zdroj: CPA.RIP / Gradually AI ⁽¹⁾	10
Obrázek 2	Webové rozhraní ChatGPT. Zdroj: OpenAI Developer Community.	13
Obrázek 3	Třírozměrná projekce příkladu vektorového vztahu král – muž + žena $\approx$ královna.	15
Obrázek 4	Aplikace Codex. Zdroj: OpenAI.	17
Obrázek 5	Claude Code při práci se souborem. Zdroj: Anthropic.	18
Obrázek 6	Aplikační rozhraní Claude. Zdroj: Anthropic.	19
Obrázek 7	Smyčka ReAct: model rozhodne o akci, harness ji provede a výsledek vrátí modelu.	20

Seznam příloh

Seznam zdrojů

1. CPA.RIP. How Many People Worldwide Use Generative AI. Online. 2026. [Accessed 21 září 2026]. Available from: <https://cpa.rip/en/news/ai-usage-worldwide/>
2. OPENAI. Introducing the Codex app. Online. 2026. [Accessed 20 září 2026]. Available from: <https://openai.com/index/introducing-the-codex-app/>
3. ANTHROPIC. Claude Code. Online. 2026. [Accessed 20 září 2026]. Available from: <https://claude.com/product/claude-code>
4. OPENAI DEVELOPER COMMUNITY. Seeking Community Advice: Best Practices for Creating a Comprehensive GPT Manual. Online. 2024. [Accessed 20 září 2026]. Available from: <https://community.openai.com/t/seeking-community-advice-best-practices-for-creating-a-comprehensive-gpt-manual/1033512>
5. OPENAI. The ChatGPT home page. Online. 2026. [Accessed 20 září 2026]. Available from: <https://help.openai.com/en/articles/9125172>
6. MIKOLOV, Tomas, CHEN, Kai, CORRADO, Greg a DEAN, Jeffrey. Efficient Estimation of Word Representations in Vector Space. *arXiv preprint arXiv:1301.3781*. Online. 2013. Available from: <https://arxiv.org/abs/1301.3781>
7. KARPATY, Andrej. A new kind of coding I call vibe coding. Online. 2025. [Accessed 20 září 2026]. Available from: <https://twitter.com/karpathy/status/1886192184808149383>
8. WILLISON, Simon. A quote from Andrej Karpathy. Online. 2025. [Accessed 20 září 2026]. Available from: <https://simonwillison.net/2025/Feb/6/andrej-karpathy/>
9. CAMBRIDGE UNIVERSITY PRESS. AI slop. Online. 2026. [Accessed 20 září 2026]. Available from: <https://dictionary.cambridge.org/dictionary/english/ai-slop>
10. ANTHROPIC. Navigating the Claude desktop app. Online. 2026. [Accessed 20 září 2026]. Available from: <https://academy.claude.com/tutorials/navigating-the-claude-desktop-app>
11. AGACHE, Alexandru, DEACONESCU, Razvan, IORDACHE, Mihai, LUPU, Alexandra, RADU, Vlad, BUGA, Cezar, BALAN, Catalin a FLORESCU, Andreea. Firecracker: Lightweight Virtualization for Serverless Applications. In : *17th USENIX Symposium on Networked Systems Design and Implementation (NSDI 20)*. Online. 2020. p. 419–434. Available from: <https://www.usenix.org/conference/nsdi20/presentation/agache>
12. MOSQUEIRA-REY, Eduardo, HERNÁNDEZ-PEREIRA, Elena, ALONSO-RÍOS, David, BOBES-BASCARÁN, José a FERNÁNDEZ-LEAL, Ángel. Human-in-the-loop machine learning: a state of the art. *Artificial Intelligence Review*. Online. 2023. Vol. 56, no. 4, p. 3005–3054. Available from: <https://doi.org/10.1007/s10462-022-10246-w>
13. SHI, Yifan, ZHANG, Wei a CUI, Tianyi. A Programming Paradigm for Spatiotemporal Composability. *arXiv preprint arXiv:2608.25512*. Online. 2026. Available from: <https://arxiv.org/abs/2608.25512>

14. YAO, Shunyu, ZHAO, Jeffrey, YU, Dian, DU, Nan, SHAFRAN, Izhak, NARASIMHAN, Karthik a CAO, Yuan. ReAct: Synergizing Reasoning and Acting in Language Models. *arXiv preprint arXiv:2210.03629*. Online. 2022. Available from: <https://arxiv.org/abs/2210.03629>
15. SHINN, Noah, CASSANO, Federico, GOPINATH, Ashwin, NARASIMHAN, Karthik a YAO, Shunyu. Reflexion: Language Agents with Verbal Reinforcement Learning. *Advances in Neural Information Processing Systems*. Online. 2023. Vol. 36, p. 8634–8652. Available from: <https://arxiv.org/abs/2303.11366>
16. WRIGHT, Austin, ANDREWS, Henry, HUTTON, Ben a DENNIS, Greg. JSON Schema Draft 2020-12. Online. 2022. [Accessed 20 září 2026]. Available from: <https://json-schema.org/draft/2020-12>
17. OPENAI. Introducing Structured Outputs in the API. Online. 2024. [Accessed 20 září 2026]. Available from: <https://openai.com/index/introducing-structured-outputs-in-the-api/>
18. ANTHROPIC. Code execution tool. Online. 2026. [Accessed 20 září 2026]. Available from: <https://platform.claude.com/docs/en/agents-and-tools/tool-use/code-execution-tool>
19. ANTHROPIC. Model Context Protocol documentation. Online. 2026. Available from: <https://modelcontextprotocol.io/docs/2026-07-28/getting-started/intro#explore-mcp>
20. AGENT SKILLS. Agent Skills Specification. Online. 2026. [Accessed 20 září 2026]. Available from: <https://agentskills.io/specification>
21. JIANG, Huiqiang, WU, Qianhui, LIN, Chin-Yew, YANG, Yuqing a QIU, Lili. LLM-Lingua: Compressing Context for Accelerated Inference of Large Language Models. *arXiv preprint arXiv:2310.05736*. Online. 2023. Available from: <https://arxiv.org/abs/2310.05736>
22. LEWIS, Patrick, PEREZ, Ethan, PIKTUS, Aleksandra, PETRONI, Fabio, KARPUKHIN, Vladimir, GOYAL, Naman, KÜTTLER, Heinrich, LEWIS, Mike, YIH, Wen-tau, ROCKTÄSCHEL, Tim, RIEDEL, Sebastian a KIELA, Douwe. Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks. *Advances in Neural Information Processing Systems*. Online. 2020. Vol. 33, p. 9459–9474. Available from: <https://arxiv.org/abs/2005.11401>
23. LIU, Nelson F., LIN, Kevin, HEWITT, John, PARANJAPE, Ashwin, BEVILACQUA, Michele, PETRONI, Fabio a LIANG, Percy. Lost in the Middle: How Language Models Use Long Contexts. *Transactions of the Association for Computational Linguistics*. Online. 2024. Vol. 12, p. 157–173. Available from: <https://arxiv.org/abs/2307.03172>
24. CHACON, Scott a STRAUB, Ben. *Pro Git*. 2. New York : Apress, 2014. ISBN 978-1-4842-0076-6.

25. HUMBLE, Jez a FARLEY, David. *Continuous Delivery: Reliable Software Releases through Build, Test, and Deployment Automation*. Boston : Addison-Wesley, 2010. ISBN 978-0-321-60191-9.
26. SOMMERVILLE, Ian. *Software Engineering*. 10. Pearson, 2016. ISBN 978-0-13-394303-0.
27. MARIUS, Patrik. DarkFactory: autonomous, governed software engineering pipelines. Online. 2026. [Accessed 8 září 2026]. Available from: <https://github.com/marius-patrik/DarkFactory>
28. VASWANI, Ashish, SHAZEER, Noam, PARMAR, Niki, USZKOREIT, Jakob, JONES, Llion, GOMEZ, Aidan N., KAISER, Łukasz a POLOSUKHIN, Illia. Attention Is All You Need. *arXiv preprint arXiv:1706.03762*. Online. 2017. Available from: <https://arxiv.org/abs/1706.03762>
29. ANTHROPIC. Prompt Engineering overview. Online. 2026. Available from: <https://platform.claude.com/docs/en/build-with-claude/prompt-engineering/overview>
30. DAO, Tri, FU, Daniel Y., ERMON, Stefano, RUDRA, Atri a RÉ, Christopher. FlashAttention: Fast and Memory-Efficient Exact Attention with IO-Awareness. *Advances in Neural Information Processing Systems*. Online. 2022. Vol. 35, p. 16344–16359. Available from: <https://arxiv.org/abs/2205.14135>
31. AINSLIE, Joshua, LEE-THORP, James, JONG, Michiel de, ZEMLYANSKIY, Yury, LEBRÓN, Federico a SANGHAI, Sumit. GQA: Training Generalized Multi-Query Transformer Models from Multi-Head Checkpoints. *arXiv preprint arXiv:2305.13245*. Online. 2023. Available from: <https://arxiv.org/abs/2305.13245>
32. WOOLDRIDGE, Michael a JENNINGS, Nicholas R. Intelligent Agents: Theory and Practice. *The Knowledge Engineering Review*. 1995. Vol. 10, no. 2, p. 115–152.
33. WANG, Lei, MA, Chen, FENG, Xueyang, ZHANG, Zeyu, YANG, Hao, ZHANG, Jingsen, CHEN, Zhiyuan, TANG, Jiakai, CHEN, Xu, LIN, Yankai, ZHAO, Wayne Xin, WEI, Zhewei a WEN, Ji-Rong. A Survey on Large Language Model Based Autonomous Agents. *Frontiers of Computer Science*. Online. 2024. Vol. 18, no. 6, p. 186345. Available from: <https://arxiv.org/abs/2308.11432>
34. SCHICK, Timo, DWIVEDI-YU, Jane, DESSÌ, Roberto, RAILEANU, Roberta, LOMELI, Maria, ZETTLEMOYER, Luke, CANCEDDA, Nicola a SCIALOM, Thomas. Toolformer: Language Models Can Teach Themselves to Use Tools. *Advances in Neural Information Processing Systems*. Online. 2023. Vol. 36, p. 68539–68551. Available from: <https://arxiv.org/abs/2302.04761>
35. SENNRICH, Rico, HADDOW, Barry a BIRCH, Alexandra. Neural Machine Translation of Rare Words with Subword Units. *Proceedings of the 54th Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers)*. Online. 2016. P. 1715–1725. Available from: <https://aclanthology.org/P16-1162/>

36. WU, Qingyun, BANSAL, Gagan, ZHANG, Jieyu, WU, Yiran, LI, Beibin, ZHU, Erkang, JIANG, Li, ZHANG, Xiaoyun, ZHANG, Chi, LIU, Jue, AWADALLAH, Ahmed Hassan, WHITE, Ryen W., BURGER, Doug a WANG, Chi. AutoGen: Enabling Next-Gen LLM Applications via Multi-Agent Conversation. *arXiv preprint arXiv:2308.08155*. Online. 2023. Available from: <https://arxiv.org/abs/2308.08155>
37. ANTHROPIC. Building effective agents. Online. 2024. Available from: <https://www.anthropic.com/research/building-effective-agents>
38. MERKEL, Dirk. Docker: lightweight linux containers for consistent development and deployment. *Linux Journal*. 2014. Vol. 2014, no. 239, p. 2.
39. KINSMAN, Timothy, WESSEL, Mairieli, GEROSA, Marco A. a TREUDE, Christoph. How do software developers use GitHub Actions to automate their workflows?. In : *Proceedings of the 18th International Conference on Mining Software Repositories*. 2021. p. 420–431.
40. DABBISH, Laura, STUART, Colleen, TSAY, Jason a HERBSLEB, Jim. Social coding in GitHub: transparency and collaboration in an open software repository. In : *Proceedings of the ACM 2012 conference on Computer Supported Cooperative Work*. 2012. p. 1277–1286.
41. FOWLER, Martin. Vibe Coding. Online. 2026. [Accessed 20 září 2026]. Available from: <https://martinfowler.com/bliki/VibeCoding.html>
42. GONÇALVES, Pavlína Wurzel, FREGNAN, Enrico, BAUM, Tobias, SCHNEIDER, Kurt a BACCHELLI, Alberto. Do explicit review strategies improve code review performance? Towards understanding the role of cognitive load. *Empirical Software Engineering*. Online. 2022. Vol. 27, no. 4, p. 99. DOI [10.1007/s10664-022-10123-8](https://doi.org/10.1007/s10664-022-10123-8).
43. GVISOR AUTHORS. Introduction to gVisor security. Online. 2026. [Accessed 20 září 2026]. Available from: https://gvisor.dev/docs/architecture_guide/intro/
44. MARIUS, Patrik. DarkFactory. Online. 2026. [Accessed 20 září 2026]. Available from: <https://github.com/marius-patrik/DarkFactory>