



Gymnázium J. K. Tyla

Agentic AI, Agentic Engineering and Harness Engineering

ODBORNÁ PRÁCE

Autor práce: Patrik Marius, 4.D
Vedoucí práce: Michal Dočekal

Rozsah práce: 3005 slov / 20035 znaků

Prohlášení

Prohlašuji, že jsem tuto studentskou odbornou práci vypracoval/a samostatně pod dohledem vedoucího uvedeného na první straně. Všechny použité zdroje jsou uvedeny v seznamu zdrojů a informace z nich získané jsou v textu řádně označeny odkazem na zdroj. Souhlasím s tím, aby tištěná forma práce byla uchována na Gymnázium J. K. Tyla a tam používána jako tištěný zdroj např. pro další studentské práce či pro prezentaci vzdělávání na GJKT.

V Hradci Králové dne

Podpis autora práce:

.....

Anotace

Tato odborná práce se zabývá současným využitím agentní umělé inteligence při vývoji softwaru. Popisuje, jaké části vývojového procesu mohou dnešní agentní systémy provádět samostatně a jaké nástroje, pravidla a kontrolní mechanismy potřebují pro opakovatelnou práci nad skutečným repozitářem. Praktickou část tvoří návrh a implementace systému DarkFactory, který tyto principy převádí do konkrétní architektury agentního harnessu.

Abstract

This thesis examines the current use of agentic artificial intelligence in software development. It describes which parts of the development process today's agentic systems can perform independently and which tools, rules, and control mechanisms they need for repeatable work on a real repository. The practical part is the design and implementation of DarkFactory, which applies these principles in a concrete agent-harness architecture.

Keywords (Klíčová slova)

Agent Harness (Agentní harness), Agent Loop (Smyčka ReAct) [ReAct Loop], Agentic Engineering (Agentické inženýrství), CI (Průběžná integrace) [Continuous Integration], Context Engineering (Kontextové inženýrství), Guardrail (Deterministický mantinel) [Deterministic Guardrail], HITL (Zapojení člověka do smyčky) [Human-in-the-loop], LLM (Jazykový model) [Large Language Model], Prompt Engineering (Promptové inženýrství), Sandbox (Izolované běhové prostředí), Tools (Nástroje), Version Control (Správa verzí)

Obsah

Prohlášení	2
Anotace	3
Abstract	4
Keywords (Klíčová slova)	5
1 Úvod	9
1.1 Motivace a vymezení problému	9
1.2 Cíl práce a výzkumné otázky	10
1.2.1 Hlavní cíl	11
1.2.2 Dílčí cíle	11
1.2.3 Výzkumné otázky	11
1.3 Metodika práce	11
2 Teoretická část	12
2.1 Úvod	12
2.2 Software Engineering (Softwarové inženýrství)	12
2.2.1 Vibe Coding	12
2.2.2 Slop	13
2.2.3 Spec-Driven Development (Vývoj řízený specifikací)	13
2.2.4 Plánování	13
2.2.5 Version Control (Správa verzí)	13
2.2.6 GitHub	14
2.2.7 Runtime (Běhové prostředí)	14
2.2.8 CI (Průběžná integrace) [Continuous Integration]	14
2.2.9 Actions (GitHub Actions)	14
2.2.10 Container (Softwarový kontejner) [Software Container]	14
2.2.11 Integration Test (Integrační test)	14
2.3 LLM (Jazykový model) [Large Language Model]	14
2.3.1 Transformer	15
2.3.2 Tokenizér	15
2.3.3 Token	15
2.3.4 Embedding (Vektorová reprezentace)	15
2.3.5 Kontextové okno	16
2.3.6 KV Cache (Mezipaměť klíčů a hodnot) [Key-Value Cache]	16
2.3.7 Degradace kontextu	16
2.4 Harness	17

2.4.1	Turn (Tah interakce)	19
2.4.2	Session (Agentní sezení) [Agent Session]	19
2.4.3	Transcript (Přepis)	19
2.4.4	Agent Loop (Smyčka ReAct) [ReAct Loop]	19
2.4.5	Patologie divergence	20
2.4.6	Plugins (Rozšíření)	20
2.4.7	Subagent (Podřízený agent)	20
2.4.8	Tools (Nástroje)	20
	JSON Schema Tool Calling (Vyvolávání nástrojů s JSON Schema)	20
	Code Execution (Spouštění kódu)	20
	MCP (Model Context Protocol)	20
2.4.9	Skills (Dovednosti)	21
2.4.10	Scripts (Skripty)	22
2.4.11	Hooks (Událostní zachytné body)	22
2.5	Agentic Engineering (Agentické inženýrství)	22
2.5.1	Guardrail (Deterministický mantinel) [Deterministic Guardrail]	22
2.5.2	HITL (Zapojení člověka do smyčky) [Human-in-the-loop]	22
2.5.3	Sandbox (Izolované běhové prostředí)	22
2.5.4	Harness Engineering (Harnessové inženýrství)	23
2.5.5	Promptové inženýrství	23
	Systémový prompt	23
2.5.6	Loop Engineering (Inženýrství prováděcí smyčky) [Execution-loop Engineering]	23
2.5.7	Graph Engineering (Inženýrství pracovních grafů) [Workflow-graph Engineering]	23
	DAG (Orientovaný acyklický graf) [Directed Acyclic Graph]	23
2.5.8	Kontextové inženýrství	24
	Context Injection (Vkládání kontextu)	24
	Compaction (Kompakce kontextu) [Context Compaction]	24
	RAG (Generování rozšířené vyhledáváním) [Retrieval-Augmented Generation]	24
	Sémantický posun	24
3	Praktická část	25
3.1	Úvod	25
3.2	Architektura DarkFactory	25
3.3	Výsledky a diskuse	25

3.3.1	Vyhodnocení výzkumných otázek	25
3.3.2	Omezení evaluace	25
4	Závěr	26
	Seznam obrázků a tabulek	27
	Seznam příloh	28
	Seznam zdrojů	29

1 Úvod

Tato práce zkoumá, jak dnes účinně využívat agentní umělou inteligenci při vývoji softwaru.

Zaměřuje se na to, co současní agenti dokážou samostatně provést a jaké prostředí, nástroje a pravidla potřebují, aby jejich práce byla opakovatelná a kontrolovatelná.

Praktickým příkladem je DarkFactory, na kterém jsou popsány principy převedeny do konkrétní architektury a vývojového procesu. Cílem úvodu je stručně vymezit, co práce zkoumá, proč je téma aktuální a podle čeho bude navržené řešení posuzováno.

1.1 Motivace a vymezení problému

Ukázat, jaké úlohy dokážou současné agentní systémy samostatně provádět a jaká technická vrstva umožňuje převést schopnost jazykového modelu do spolehlivého jednání nad skutečným softwarovým projektem.

Generativní AI se během několika let rozšířila do masového používání a současně se rozšiřují systémy, které plánují více kroků, pracují se soubory a nástroji, spouštějí příkazy a testy a vykonávají delší úlohy.

V softwarovém inženýrství tento posun reprezentují například Codex a Claude Code, které pracují nad repozitáři, upravují soubory a spouštějí testy. ^(1, 2)

CPA.RIP dne 14. září 2026 publikoval odhad Gradually AI, podle kterého generativní AI používá přibližně 2,4 miliardy lidí, tedy 29 % světové populace. Výpočet vychází z dat DataReportal pro duben 2026 a článek výslovně uvádí, že všechny globální hodnoty jsou přibližné. ⁽³⁾

How many people use AI? The world population as a dot grid

Each dot represents roughly 3.3 million people

2,500 dots = 8.3 billion people. Color = most advanced AI usage. Own estimate, as of August 2026.



Sources: DataReportal, OpenAI, ITU et al.

gradually.ai

Obrázek 1: Odhad používání AI ve světové populaci. Zdroj: CPA.RIP / Gradually AI ⁽³⁾.

1.2 Cíl práce a výzkumné otázky

Tato část stanovuje hlavní cíl, dílčí cíle a výzkumné otázky práce. Společně vymezují rozsah návrhu DarkFactory a rámec jeho evaluace.

1.2.1 Hlavní cíl

Zjistit, jak lze současnou agentní AI účinně používat při vývoji softwaru, a navrhnout architekturu agent harnessu, která podporuje vysokou míru autonomie při zachování lidského dohledu v důležitých rozhodnutích.

DarkFactory slouží jako konkrétní návrh této architektury.

1.2.2 Dílčí cíle

- Vymezit infrastrukturu pro správu verzí a průběžné automatické ověřování změn.
- Popsat limity modelového kontextu, jeho správu a mechanismy pro dlouhotrvající agentní úlohy.
- Popsat nástrojové a prováděcí mechanismy současného agentního harnessu.
- Navrhnout způsob, jak zachovat lidský dohled nad důležitými rozhodnutími bez nutnosti ručně provádět každou rutinní změnu.

Dílčí cíle pokrývají vývojové prostředí, kontext, provádění a lidský dohled.

1.2.3 Výzkumné otázky

- O1: Jak lze současný agentní systém zapojit do vývoje softwaru tak, aby samostatně prováděl co největší část běžné práce a člověk se soustředil na zadání, kontrolu a důležitá rozhodnutí?
- O2: Jaké mechanismy harnessu pomáhají rozpoznat a zastavit neproduktivní opakování, oscilaci nebo zacyklení během delší úlohy?
- O3: Jak spravovat pracovní kontext agenta tak, aby při delších úlohách neztrácel důležité požadavky a stav projektu?

O1–O3 pokrývají autonomii, stabilitu prováděcí smyčky a správu pracovního kontextu.

1.3 Metodika práce

Práce porovnává veřejně popsané principy současných agentních systémů, rozděluje je do samostatných konceptů a používá je při návrhu DarkFactory.

Předmětem práce není trénování neuronových sítí, optimalizace vah ani podrobná matematika modelového učení. *LLM (Jazykový model) [Large Language Model]* je chápán jako hotová inferenční komponenta a je popsán pouze v rozsahu potřebném pro další části práce.

Architektura kolem modelu je rozložena do samostatných konceptů, aby měl každý mechanismus vlastní definici, popis a nebylo nutné stejné vysvětlení opakovat v několika kapitolách.

Navržené principy jsou následně promítnuty do DarkFactory.

2 Teoretická část

Vymezení konceptů potřebných pro pochopení současného agentního vývoje softwaru. Postupuje od softwarového inženýrství přes jazykový model a harness k agentickému inženýrství.

2.1 Úvod

Vymezení hranic teoretické části a vztahů mezi jejími hlavními vrstvami. Jazykový model je v práci chápán jako hotová inferenční komponenta. Teoretická část postupuje přes Software Engineering, LLM a Harness k Agentic Engineering, pod které spadá také Harness Engineering.

2.2 Software Engineering (Softwarové inženýrství)

Systematické uplatňování inženýrských principů na specifikaci, návrh, implementaci, ověřování, provoz a údržbu softwarových systémů. V agentním vývoji zasazuje generování kódu do řízeného procesu požadavků, změn, automatického ověřování a revize.

2.2.1 Vibe Coding

Způsob tvorby softwaru, při kterém člověk zadává požadované chování přirozeným jazykem a iteruje nad výsledkem bez průběžné kontroly vygenerovaného kódu. Termín zavedl Andrej Karpathy v roce 2025. Přístup urychluje experimentování, ale u udržovaného softwaru nenahrazuje kontrolu požadavků, testů a výsledného chování. ^(4,5) Tweet Andreje Karpathyho z 2. února 2025, ve kterém popsal původní význam Vibe Coding.



Andrej Karpathy ✓
@karpathy



There's a new kind of coding I call "vibe coding", where you fully give in to the vibes, embrace exponentials, and forget that the code even exists. It's possible because the LLMs (e.g. Cursor Composer w Sonnet) are getting too good. Also I just talk to Composer with SuperWhisper so I barely even touch the keyboard. I ask for the dumbest things like "decrease the padding on the sidebar by half" because I'm too lazy to find it. I "Accept All" always, I don't read the diffs anymore. When I get error messages I just copy paste them in with no comment, usually that fixes it. The code grows beyond my usual comprehension, I'd have to really read through it for a while. Sometimes the LLMs can't fix a bug so I just work around it or ask for random changes until it goes away. It's not too bad for throwaway weekend projects, but still quite amusing. I'm building a project or webapp, but it's not really coding - I just see stuff, say stuff, run stuff, and copy paste stuff, and it mostly works.

3:17 PM · Feb 2, 2025 · 6.8M Views

Obrázek 2: Původní tweet Andreje Karpathyho o Vibe Coding. ^(4,6)

2.2.2 Slop

Neformální označení pro velmi nekvalitní digitální obsah, zejména obsah vytvořený umělou inteligencí.

V softwaru se projevuje jako rychle vytvořený, ale zbytečně složitý, duplicitní nebo neověřený výstup; kvalitu proto musí určovat skutečné chování, testy a udržitelnost. ⁽⁷⁾

2.2.3 Spec-Driven Development (Vývoj řízený specifikací)

Přístup k AI-asistovanému vývoji softwaru, při němž se před implementací vytvoří explicitní specifikace a ta slouží jako zdroj pravdy pro člověka i agenta. Specifikace odděluje požadované chování a omezení od konkrétní implementace a používá se při plánování, generování a ověřování změn. ⁽⁸⁾

2.2.4 Plánování

Proces převodu požadavku na explicitní posloupnost kroků, závislostí a ověřovacích podmínek před prováděním změn.

V agentním vývoji plán před změnami určuje kontrolovatelné kroky a podmínky, podle nichž se ověří splnění zadání.

2.2.5 Version Control (Správa verzí)

Sledování historie změn v repozitáři tak, aby bylo možné změny porovnávat, oddělovat a bezpečně slučovat.

DarkFactory používá Git a GitHub k oddělení pracovního stavu agenta od hlavní historie projektu a k dohledání provedených změn. ⁽⁹⁾

2.2.6 GitHub

Cloudová platforma pro hosting gitových repozitářů a koordinaci vývojového cyklu pomocí Issues, Pull Requests a automatizačních workflow. Nad historií spravovanou Gitem přidává GitHub zadání práce, revizi změn a automatizační workflow.

2.2.7 Runtime (Běhové prostředí)

Prostředí, ve kterém se program nebo agent vykonává a využívá procesy, souborový systém, síť a další systémové prostředky. Runtime určuje skutečné nástroje, soubory a oprávnění dostupné agentovi a může být omezen kontejnerem nebo sandboxem.

2.2.8 CI (Průběžná integrace) [Continuous Integration]

Vývojová praxe, při níž se změny často integrují a automaticky ověřují sestavením, testy a dalšími kontrolami. Kód vytvořený jazykovým modelem nelze považovat za ověřený pouze proto, že byl vygenerován. CI poskytuje opakovatelnou kontrolu sestavení, testů a dalších strojově vyhodnotitelných podmínek. ⁽¹⁰⁾

2.2.9 Actions (GitHub Actions)

Automatizační platforma GitHubu pro spouštění deklarovaných workflow a jejich jobů v reakci na události repozitáře nebo ruční spuštění. V DarkFactory GitHub Actions spouští CI kontroly a další automatizované procesy repozitáře.

2.2.10 Container (Softwarový kontejner) [Software Container]

Izolované uživatelské běhové prostředí, které balí aplikaci a její závislosti při sdílení jádra hostitelského operačního systému. V CI poskytuje kontejner opakovatelné prostředí s deklarovanými nástroji a závislostmi, ale sám o sobě nezaručuje úplnou bezpečnostní izolaci.

2.2.11 Integration Test (Integrační test)

Ověření spolupráce více komponent nebo vrstev systému přes jejich skutečná rozhraní. V agentním vývoji ověřuje, že změna funguje nejen izolovaně, ale také v toku mezi částmi aplikace, službami, úložišti nebo automatizačními kroky. ⁽¹¹⁾

2.3 LLM (Jazykový model) [Large Language Model]

Neuronový model pro zpracování a generování posloupností tokenů; současné modely tohoto typu typicky používají *Transformer*.

Model při generování odhaduje další token z aktivního kontextu. Práci se soubory, příkazy, nástroji a stavem poskytuje až okolní aplikační nebo agentní vrstva.

2.3.1 Transformer

Architektura neuronových sítí založená na mechanismu pozornosti, která modeluje vztahy mezi prvky sekvence a tvoří základ většiny současných velkých jazykových modelů.

2.3.2 Tokenizér

Komponenta, která převádí text nebo jiný podporovaný vstup na posloupnost tokenů a jejich identifikátorů a provádí odpovídající zpětné dekodování.

Konkrétní tokenizér určuje slovník i pravidla rozdělení vstupu, často pomocí subword metod, jako je Byte Pair Encoding. Stejný text proto může mít u různých modelových rodin odlišný počet tokenů a jinou segmentaci.

2.3.3 Token


Diskrétní jednotka zpracovávaná jazykovým modelem, odpovídající položce slovníku tokenizéru a reprezentovaná číselným identifikátorem.

Token nemusí odpovídat celému slovu; podle použitého tokenizéru může představovat slovo, část slova, znakový fragment nebo jinou jednotku. Po tokenizaci jsou identifikátory převedeny na vektorové reprezentace, se kterými pracují vrstvy modelu.

2.3.4 Embedding (Vektorová reprezentace)

Vícerozměrná vektorová reprezentace tokenů nebo jiných dat, v níž numerické vztahy mezi vektory zachycují užitečné vztahy mezi reprezentovanými objekty.

V jazykovém modelu embedding převádí diskrétní identifikátory tokenů na spojitě vektory zpracovatelné neuronovou sítí. Podobné reprezentace lze použít také pro sémantické vyhledávání nebo porovnávání podobnosti. ⁽¹²⁾



Obrázek 3: Ilustrativní 2D projekce vztahu $\text{král} - \text{muž} + \text{žena} \approx \text{královna}$; osy Pohlaví a Královský status slouží pouze k názornému vysvětlení a nepředstavují doslovné naučené dimenze embeddingového prostoru.

2.3.5 Kontextové okno

Maximální rozsah tokenové sekvence, kterou model při jednom inferenčním běhu dokáže zahrnout do aktivního kontextu. Do tohoto limitu se společně započítávají systémové instrukce, uživatelský vstup, historie běhu, výsledky nástrojů a další data předaná modelu. Omezení proto přímo ovlivňuje, kolik pracovního stavu může agent udržovat současně bez výběru, externí paměti nebo kompakce.

2.3.6 KV Cache (Mezipaměť klíčů a hodnot) [Key-Value Cache]

Mezipaměť dříve vypočtených vektorů klíčů a hodnot v pozornostních vrstvách transformeru, která při autoregresivním generování omezuje opakovaný výpočet předchozích tokenů.

Při každém novém tokenu lze znovu použít klíče a hodnoty vytvořené pro předchozí část sekvence namísto jejich úplného přepočítání. Mezipaměť tím snižuje výpočetní režii generování, ale její velikost roste s délkou aktivní sekvence a představuje významnou část paměťových nároků inference.

2.3.7 Degradace kontextu

Pokles schopnosti modelu spolehlivě využívat informace v dlouhém nebo zahlceném kontextu.

Nominální délka kontextového okna nezaručuje rovnoměrné využití všech informací; výkon může klesat zejména u relevantních údajů umístěných uvnitř dlouhého vstupu. ⁽¹³⁾

2.4 Harness


Aplikační a orchestrační vrstva, která propojuje model s prostředím a řídí jeho opakované jednání nad stavem a nástroji.

Harness spravuje pracovní kontext, nástroje, stav úlohy, výsledky akcí a podmínky pokračování nebo ukončení běhu; provádění koordinuje *Agent Loop (Smyčka ReAct) [ReAct Loop]*.

Codex. Agentní vývojový systém OpenAI určený pro samostatné plnění softwarově-inženýrských úloh.

Desktopová aplikace umožňuje řídit více agentů paralelně, oddělovat jejich práci do vláken a worktree, kontrolovat diffy a delegovat dlouhotrvající úlohy.

Rozhraní pro práci s agentními úlohami a dovednostmi.




Obrázek 4: Aplikace Codex. Zdroj: OpenAI.

(1, 1)

Claude Code. Agentní vývojové prostředí společnosti Anthropic dostupné v terminálu, IDE, na webu a v desktopové aplikaci.

Claude Code může plánovat změny, upravovat soubory, spouštět příkazy a testy, používat Git a MCP a vytvářet pull requesty.

Čtení souboru, zápis změny a průběžný stav agentní úlohy.




Obrázek 5: Claude Code při práci se souborem. Zdroj: Anthropic.

(2, 2)

Claude Desktop (Aplikace Claude pro desktop) [Claude Desktop App]. Desktopová aplikační vrstva nad modely Claude, která propojuje konverzaci s lokálními soubory, aplikacemi, webem a dalšími schopnostmi.

Se souhlasem uživatele může aplikace číst, upravovat a ukládat soubory a pracovat s dalšími aplikacemi.

Konverzace s pracovním artefaktem a samostatným pracovním povrchem.



Obrázek 6: Aplikační rozhraní Claude. Zdroj: Anthropic.

2.4.1 Turn (Tah interakce)

Jedna diskrétní jednotka interakce v konverzačním nebo agentním protokolu, například zpráva uživatele, výstup modelu nebo samostatně evidovaný výsledek nástroje. Historie tahů tvoří část pracovního kontextu; harness rozhoduje, které vstupy, modelová rozhodnutí a výsledky nástrojů zůstanou dostupné v dalších iteracích.

2.4.2 Session (Agentní sezení) [Agent Session]


Ohraničený běh se sdíleným stavem, systémovými instrukcemi, pracovním kontextem, historií tahů a provozními rozpočty. Harness v rámci session spravuje pracovní kontext a sleduje rozpočty, například spotřebu tokenů nebo počet iterací.

2.4.3 Transcript (Přepis)

Uspořádaný záznam zpráv, tahů, volání nástrojů, jejich výsledků a dalších událostí vzniklých během agentního sezení. Slouží k rekonstrukci průběhu sezení, auditu a výběru informací, které se mají znovu vložit do aktivního kontextu.

2.4.4 Agent Loop (Smyčka ReAct) [ReAct Loop]

Iterativní cyklus, v němž model vyhodnotí stav, zvolí akci, harness ji provede a výsledek vrátí do další iterace. Ve vzoru ReAct se cyklus opakuje jako rozhodnutí – volání nástroje – pozorování výsledku – další rozhodnutí. Harness zajišťuje provedení nástroje a vrácení pozorování do aktivního kontextu. ⁽¹⁵⁾



Obrázek 7: Smyčka ReAct: model rozhodne o akci, harness ji provede a výsledek vrátí modelu.

2.4.5 Patologie divergence

Selhání agentní smyčky, při němž se běh vzdaluje cíli opakováním neúčinných kroků, oscilací nebo nekontrolovanou spotřebou zdrojů.

Typickými projevy jsou opakování stejné neúspěšné akce, střídání protichůdných změn a pokračování běhu bez měřitelného pokroku. Harness je proto musí rozpoznat pomocí pozorovaného stavu, limitů a podmínek ukončení. ⁽¹⁶⁾

2.4.6 Plugins (Rozšíření)

Programové rozšíření běžící přímo v prostředí harnessu, které může doplnit exekuční jádro o systémové adaptéry, ovladače nástrojů nebo deterministické zachytné body. Na rozdíl od instrukční dovednosti mění plugin programové chování běhové vrstvy harnessu. ⁽¹⁷⁾

2.4.7 Subagent (Podřízený agent)

Dočasná nebo specializovaná agentní instance, které nadřazený orchestrátor deleguje vymezenou dílčí úlohu a následně převezme její výsledek.

Subagent izoluje dílčí práci, například průzkum, plánování nebo implementaci, a může nadřazenému orchestrátoru vrátit pouze výsledek místo celé pracovní historie.

2.4.8 Tools (Nástroje)

Rozhraní zpřístupňující modelu operace mimo samotnou textovou inferenci, například čtení souboru, dotaz na API nebo změnu stavu systému.

Harness přijme požadavek modelu, zkontroluje parametry, provede příslušnou operaci a vrátí její výsledek do dalšího kroku běhu.

JSON Schema Tool Calling (Vývolávání nástrojů s JSON Schema)

Formální popis parametrů nástroje pomocí JSON Schema s ověřením, že vygenerované argumenty před provedením odpovídají očekávané struktuře.

Schéma určuje povinná pole, datové typy a další omezení vstupu; rozhraní modelu může zároveň omezit generování argumentů tak, aby schématu odpovídaly. ^(18,19)

Code Execution (Spouštění kódu)

Nástrojová schopnost, která umožňuje vykonat program nebo příkaz a získat jeho skutečný výstup.

Při vývoji softwaru umožňuje spouštět testy, buildy, formátovače a diagnostické příkazy v řízeném prostředí místo odhadování jejich výsledku modelem. ⁽²⁰⁾

MCP (Model Context Protocol)

Otevřený protokol pro standardizované propojení AI aplikací s externími nástroji, zdroji a daty.

MCP používá klient-server rozhraní nad JSON-RPC, takže nástroje a datové zdroje mohou být implementovány mimo jádro harnessu a znovu používány různými aplikacemi. ⁽²¹⁾

2.4.9 Skills (Dovednosti)

Znovupoužitelný balíček instrukcí a volitelných zdrojů načítaný pro úlohy, ke kterým je relevantní.

Formát Agent Skills používá soubor SKILL.md s metadaty a instrukcemi a může doplnit skripty, reference nebo další zdroje. ⁽²²⁾

SKILL.md (Formát SKILL.md) [SKILL.md Format]. Povinný definiční soubor Agent Skill.

Podle specifikace obsahuje YAML frontmatter následovaný instrukcemi v Markdownu; povinnými poli frontmatteru jsou `name` a `description`. ⁽²²⁾

Následující úplný příklad používá povinná pole i několik volitelných polí povolených specifikací: ⁽²²⁾

```
---
name: repository-tests
description: Run, diagnose, and summarize the repository test suite. Use
when a software change must be validated before completion.
license: MIT
compatibility: Requires the repository's test runner to be available in
the runtime.
metadata:
  author: DarkFactory
  version: "1.0"
allowed-tools: Bash Read
---
```

Repository tests

Use this skill when a change must be validated against the repository's tests.

Procedure

1. Detect the test command documented by the repository.
2. Run the smallest relevant test scope first.
3. Fix or report failures before continuing.
4. Run the complete required suite before completion.
5. Report the commands run and the final result.

Failure reporting

For every unresolved failure, include the command, failing target, and relevant output.

Specifikace dovoluje vedle `SKILL.md` také volitelné adresáře například pro skripty, reference a assety; ty se načítají pouze podle potřeby. ⁽²²⁾

2.4.10 Scripts (Skripty)

Soubory nebo posloupnosti příkazů určené k automatizovanému vykonání interpretem, shellem nebo jiným běhovým prostředím.

V harnessu se používají pro opakovatelné transformace, validace a další kroky, které nemají vyžadovat nové rozhodnutí modelu.

2.4.11 Hooks (Událostní záchytné body)

Definované body životního cyklu nebo události, na které lze navázat vlastní deterministickou logiku před, po nebo místo standardního chování systému.

Používají se například před spuštěním nástroje, po dokončení kroku nebo při změně stavu běhu.

2.5 Agentic Engineering (Agentické inženýrství)

Návrh a provoz systémů kolem jazykových modelů, které zajišťují nástroje, kontext, stav, provádění, mantinely a lidský dohled.

Jeho předmětem je systém, který převádí modelový výstup na řízené a ověřitelné jednání, nikoli architektura nebo trénování samotného modelu.

2.5.1 Guardrail (Deterministický mantinel) [Deterministic Guardrail]

Programově vynucené omezení nebo kontrola, která neponechává kritické provozní pravidlo pouze na pravděpodobnostním rozhodnutí modelu.

Pokud samotná instrukce v promptu neposkytuje dostatečnou záruku, harness může pravidlo vynutit deterministicky, například omezením přístupových práv, validací parametrů nástroje nebo odmítnutím nepovoleného stavového přechodu. Kritická bezpečnostní a procesní pravidla patří do deterministicky vynucované vrstvy harnessu, nikoli pouze do textových instrukcí modelu.

2.5.2 HITL (Zapojení člověka do smyčky) [Human-in-the-loop]

Návrhový vzor, v němž člověk schvaluje nebo přebírá rozhodnutí v určených bodech automatizovaného procesu.

V DarkFactory zůstávají člověku zejména významná nebo nevratná rozhodnutí, zatímco rutinní kroky může harness provádět samostatně. Ke kontrole má předkládat pozorovatelný stav, například diff, výsledky kontrol a chyby. ⁽²³⁾

2.5.3 Sandbox (Izolované běhové prostředí)

Omezené běhové prostředí, které odděluje prováděný kód a jeho oprávnění od hostitelského systému.

Harness v sandboxu omezuje přístup k souborům, síti, tajnostem a dalším systémovým prostředkům. Silnější izolaci nedůvěryhodného kódu mohou poskytovat virtualizované hranice, například microVM. ⁽²⁴⁾

2.5.4 Harness Engineering (Harnessové inženýrství)

Návrh, implementace a provoz harnessu, který propojuje jazykový model s nástroji, stavem, kontextem a kontrolními mechanismy. Zaměřuje se na strukturu běhové vrstvy, její rozhraní a deterministické mechanismy, které převádějí modelový výstup na řízené a ověřitelné jednání.

2.5.5 Promptové inženýrství

Systematický návrh instrukcí a kontextu určujících požadované chování jazykového modelu nebo agenta. Prompt může řídit postup a používání nástrojů, ale nevynucuje bezpečnostní nebo procesní pravidla; ta zajišťuje **Guardrail (Deterministický mantinel) [Deterministic Guardrail]**.

Systémový prompt

Instrukční vrstva s vysokou prioritou, která vymezuje roli a základní pravidla chování modelu nebo agenta. V harnessu tvoří stabilní instrukční základ pro práci s kontextem a nástroji, nikoli technickou bezpečnostní hranici.

2.5.6 Loop Engineering (Inženýrství prováděcí smyčky) [Execution-loop Engineering]

Návrh a řízení stavových přechodů, podmínek ukončení, rozpočtů, opakování, eskalací a vazby mezi rozhodováním modelu a nástroji. Harness tak může nezávisle na modelu omezit počet iterací, ukončit neproduktivní běh, opakovat selhaný krok nebo vyžádat lidské schválení.

2.5.7 Graph Engineering (Inženýrství pracovních grafů) [Workflow-graph Engineering]

Návrh agentních nebo automatizačních workflow jako explicitních grafů uzlů, závislostí a přechodů namísto jediné neomezené smyčky. Graf umožňuje explicitně řídit pořadí, paralelizaci a kontrolní body vícefázové úlohy. Dílčí práci lze delegovat pomocí **Subagent (Podřízený agent)** a její závislosti vyjádřit pomocí **DAG (Orientovaný acyklický graf) [Directed Acyclic Graph]**.

DAG (Orientovaný acyklický graf) [Directed Acyclic Graph]

Orientovaný graf bez orientovaného cyklu, který umožňuje explicitně vyjádřit závislosti a pořadí kroků pracovního postupu. V agentním workflow reprezentuje DAG kroky jako uzly a jejich závislosti jako hrany, takže navazující krok může začít až po splnění svých předpokladů.

2.5.8 Kontextové inženýrství

Systematický výběr, pořadí a životní cyklus informací zpřístupňovaných modelu v aktivním kontextu.

Určuje, které instrukce, pracovní stav, výsledky nástrojů a externí data model právě vidí a jak se tento obsah mění při omezené kapacitě kontextového okna.

Context Injection (Vkládání kontextu)

Cílené vložení informací do aktivního kontextu modelu v okamžiku, kdy jsou potřebné pro aktuální krok úlohy.

Harness může tímto způsobem doplnit instrukce, stav projektu, výsledky nástrojů nebo externě načtená data bez jejich trvalého držení v celém průběhu sezení.

Compaction (Kompakce kontextu) [Context Compaction]

Zmenšení aktivního kontextu výběrem, shrnutím nebo nahrazením starší historie kompaktnější reprezentací.

Kompakce uvolňuje místo v kontextovém okně za cenu možné ztráty přesných detailů; důležité požadavky a stav proto nemají existovat pouze v rekurzivně shrnované historii.⁽²⁵⁾

RAG (Generování rozšířené vyhledávání) [Retrieval-Augmented Generation]

Architektura, v níž systém vyhledá relevantní informace z externího zdroje a vloží je do kontextu modelu.

RAG umožňuje načítat potřebné informace podle aktuální úlohy místo jejich trvalého držení v aktivním kontextu.⁽²⁶⁾

Sémantický posun

Postupné zkreslování významu nebo faktického stavu při opakovaném ztrátovém shrnování či transformaci kontextu.

Každá další komprese může převzít nepřesnost z předchozí verze jako fakt, až se pracovní reprezentace agenta rozejde se skutečným stavem systému.

3 Praktická část

Aplikace teoretických principů na konkrétní systém DarkFactory. Praktická část popisuje ověřenou architekturu DarkFactory a hodnotí doložitelné vlastnosti výsledného řešení.

3.1 Úvod

Vymezení způsobu, jakým praktická část aplikuje teoretické mechanismy na systém DarkFactory.

Praktická část popisuje pouze ověřenou implementaci DarkFactory a následně hodnotí chování a důkazy, které lze skutečně doložit.

3.2 Architektura DarkFactory

Konkrétní uspořádání komponent agentního harnessu do jednoho vývojového systému. Spojuje modelovou, stavovou, nástrojovou a kontrolní vrstvu do řízeného toku provádění softwarových úloh.

3.3 Výsledky a diskuse

Vyhodnocení, jak návrh DarkFactory odpovídá stanoveným cílům a výzkumným otázkám.

Výsledky odpovídají na O1–O3 a odděleně vymezují hranice toho, co lze z provedeného ověření tvrdit.

3.3.1 Vyhodnocení výzkumných otázek

Posouzení, jak navržená architektura DarkFactory odpovídá na stanovené otázky.

O1 — autonomie při zachování lidského dohledu: harness odděluje zadání, provádění, automatické kontroly a lidská rozhodnutí tak, aby rutinní kroky mohl vykonávat agent a člověk zůstal u významných rozhodnutí.

O2 — rozpoznání neproduktivního běhu: návrh používá explicitní stav, limity běhu, deterministické kontroly a eskalaci k člověku namísto neomezeného pokračování modelové smyčky.

O3 — zachování kontextu: trvalý stav úlohy je oddělen od omezeného kontextového okna modelu a potřebné informace lze průběžně komprimovat a znovu načítat.

3.3.2 Omezení evaluace

Vymezení tvrzení, která nelze z architektonického a implementačního ověření spolehlivě odvodit.

Práce nepředstavuje statistický benchmark úspěšnosti agentů, ceny, latence ani četnosti zacyklení na reprezentativním souboru úloh. Taková tvrzení vyžadují samostatný kontrolovaný experiment.

Výsledky proto hodnotí návrh a jeho technické ověření, nikoli obecnou výkonnostní převahu DarkFactory nad jinými agentními systémy.

4 Závěr

Práce zkoumala, jak lze současnou agentní AI účinně zapojit do vývoje softwaru a jakou architekturu musí mít agent harness, aby spojoval autonomii s kontrolovatelným prováděním.

K O1 architektura přesouvá rutinní kroky na agentní systém a ponechává člověku zadání, kontrolu a důležitá rozhodnutí. K O2 používá explicitní stav, limity, kontrolní uzly a eskalaci namísto neomezené smyčky. K O3 odděluje trvalý stav úlohy od omezeného pracovního kontextu modelu.

DarkFactory tyto principy spojuje v konkrétní architektuře agentního harnessu.

Seznam obrázků a tabulek

Obrázek 1	Odhad používání AI ve světové populaci. Zdroj: CPA.RIP / Gradually AI ⁽³⁾	10
Obrázek 2	Původní tweet Andreje Karpathyho o Vibe Coding. ^(4,6)	13
Obrázek 3	Ilustrativní 2D projekce vztahu král – muž + žena $\approx$ královna; osy Pohlaví a Královský status slouží pouze k názornému vysvětlení a nepředstavují doslov- né naučené dimenze embeddingového prostoru.	16
Obrázek 4	Aplikace Codex. Zdroj: OpenAI.	17
Obrázek 5	Claude Code při práci se souborem. Zdroj: Anthropic.	18
Obrázek 6	Aplikační rozhraní Claude. Zdroj: Anthropic.	18
Obrázek 7	Smyčka ReAct: model rozhodne o akci, harness ji provede a výsledek vrátí mo- delu.	19

Seznam příloh

Seznam zdrojů

1. OPENAI. Introducing the Codex app. Online. 2026. [Accessed 20 září 2026]. Available from: <https://openai.com/index/introducing-the-codex-app/>
2. ANTHROPIC. Claude Code. Online. 2026. [Accessed 20 září 2026]. Available from: <https://claude.com/product/claude-code>
3. CPA.RIP. How Many People Worldwide Use Generative AI. Online. 2026. [Accessed 21 září 2026]. Available from: <https://cpa.rip/en/news/ai-usage-worldwide/>
4. KARPATY, Andrej. A new kind of coding I call vibe coding. Online. 2025. [Accessed 20 září 2026]. Available from: <https://twitter.com/karpathy/status/1886192184808149383>
5. WILLISON, Simon. A quote from Andrej Karpathy. Online. 2025. [Accessed 20 září 2026]. Available from: <https://simonwillison.net/2025/Feb/6/andrej-karpathy/>
6. KRAVETS, David. A semantic history: How the term 'vibe coding' went from a tweet to prod. Online. 2026. [Accessed 21 září 2026]. Available from: <https://www.coderabbit.ai/blog/a-semantic-history-how-the-term-vibe-coding-went-from-a-tweet-to-prod>
7. CAMBRIDGE UNIVERSITY PRESS. AI slop. Online. 2026. [Accessed 20 září 2026]. Available from: <https://dictionary.cambridge.org/dictionary/english/ai-slop>
8. BÖCKELER, Birgitta. Understanding Spec-Driven-Development: Kiro, spec-kit, and Tessel. Online. 2025. [Accessed 21 září 2026]. Available from: <https://martinfowler.com/articles/exploring-gen-ai/sdd-3-tools.html>
9. CHACON, Scott a STRAUB, Ben. *Pro Git*. 2. New York : Apress, 2014. ISBN 978-1-4842-0076-6.
10. HUMBLE, Jez a FARLEY, David. *Continuous Delivery: Reliable Software Releases through Build, Test, and Deployment Automation*. Boston : Addison-Wesley, 2010. ISBN 978-0-321-60191-9.
11. SOMMERVILLE, Ian. *Software Engineering*. 10. Pearson, 2016. ISBN 978-0-13-394303-0.
12. MIKOLOV, Tomas, CHEN, Kai, CORRADO, Greg a DEAN, Jeffrey. Efficient Estimation of Word Representations in Vector Space. *arXiv preprint arXiv:1301.3781*. Online. 2013. Available from: <https://arxiv.org/abs/1301.3781>
13. LIU, Nelson F., LIN, Kevin, HEWITT, John, PARANJAPE, Ashwin, BEVILACQUA, Michele, PETRONI, Fabio a LIANG, Percy. Lost in the Middle: How Language Models Use Long Contexts. *Transactions of the Association for Computational Linguistics*. Online. 2024. Vol. 12, p. 157–173. Available from: <https://arxiv.org/abs/2307.03172>
14. ANTHROPIC. Navigating the Claude desktop app. Online. 2026. [Accessed 20 září 2026]. Available from: <https://academy.claude.com/tutorials/navigating-the-claude-desktop-app>
15. YAO, Shunyu, ZHAO, Jeffrey, YU, Dian, DU, Nan, SHAFRAN, Izhak, NARASIMHAN, Karthik a CAO, Yuan. ReAct: Synergizing Reasoning and Acting in Language Models.

- arXiv preprint arXiv:2210.03629*. Online. 2022. Available from: <https://arxiv.org/abs/2210.03629>
16. SHINN, Noah, CASSANO, Federico, GOPINATH, Ashwin, NARASIMHAN, Karthik a YAO, Shunyu. Reflexion: Language Agents with Verbal Reinforcement Learning. *Advances in Neural Information Processing Systems*. Online. 2023. Vol. 36, p. 8634–8652. Available from: <https://arxiv.org/abs/2303.11366>
 17. SHI, Yifan, ZHANG, Wei a CUI, Tianyi. A Programming Paradigm for Spatiotemporal Composability. *arXiv preprint arXiv:2608.25512*. Online. 2026. Available from: <https://arxiv.org/abs/2608.25512>
 18. WRIGHT, Austin, ANDREWS, Henry, HUTTON, Ben a DENNIS, Greg. JSON Schema Draft 2020-12. Online. 2022. [Accessed 20 září 2026]. Available from: <https://json-schema.org/draft/2020-12>
 19. OPENAI. Introducing Structured Outputs in the API. Online. 2024. [Accessed 20 září 2026]. Available from: <https://openai.com/index/introducing-structured-outputs-in-the-api/>
 20. ANTHROPIC. Code execution tool. Online. 2026. [Accessed 20 září 2026]. Available from: <https://platform.claude.com/docs/en/agents-and-tools/tool-use/code-execution-tool>
 21. ANTHROPIC. Model Context Protocol documentation. Online. 2026. Available from: <https://modelcontextprotocol.io/docs/2026-07-28/getting-started/intro#explore-mcp>
 22. AGENT SKILLS. Agent Skills Specification. Online. 2026. [Accessed 20 září 2026]. Available from: <https://agentskills.io/specification>
 23. MOSQUEIRA-REY, Eduardo, HERNÁNDEZ-PEREIRA, Elena, ALONSO-RÍOS, David, BOBES-BASCARÁN, José a FERNÁNDEZ-LEAL, Ángel. Human-in-the-loop machine learning: a state of the art. *Artificial Intelligence Review*. Online. 2023. Vol. 56, no. 4, p. 3005–3054. Available from: <https://doi.org/10.1007/s10462-022-10246-w>
 24. AGACHE, Alexandru, DEACONESCU, Razvan, IORDACHE, Mihai, LUPU, Alexandra, RADU, Vlad, BUGA, Cezar, BALAN, Catalin a FLORESCU, Andreea. Firecracker: Lightweight Virtualization for Serverless Applications. In : *17th USENIX Symposium on Networked Systems Design and Implementation (NSDI 20)*. Online. 2020. p. 419–434. Available from: <https://www.usenix.org/conference/nsdi20/presentation/agache>
 25. JIANG, Huiqiang, WU, Qianhui, LIN, Chin-Yew, YANG, Yuqing a QIU, Lili. LLMingua: Compressing Context for Accelerated Inference of Large Language Models. *arXiv preprint arXiv:2310.05736*. Online. 2023. Available from: <https://arxiv.org/abs/2310.05736>
 26. LEWIS, Patrick, PEREZ, Ethan, PIKTUS, Aleksandra, PETRONI, Fabio, KARPUKHIN, Vladimir, GOYAL, Naman, KÜTTLER, Heinrich, LEWIS, Mike, YIH, Wen-tau, ROCKTÄSCHEL, Tim, RIEDEL, Sebastian a KIELA, Douwe. Retrieval-Augmented Generation for

- Knowledge-Intensive NLP Tasks. *Advances in Neural Information Processing Systems*. Online. 2020. Vol. 33, p. 9459–9474. Available from: <https://arxiv.org/abs/2005.11401>
27. MARIUS, Patrik. DarkFactory: autonomous, governed software engineering pipelines. Online. 2026. [Accessed 8 září 2026]. Available from: <https://github.com/marius-patrik/DarkFactory>
 28. VASWANI, Ashish, SHAZEER, Noam, PARMAR, Niki, USZKOREIT, Jakob, JONES, Llion, GOMEZ, Aidan N., KAISER, Łukasz a POLOSUKHIN, Illia. Attention Is All You Need. *arXiv preprint arXiv:1706.03762*. Online. 2017. Available from: <https://arxiv.org/abs/1706.03762>
 29. ANTHROPIC. Prompt Engineering overview. Online. 2026. Available from: <https://platform.claude.com/docs/en/build-with-claude/prompt-engineering/overview>
 30. DAO, Tri, FU, Daniel Y., ERMON, Stefano, RUDRA, Atri a RÉ, Christopher. FlashAttention: Fast and Memory-Efficient Exact Attention with IO-Awareness. *Advances in Neural Information Processing Systems*. Online. 2022. Vol. 35, p. 16344–16359. Available from: <https://arxiv.org/abs/2205.14135>
 31. AINSLIE, Joshua, LEE-THORP, James, JONG, Michiel de, ZEMLYANSKIY, Yury, LEBRÓN, Federico a SANGHAI, Sumit. GQA: Training Generalized Multi-Query Transformer Models from Multi-Head Checkpoints. *arXiv preprint arXiv:2305.13245*. Online. 2023. Available from: <https://arxiv.org/abs/2305.13245>
 32. WOOLDRIDGE, Michael a JENNINGS, Nicholas R. Intelligent Agents: Theory and Practice. *The Knowledge Engineering Review*. 1995. Vol. 10, no. 2, p. 115–152.
 33. WANG, Lei, MA, Chen, FENG, Xueyang, ZHANG, Zeyu, YANG, Hao, ZHANG, Jingsen, CHEN, Zhiyuan, TANG, Jiakai, CHEN, Xu, LIN, Yankai, ZHAO, Wayne Xin, WEI, Zhewei a WEN, Ji-Rong. A Survey on Large Language Model Based Autonomous Agents. *Frontiers of Computer Science*. Online. 2024. Vol. 18, no. 6, p. 186345. Available from: <https://arxiv.org/abs/2308.11432>
 34. SCHICK, Timo, DWIVEDI-YU, Jane, DESSÌ, Roberto, RAILEANU, Roberta, LOMELI, Maria, ZETTMELMOYER, Luke, CANCELEDDA, Nicola a SCIALOM, Thomas. Toolformer: Language Models Can Teach Themselves to Use Tools. *Advances in Neural Information Processing Systems*. Online. 2023. Vol. 36, p. 68539–68551. Available from: <https://arxiv.org/abs/2302.04761>
 35. SENNRICH, Rico, HADDOW, Barry a BIRCH, Alexandra. Neural Machine Translation of Rare Words with Subword Units. *Proceedings of the 54th Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers)*. Online. 2016. P. 1715–1725. Available from: <https://aclanthology.org/P16-1162/>
 36. WU, Qingyun, BANSAL, Gagan, ZHANG, Jieyu, WU, Yiran, LI, Beibin, ZHU, Erkang, JIANG, Li, ZHANG, Xiaoyun, ZHANG, Chi, LIU, Jue, AWADALLAH, Ahmed Hassan, WHITE, Ryan W., BURGER, Doug a WANG, Chi. AutoGen: Enabling Next-Gen LLM App-

- lications via Multi-Agent Conversation. *arXiv preprint arXiv:2308.08155*. Online. 2023. Available from: <https://arxiv.org/abs/2308.08155>
37. ANTHROPIC. Building effective agents. Online. 2024. Available from: <https://www.anthropic.com/research/building-effective-agents>
 38. MERKEL, Dirk. Docker: lightweight linux containers for consistent development and deployment. *Linux Journal*. 2014. Vol. 2014, no. 239, p. 2.
 39. KINSMAN, Timothy, WESSEL, Mairieli, GEROSA, Marco A. a TREUDE, Christoph. How do software developers use GitHub Actions to automate their workflows?. In : *Proceedings of the 18th International Conference on Mining Software Repositories*. 2021. p. 420–431.
 40. DABBISH, Laura, STUART, Colleen, TSAY, Jason a HERBSLEB, Jim. Social coding in GitHub: transparency and collaboration in an open software repository. In : *Proceedings of the ACM 2012 conference on Computer Supported Cooperative Work*. 2012. p. 1277–1286.
 41. OPENAI. The ChatGPT home page. Online. 2026. [Accessed 20 září 2026]. Available from: <https://help.openai.com/en/articles/9125172>
 42. OPENAI DEVELOPER COMMUNITY. Seeking Community Advice: Best Practices for Creating a Comprehensive GPT Manual. Online. 2024. [Accessed 20 září 2026]. Available from: <https://community.openai.com/t/seeking-community-advice-best-practices-for-creating-a-comprehensive-gpt-manual/1033512>
 43. FOWLER, Martin. Vibe Coding. Online. 2026. [Accessed 20 září 2026]. Available from: <https://martinfowler.com/bliki/VibeCoding.html>
 44. GONÇALVES, Pavlína Wurzel, FREGNAN, Enrico, BAUM, Tobias, SCHNEIDER, Kurt a BACCHELLI, Alberto. Do explicit review strategies improve code review performance? Towards understanding the role of cognitive load. *Empirical Software Engineering*. Online. 2022. Vol. 27, no. 4, p. 99. DOI [10.1007/s10664-022-10123-8](https://doi.org/10.1007/s10664-022-10123-8).
 45. GVISOR AUTHORS. Introduction to gVisor security. Online. 2026. [Accessed 20 září 2026]. Available from: https://gvisor.dev/docs/architecture_guide/intro/
 46. MARIUS, Patrik. DarkFactory. Online. 2026. [Accessed 20 září 2026]. Available from: <https://github.com/marius-patrik/DarkFactory>